Ray Tracing Attention：词表角度、因果几何与光路计算

摘要

Ray Tracing Attention（RTA）将高维状态拆分为完整坐标块，以各块的局部角度与幅度形成光路，以历史出现实例保存上下文，由原生光线追踪的交点、遮挡和路径形成读取信号。LM Head 按同一坐标分块编译，保留词元身份、原始量化系数与各包的幅度。当前输入通过编译后的发射映射形成查询，固定传输系数、共享透镜与光路增强共同形成探测信号。历史内容由表面形状、路径状态和探测响应承载，模型采用几何状态缓存。本文给出因果几何、单路径解析式、并行传播、共享内容读出与路径缓存的统一定义，并给出内容信号与参考信号比值实现完整 softmax 注意力的充分条件。分块拼接与逆变换在各层恢复完整高维状态，固定权重与完整块贡献共同保持原模型算子。

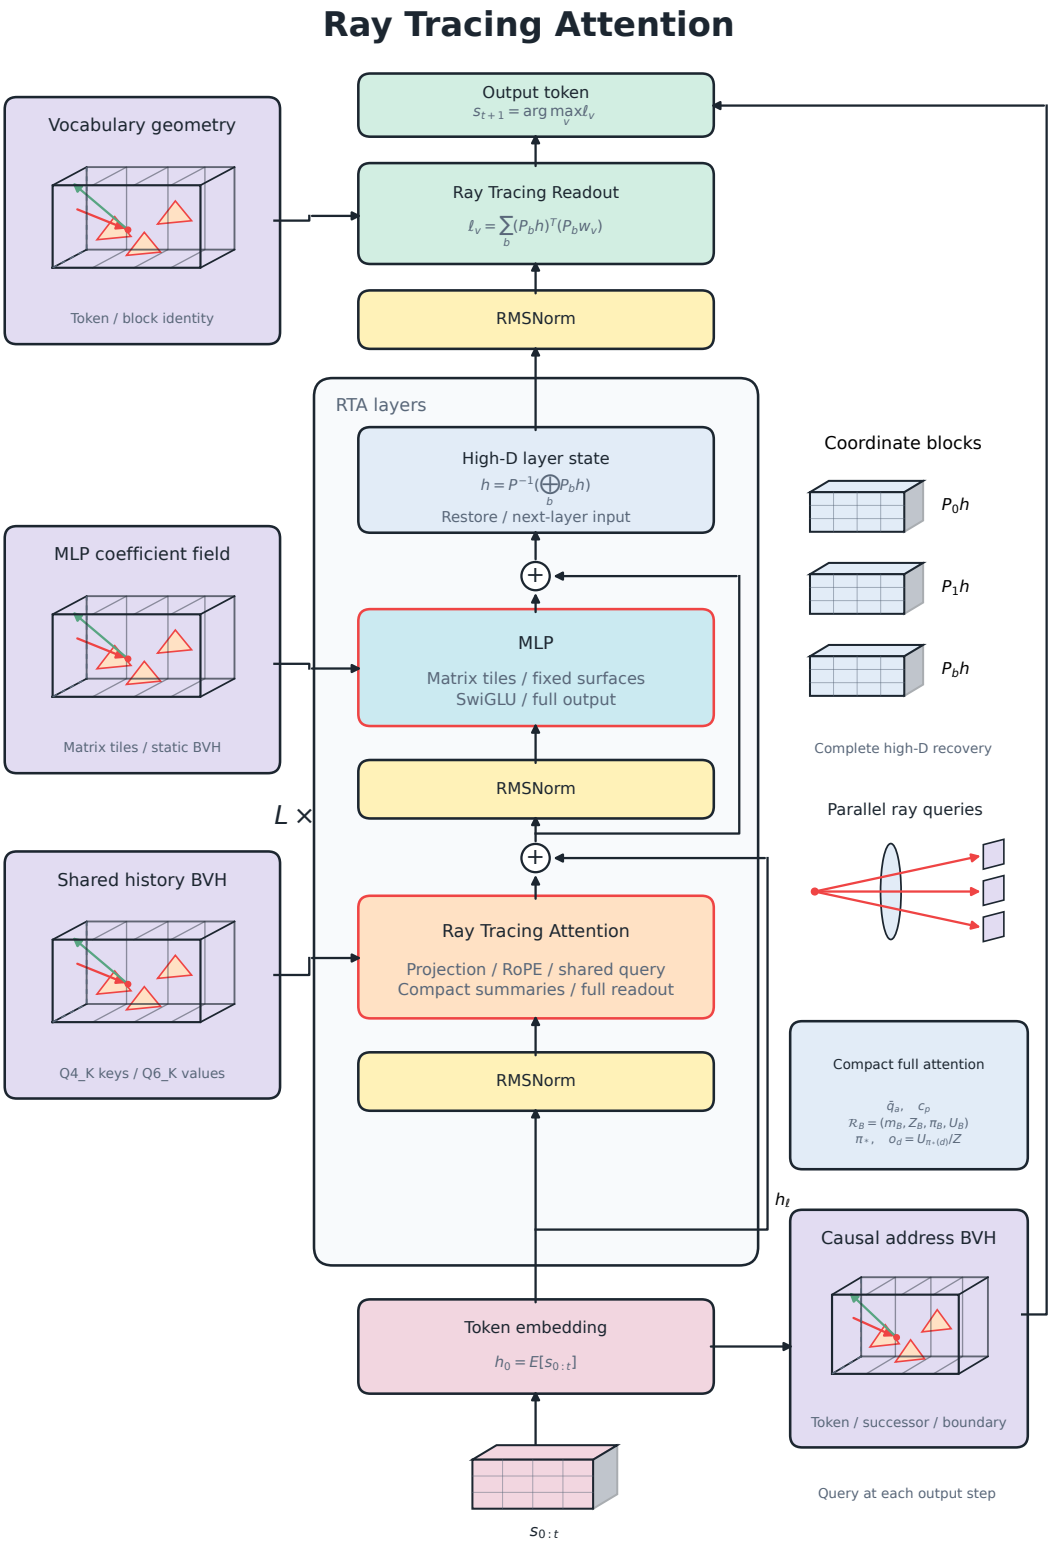


图 1: Ray Tracing Attention 总体算子结构。词元嵌入经过重复 L 层的归一化、Attention、MLP、残差汇合和高维恢复，再由词表光学读出确定输出词元。几何权重与上下文以立体 BVH 表示，坐标分块和并行光线以张量及空间光路表示；各层沿恢复后的完整高维状态连接。

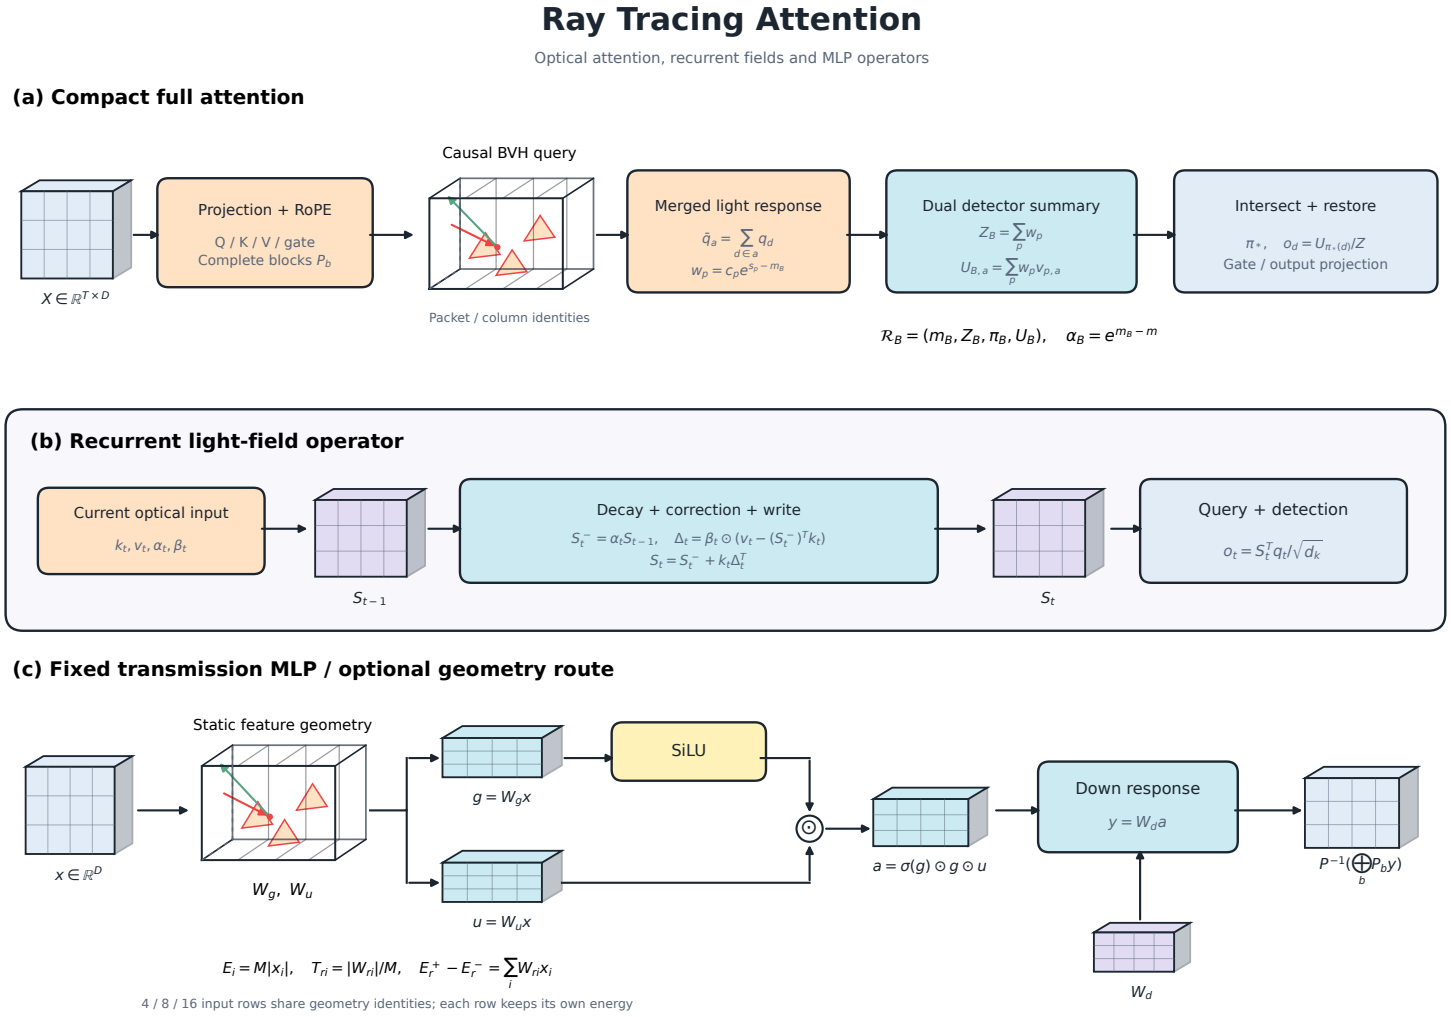


图 2: Attention、递推光场与 MLP 算子。完整注意力由因果几何查询、增强光强、内容与参考探测、比值读出及输出投影组成。递推光场由衰减、校正差和外积写入更新。图中 MLP 将 gate/up 光学响应经 SiLU 与逐分量相乘连接到 down 传输，有符号探测恢复原乘加。矩阵分块实现同一完整前馈算子。

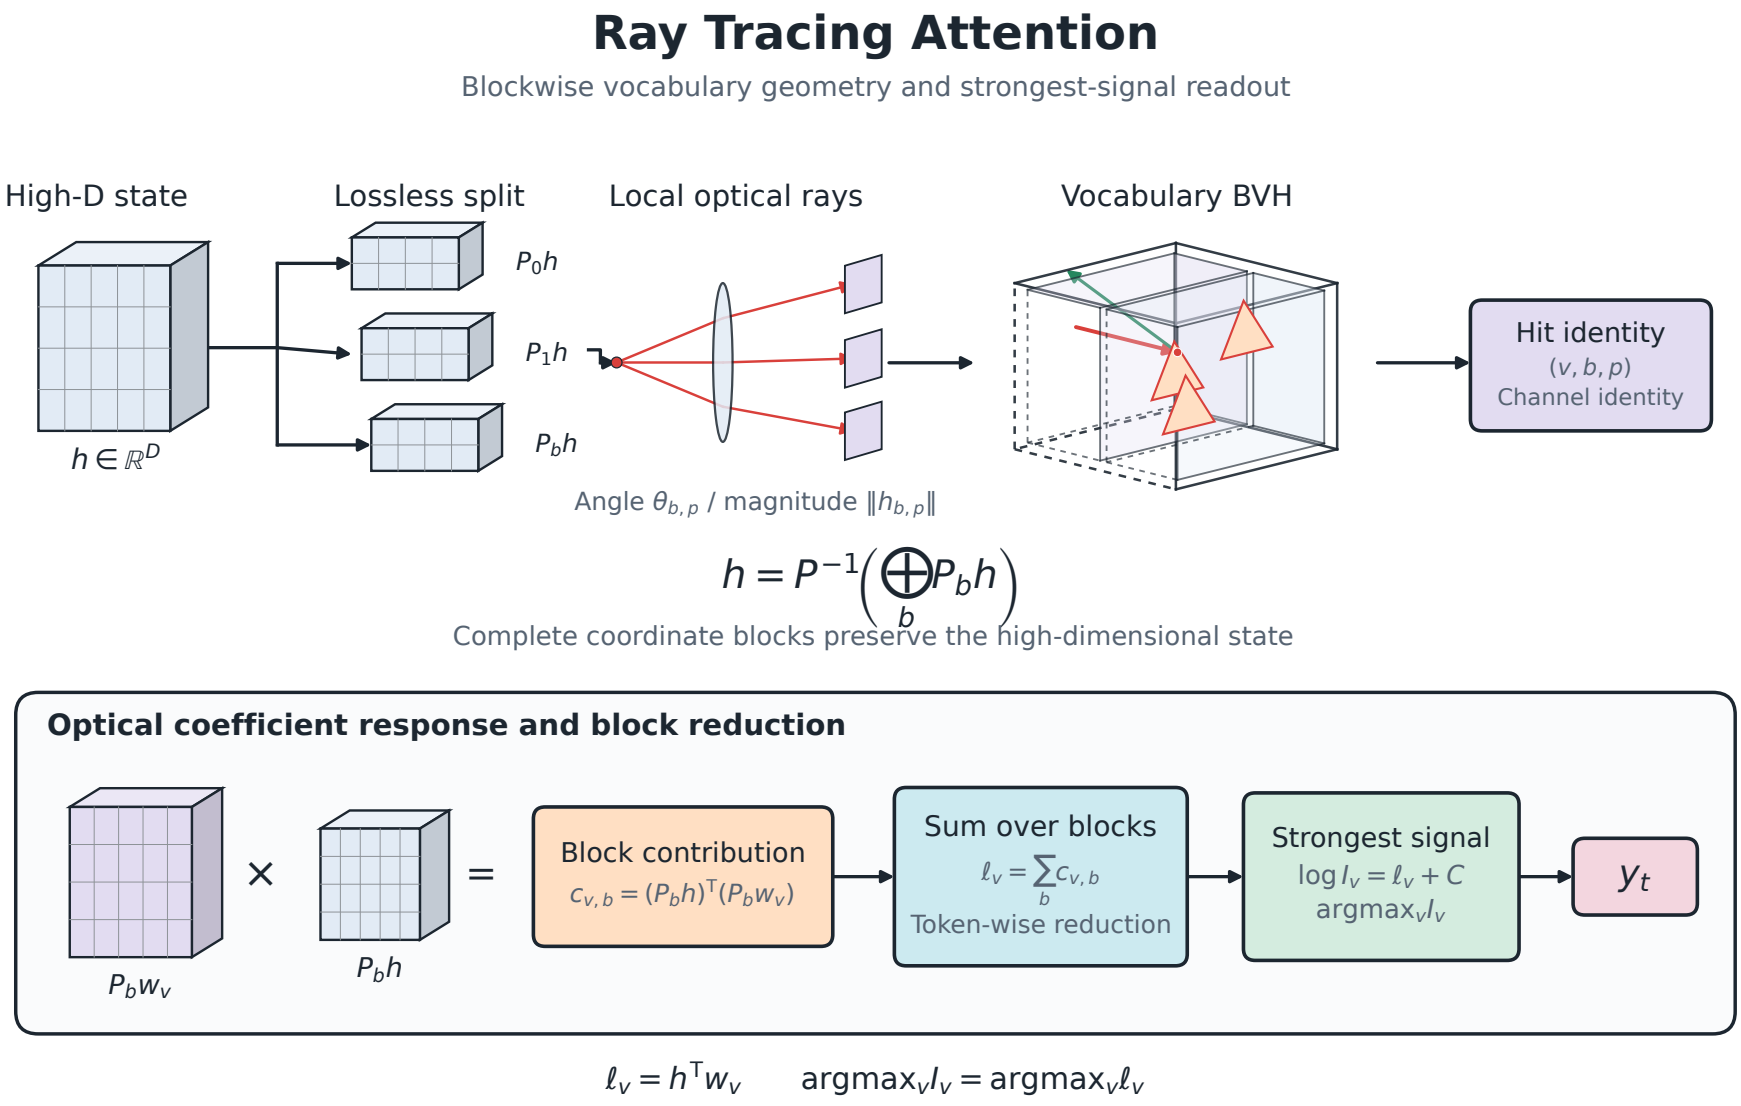


图 3: 分块词表几何与光学读出算子。完整高维状态分为保持通道身份的坐标块，局部角度与幅度形成光线，词表 BVH 求交给出词元、块和包身份。光学系数响应按词元汇合完整块贡献，恢复 LM Head 分数，并以增强光强的最大信号确定输出。

1 整体定义

图 1 展示整体信息流：并行光线查询在层内汇合，各层以恢复后的高维状态相连。图 2 展开 Attention、递推光场和 MLP 的数学算子；图 3 展开完整分块词表几何、光学系数响应和最大信号选词。

设输入词元为 $s_0, \dots, s_{N-1} \in \mathcal{W}$，词表大小为 $V = |\mathcal{W}|$，位置从 0 开始编号。$x_i \in \mathbb{R}^m$ 表示当前输入状态，h_i^{ctx} 表示从已有 RT 光路读取的上下文状态。共享词元参数给出基础方向与模板几何；几何写入器 $\mathcal{G}_\theta$ 把本次出现的内容、位置和上下文写入独立表面实例 S_i。发射器 $\mathcal{E}_\theta$ 围绕词元基础方向产生当前射线。模型在一个 token 上的完整读取为

$$\boxed{x_i \;\longmapsto\; (o_i, d_i) \;\longmapsto\; P_i \in S_{j_i^*} \;\longmapsto\; \gamma_i \;\longmapsto\; z_i = \mathcal{D}(\gamma_i) \;\longmapsto\; y_i.} \tag{1}$$

其中 P_i 是最近可见交点，γ_i 是从发射器经命中表面返回探测器的光路，$\mathcal{D}$ 是全体记录共享的探测规则。每个 token 对应一个入射查询，光路中的传播状态承载后续读出。

符号	含义
$g_j,\ S_j$	第 j 条记录的几何参数与表面
$q_i,\ o_i,\ d$	平面发射位置、三维起点与单位入射方向
$j_i^*,\ P_i,\ \lambda_i$	命中记录、交点与入口传播距离
$r_i,\ F_i,\ \ell_i$	出射方向、探测器相对落点与完整光程
$\Phi_D,\ z_i$	D 通道共享探测映射及其响应
$\theta_{v,b,p},\ n_{v,b,p}$	词元 v 在块 b、包 p 中的局部角度与幅度
$P_b,\ P^{-1}$	完整坐标选择器与拼接后的高维逆变换
$h_i^{\mathrm{ctx}},\ \mathcal{S}_i$	RT 上下文读出及截至位置 i 的几何实例状态

状态的顺序更新写为

$$g_i = \mathcal{G}_\theta(s_i, x_i, h_i^{\mathrm{ctx}}), \qquad \mathcal{S}_i = \mathcal{S}_{i-1} \cup \{S(g_i, i)\}. \tag{2}$$

写入器规定内容在空间中的形状，发射器规定读取地址，传播规律规定命中内容怎样形成探测信号。式 (1) 描述一条基本光路；多分支与多段光路在后文沿同一接口组合。历史状态由几何实例、时序身份和光路状态构成，内容读取采用共享几何探测映射。

2 分块词表几何与共享码本

2.1 可逆坐标分块与高维恢复

设当前层状态为 $h \in \mathbb{R}^m$。编译器定义可逆坐标变换 P，按不重叠、无遗漏的选择器 E_b 取出分块 $P_b = E_b P$。将所有块按编译顺序直接拼接，即得到式 (3)。当前实现采用原始坐标顺序的完整选择器，一个计算块包含 256 个坐标，并进一步分成 128 个双坐标光路包。分块数为 $B_P = m/256$；块索引、包索引和块内坐标共同确定原始通道。各包以原始有限数值的位模式保存，拼接恢复包括符号、指数、有效位与有符号零。几何角度、幅度和固定响应由对应包形成，完整包载荷承载高维信息。

对任意可逆 P，输出头同步变换为 $\widetilde{W}_{\mathrm{LM}} = W_{\mathrm{LM}} P^{-1}$。对当前完整坐标选择器或坐标置换，有 $\sum_b P_b^{\mathsf{T}} P_b = I$，因此

$$\widetilde{h} = Ph = \bigoplus_{b=0}^{B_P-1} P_b h, \qquad \boxed{h = P^{-1}\left(\bigoplus_b P_b h\right)}. \tag{3}$$

$$h^{\mathsf{T}} w_v = \sum_b (P_b h)^{\mathsf{T}} (P_b w_v). \tag{4}$$

每层光路分别读取对应块，探测结果按块与通道身份写回，由式 (3) 恢复当前层的完整高维状态，再进入下一层。词表输出端对同一词元汇合各块贡献，随后确定最大信号的词元。

2.2 LM Head 的分块方向与尺度

设原模型的无偏置输出头为 $W_{\mathrm{LM}} \in \mathbb{R}^{V\times m}$，第 v 行为 w_v^{T}。记块内第 p 个双坐标包为 $h_{b,p}$ 与 $w_{v,b,p}$，定义局部幅度 $n_{v,b,p} = \|w_{v,b,p}\|$。完整词表分数满足

$$\ell_v = h^{\mathsf{T}} w_v = \sum_{b,p} \|h_{b,p}\|\, n_{v,b,p} \cos\angle(h_{b,p}, w_{v,b,p}), \qquad \|w_v\|^2 = \sum_{b,p} n_{v,b,p}^2. \tag{5}$$

角度由各个双坐标包产生，幅度保留该包的分数尺度。零幅度包贡献为零，并保留其词元与坐标身份。

导出时按原始词表顺序读取全部 V 行，保留原始量化块、系数位模式和词元身份。编译资产记录每个 256 坐标块的起始通道、长度与双坐标包索引。模型前向时由对应块的当前数值形成局部几何，固定参数下复用首次前向得到的几何实例与共享响应测量。输入嵌入与输出头共享权重时复用同一份固定载荷。

2.3 局部光学坐标与复合身份

对一个固定双坐标包 $\xi_{v,b,p}$，局部光学坐标记为 $t_{v,b,p} \in \mathbb{R}^2$。方向由同一半球坐标图形成：

$$d_{v,b,p} = \frac{(t_{v,b,p,1}, t_{v,b,p,2}, 1)}{\sqrt{1+\|t_{v,b,p}\|^2}}, \qquad \theta_{v,b,p} = \left(\operatorname{atan2}(t_{v,b,p,2}, t_{v,b,p,1}), \arctan\|t_{v,b,p}\|\right). \tag{6}$$

$$\mathrm{Address}(v,b,p) = (v,b,p), \qquad (v,b,p) \neq (u,c,r) \Longrightarrow \mathrm{Address}(v,b,p) \neq \mathrm{Address}(u,c,r). \tag{7}$$

取 $\|t_{v,b,p}\| \le \tan\beta_{\max}$、$\beta_{\max} < \pi/2$。原始包与幅度同时保存，局部坐标图由包的数值生成。后文描述固定块中的单条光路时，省略 b,p 下标。

块实例以复合身份寻址：式 (7)。相同局部方向可以复用同一基础图元，词元 ID、分块 ID 与包索引保持独立。原生图元 ID 确定块域与词元，固定系数块与双坐标包确定其完整通道载荷。命中回执按块分别保存，并按词元身份汇合探测信号。

2.4 稳定基础方向与上下文修正

在读取位置 i，首先用词元基础射线从历史场景 $\mathcal{S}_{i-1}$ 得到上下文：式 (8)。再在 d_{s_i} 的切平面中给出小幅修正。令 $T_v \in \mathbb{R}^{3\times 2}$ 的列为该切平面的正交基，则

$$\gamma_i^{\mathrm{ctx}} = \mathrm{TraceRT}(\mathcal{S}_{i-1}, s_i, \theta_{s_i}), \qquad h_i^{\mathrm{ctx}} = \mathcal{D}_{\mathrm{ctx}}(\gamma_i^{\mathrm{ctx}}). \tag{8}$$

$$\epsilon_i = \epsilon_{\max}\tanh\mathcal{A}_\theta(x_i, h_i^{\mathrm{ctx}}, \theta_{s_i}), \qquad d_i = \frac{d_{s_i} + T_{s_i}\epsilon_i}{\|d_{s_i} + T_{s_i}\epsilon_i\|}. \tag{9}$$

因为 $d_{s_i}^{\mathsf{T}} T_{s_i} = 0$，方向改变量满足 $\angle(d_i, d_{s_i}) = \arctan\|\epsilon_i\|$。取 $\beta_{\max} + \arctan(\sqrt{2}\epsilon_{\max}) < \pi/2$ 保持因果方向，由 $\|\epsilon_i\| \le \sqrt{2}\epsilon_{\max}$ 控制局部范围，保持词元基础方向稳定，同时让当前语境改变有效寻址。

同一词元的多次出现共用 θ_v 和基础模板，每次出现分别保存位置 j、上下文形状 g_j 和时序身

份。例如同一主体的较新事实可以写入本次上下文光路覆盖的地址域，查询的角度修正与原生最近命中共同定位当前有效记录。这种更新保留词元基础身份，并以历史实例之间的光路关系表达事实变化。

3 几何记忆与因果时间轴

3.1 有限镜面的参数化

基本记录采用七个几何参数：式 (10)。$c_j \in \mathbb{R}^2$ 是镜面中心，$a_j \in \mathbb{R}^2$ 决定倾角，h_j 是相对高度，$r_j \in \mathbb{R}^2_{>0}$ 是半孔径。记平面坐标 $\xi = (x, y)$，镜面定义为式 (11)。不等式按坐标分别成立。镜面朝 $-z$ 一侧反射，另一侧透射。

一组具体的有界写入映射为式 (14)。取

$$g_j = (c_{jx}, c_{jy}, a_{jx}, a_{jy}, h_j, r_{jx}, r_{jy}). \tag{10}$$

$$S_j : \quad z = -\Delta j + h_j - a_j^{\mathsf{T}}(\xi - c_j), \qquad |\xi - c_j| \le r_j. \tag{11}$$

$$w_j = W_G \,\mathrm{Norm}(x_j) + b_G \in \mathbb{R}^7, \tag{12}$$

$$c_j = \tanh(w_{j,1:2}), \qquad a_j = A \tanh(w_{j,3:4}), \tag{13}$$

$$h_j = H \tanh(w_{j,5}), \qquad r_j = r_{\min} + (r_{\max} - r_{\min})\sigma(w_{j,6:7}), \tag{14}$$

$$A = H = \frac{1}{4}, \qquad r_{\min} = \frac{1}{40}, \qquad r_{\max} = \frac{1}{2}, \qquad \Delta = 4. \tag{15}$$

中心与孔径决定可访问区域，倾角决定反射方向，高度决定传播距离。这些量共同定义同一块几何记忆。

3.2 竖直射线的解析坐标模板

为得到可直接验证的闭式光路，先采用竖直入射的局部模板。发射器将当前输入映射到二维平面地址：式 (16)。令发射器位于当前时间层的下方，固定间距 $s = 2$：

$$q_i = \tanh\big(W_E \,\mathrm{Norm}(x_i) + b_E\big) \in (-1, 1)^2. \tag{16}$$

$$o_i = (q_{ix}, q_{iy}, -\Delta i - s), \qquad d = (0, 0, 1), \qquad \rho_i(t) = o_i + td, \quad t > 0. \tag{17}$$

二维地址承担这一模板的语义寻址，纵向坐标承担顺序与因果关系。一般角度射线沿式 (6)–(9) 发射，其求交与传播在后文定义。

3.3 因果性的几何构造

令镜面相对于时间层的最大高度幅度为 同组的高度幅度式。于是每个表面都满足

$$B_z = H + 2Ar_{\max} = \frac{1}{2}.$$

$$-\Delta j - B_z \le z(S_j) \le -\Delta j + B_z. \tag{18}$$

命题 1 (因果可见性)**.** 当 $B_z < s < \Delta - B_z$ 时，查询 i 的全部历史镜面位于入射方向前方，全部未来镜面位于起点后方。

证明. 对 $j \le i$，镜面的最低点与起点之间的纵向距离至少为 同组的历史距离下界。对 $j \ge i+1$，镜面的最高点与起点之间的距离至多为

$$\Delta(i-j)+s-B_z \geq s-B_z > 0.$$

$$\Delta(i-j)+s+B_z \leq -\Delta+s+B_z < 0.$$

式 (15) 取值下，两侧各有 1.5 的严格间隔。 □

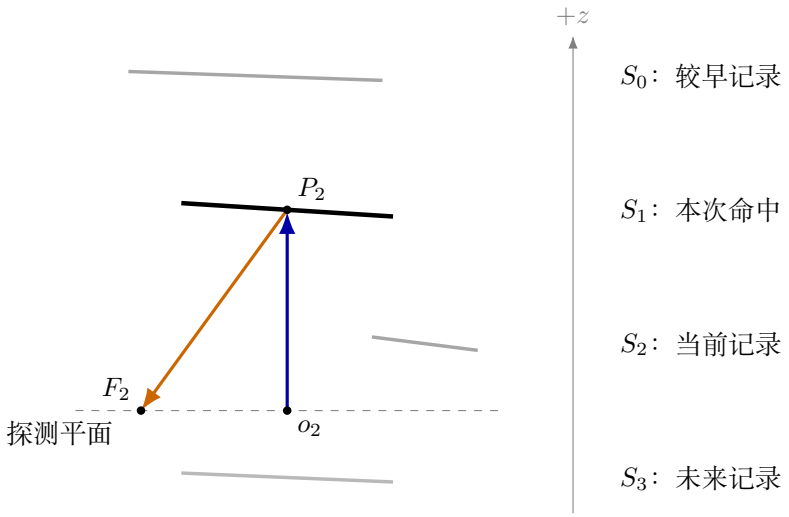


图 4: 时间层与单条光路的截面示意。查询地址穿过当前镜面的孔径之外，在较早镜面上反射；未来记录位于发射器后方。

3.4 空间地址上的最近写入

记孔径区域 同组的孔径定义。当 $q_i \in \mathcal{A}_j$ 时，入口距离由平面方程直接给出：式 (19)。设可访问记录集合为 同组的可访问集合定义。读取索引为

$$\mathcal{A}_j = \{\xi : |\xi - c_j| \leq r_j\}.$$

$$\lambda_{ij} = \Delta(i-j)+s+h_j-a_j^{\mathsf{T}}(q_i-c_j). \tag{19}$$

$$\mathcal{V}_i(q_i) = \{j \leq i : q_i \in \mathcal{A}_j\}.$$

$$j_i^* = \arg\min_{j\in\mathcal{V}_i(q_i)} \lambda_{ij}. \tag{20}$$

$$j_i^* = \max \mathcal{V}_i(q_i). \tag{21}$$

$$\mathcal{D}_{ij} = \mathcal{A}_j \setminus \bigcup_{j<k\leq i} \mathcal{A}_k. \tag{22}$$

集合为空时，以 $\perp$ 表示空路径，并令其探测响应为零。

由于相邻时间层的间隔 Δ 大于 $2B_z$，式 (20) 等价于式 (21)。这是一种带空间地址的覆盖式记忆：同一地址由最近覆盖它的表面响应，不同孔径区域保存各自的可见历史。

对于固定查询时刻 i，记录 j 的可见地址域为式 (22)。这些区域将发射平面划分为由不同记录响应的部分。BVH 将该几何集合组织为空间层次，按照射线与包围区域的相交关系完成定位，最近交点直接确定读取路径。式 (20) 和式 (22) 定义几何语义；运行时的候选、交点与遮挡由原生 RT Core/BVH 求得。

4 单路径反射与完整光程

4.1 命中点与出射方向

记本次命中参数为 $a = a_{j_i^*}$、$\lambda = \lambda_{ij_i^*}$。在发射器局部坐标系中，入射点为原点，命中点为 同组的命中点式。取 $n = (a_x, a_y, 1)$。反射方向由

$$P = (0, 0, \lambda).$$

$$r = d - 2\frac{n^{\mathsf{T}} d}{n^{\mathsf{T}} n} n = \left(-\frac{2a}{1 + \|a\|^2}, \frac{\|a\|^2 - 1}{1 + \|a\|^2} \right) \tag{23}$$

给出，且 $\|r\| = 1$。参数域 (15) 保证 $\|a\|^2 \le 1/8$，所以 $r_z < 0$。射线沿同一条反射路径返回探测平面。

4.2 固定局部探测平面

探测器固定在发射器局部坐标系的 $z = 0$ 平面，其全局位置随时间原点平移。令返回距离为 η，则 同组的回程距离式。相对发射位置的落点及往返光程为

$$\lambda + \eta r_z = 0, \qquad \eta = \lambda \frac{1 + \|a\|^2}{1 - \|a\|^2}.$$

$$\boxed{F_{xy} = -\frac{2\lambda a}{1 - \|a\|^2}, \qquad \ell = \lambda + \eta = \frac{2\lambda}{1 - \|a\|^2}.} \tag{24}$$

因而 $F_{xy} = -\ell a$。倾角写入探测器落点，高度与记录距离写入飞行时间，两者由同一次几何命中联合读出。

4.3 回程的几何可达性

命题 2 (单面镜的直接回程)**.** 设场景内任意镜面倾角 a, b 均满足各坐标绝对值不超过 $1/4$。由倾角 a 产生的反射方向，在其他镜面上均从透射侧通过。

证明. 用 $\tilde{n}_b = (b_x, b_y, 1)$ 表示另一镜面的法向。根据式 (23)，

$$\tilde{n}_b^{\mathsf{T}} r = \frac{\|a\|^2 - 1 - 2b^{\mathsf{T}} a}{1 + \|a\|^2} \le \frac{-5/8}{1 + \|a\|^2} < 0.$$

其他镜面的反射正面朝 $-\tilde{n}_b$，因此回程与其外向反射法向的内积为正，对应背面透射。整条返回光路由式 (24) 确定。 □

4.4 传播能量

在均匀介质中，采用光程衰减系数 $\mu > 0$，单位发射与单位表面增益的基准强度为

$$E_i = \exp(-\mu \ell_i). \tag{25}$$

一个具体取值为 $\mu = 1/4096$。这使路径长度同时表现为时间观测和强度观测。发射、表面相互作用与探测共同构成一次完整的有向几何读取。路径增强在这一传播因子上乘以独立增益。

5 共享探测器与多通道编码

5.1 路径观测

定义归一化光路观测

$$u_i = \left(\frac{F_{ix}}{1+\ell_i}, \frac{F_{iy}}{1+\ell_i}, \log_2(1+\ell_i) \right) \in \mathbb{R}^3. \tag{26}$$

$$z_{i,k} = E_i b_k(u_i).$$

前两项描述落点，第三项描述飞行距离的对数尺度。探测器采用对所有记录共享的基函数 $b_k(u)$，产生 同组的通道响应式。输出宽度由探测模式的数量确定，每个模式观测同一条入射与反射光路。

5.2 一组具体的 Fourier 探测模式

令输出维数 $D \geq 4$ 为偶数，模式编号 $k = 0, \ldots, D/2-1$。取

$$d_k = k \bmod 3, \qquad f_k = \frac{\lfloor k/3 \rfloor + 1}{4}.$$

$$z_{i,2k} = E_i \sin(2\pi f_k u_{i,d_k}), \tag{27}$$

$$z_{i,2k+1} = E_i \cos(2\pi f_k u_{i,d_k}). \tag{28}$$

完整响应定义为式 (28)。$D = 256$ 对应 128 对正弦与余弦响应。较低频率描述光路的整体变化，较高频率提供更细的响应结构。共享线性输出投影将这些模式组合为模型的残差分支信号。

命题 3 (基准强度下的光路可解码性)**.** 对 $\ell > 0$、$\mu > 0$，采用式 (25) 的已标定基准强度时，式 (28) 的前两个空间模式及其共同强度可以恢复 ℓ 与 F_{xy}。

证明. 由第一对响应恢复强度：同组的强度与光程恢复式。对任意单位方向传播到探测平面的光路，$|F_x|, |F_y| \leq \ell$，所以 $|u_x|, |u_y| < 1$。第一组空间频率为 $1/4$，相位落在 $(-\pi/2, \pi/2)$ 内，故

$$E = \sqrt{z_0^2 + z_1^2}, \qquad \ell = -\frac{1}{\mu} \log E.$$

$$u_x = \frac{2}{\pi} \operatorname{atan2}(z_0, z_1), \qquad u_y = \frac{2}{\pi} \operatorname{atan2}(z_2, z_3), \qquad F_{xy} = (1+\ell)(u_x, u_y).$$

在镜面模板下，进一步由 $a = -F_{xy}/\ell$ 与 $\lambda = \ell(1 - \|a\|^2)/2$ 恢复命中倾角和入口距离。 □

这个构造把形状响应、传播距离与有符号输出连接起来。能量控制共同幅度，探测基函数提供各输出通道的空间与时间响应。

5.3 平衡探测的有符号读出

对任一探测模式 $b_c(u) \in [-1, 1]$，将对应份额的光强分配到正、负两支：

$$I_c^+ = \frac{E}{2D}\big(1 + b_c(u)\big), \qquad I_c^- = \frac{E}{2D}\big(1 - b_c(u)\big). \tag{29}$$

$$z_c = D(I_c^+ - I_c^-) = E\, b_c(u). \tag{30}$$

两支均为非负强度，全部通道的强度总和为 E。统一标定后的平衡差给出式 (30)。空间与飞行时间决定共享模板的透射比例，平衡差形成模型使用的有符号特征。

6 曲面几何的统一表达

6.1 从平面到形状场

几何记忆还可以表示为有限孔径上的高度场：式 (31)。约束取为式 (32)。这些条件保持时间层的因果间隔和反射法向的角度范围。

一条竖直射线在其查询地址处读取

$$S_j:\quad z=-\Delta j+H_j(\xi),\qquad \xi\in\mathcal{A}_j. \tag{31}$$

$$|H_j(\xi)|\le B_z,\qquad |\partial_x H_j(\xi)|,\ |\partial_y H_j(\xi)|\le A. \tag{32}$$

$$\lambda_{ij}=\Delta(i-j)+s+H_j(q_i),\qquad a_{ij}=-\nabla H_j(q_i). \tag{33}$$

将它们代入式 (24)，即可得到同一探测规则下的光路。曲面在不同地址提供不同的高度与法向响应，从而将一条历史记录表示为可被查询位置采样的几何函数。

6.2 控制点写入

例如，采用次数为 (p,q) 的张量积 Bézier 高度场。在孔径内定义局部坐标 同组的局部坐标式。令 $B_a^p(s)=\binom{p}{a}s^a(1-s)^{p-a}$，写入

$$s_x=\frac{\xi_x-c_{jx}+r_{jx}}{2r_{jx}},\qquad s_y=\frac{\xi_y-c_{jy}+r_{jy}}{2r_{jy}}.$$

$$H_j(\xi)=\sum_{a=0}^{p}\sum_{b=0}^{q}\beta_{j,ab}B_a^p(s_x)B_b^q(s_y). \tag{34}$$

控制系数 $\beta_{j,ab}$ 是曲面的形状坐标。Bernstein 基函数的非负性和分割统一性给出 同组的幅度界。同时，

$$|H_j|\le\max_{a,b}|\beta_{j,ab}|.$$

$$|\partial_x H_j|\le\frac{p}{2r_{jx}}\max_{a,b}|\beta_{j,a+1,b}-\beta_{j,ab}|, \tag{35}$$

$$|\partial_y H_j|\le\frac{q}{2r_{jy}}\max_{a,b}|\beta_{j,a,b+1}-\beta_{j,ab}|. \tag{36}$$

因此，控制点的幅度与相邻差分约束直接实现式 (32)。平面、分片平面和光滑曲面由此共享同一套时间轴、入口查询与探测定义。几何表示的细节通过命中位置处的高度和局部法向进入读出。

7 发射模板与单路径软读取

7.1 发射位置的概率模板

令 $p_i(q)$ 为查询 i 在发射平面上的概率密度。它描述语义地址附近的入射分布。一次读取从该模板取一个位置：同组的发射位置式。记录 j 被读取的概率为式 (37)。设 $\mathcal{D}_{i\perp}$ 为孔径并集之外的区域，则 同组的概率归一化式。

在概率意义下，探测响应的完整期望为

$$q_i\sim p_i(q),\qquad \rho_i(t)=(q_i,-\Delta i-s)+td.$$

$$\alpha_{ij}=\int_{\mathcal{D}_{ij}}p_i(q)\,\mathrm{d}q. \tag{37}$$

$$\sum_{j\le i}\alpha_{ij}+\alpha_{i\perp}=1.$$

$$\overline{z}_i=\sum_{j\le i}\int_{\mathcal{D}_{ij}}p_i(q)\,e^{-\mu\ell_{ij}(q)}\Phi_D\big(u_{ij}(q)\big)\,\mathrm{d}q. \tag{38}$$

$$\eta_i\sim\mathcal{N}(m_i,\Sigma_i),\qquad q_i=\tanh\eta_i,\qquad (m_i,\Sigma_i)=\mathcal{E}_\theta(x_i). \tag{39}$$

这里 Φ_D 表示式 (28) 中的单位幅度模式。一次采样产生一个 z_i，其期望正是式 (38)。可见区域的概率质量决定记录的参与程度，光路决定具体的信号内容。

一种带有限束宽的发射模板为式 (39)。例如可取 $\Sigma_i = \mathrm{diag}(\mathrm{softplus}(s_i)^2)$，其中 s_i 由发射器同时给出。中心 m_i 给出查询地址，协方差 Σ_i 给出射线束的空间范围。将分布集中到中心位置，得到确定性的中心射线读取。

7.2 单次方向采样的漫反射模板

在命中点处，可围绕镜面方向 r 规定一个半角为 Θ 的散射锥。令 (t_1, t_2, r) 为正交标架，出射方向写为式 (40)。相对于立体角 $\mathrm{d}\omega = \sin\theta\,\mathrm{d}\theta\,\mathrm{d}\phi$，归一化余弦模板为式 (41)。令 u, v 为两个独立均匀随机数，使用

$$\omega = \cos\theta\, r + \sin\theta(\cos\phi\, t_1 + \sin\phi\, t_2). \tag{40}$$

$$p_\Theta(\theta,\phi) = \frac{\cos\theta}{\pi \sin^2\Theta}\mathbf{1}_{\{0\le\theta\le\Theta\}}, \quad 0 \le \phi < 2\pi. \tag{41}$$

$$\theta = \arcsin(\sin\Theta\sqrt{u}), \qquad \phi = 2\pi v$$

即可取一个出射方向。$\Theta = 0$ 对应中心镜面方向。

记法向最大偏角为 $\beta = \arctan(\sqrt{2}A)$。取式 (42) 中的约束，便保持出射方向朝向探测器，并从场景其他镜面的透射侧通过。例如 $A = 1/4$ 时可取 $\Theta \le \pi/12$。

给定本次采样的 ω，完整返回光路为

$$3\beta + \Theta < \frac{\pi}{2}, \tag{42}$$

$$\eta = \frac{\lambda}{-\omega_z}, \qquad F_{xy} = \eta\omega_{xy}, \qquad \ell = \lambda + \eta. \tag{43}$$

同一条路径在表面上完成一次方向选择，再进入共享探测规则。对发射位置和出射方向同时取期望，式 (38) 的被积项相应增加对散射模板的期望。这把确定性反射和单路径漫反射纳入统一的传播模型。

8 角度光路、共享透镜与独立增强

8.1 一般射线与多段传播

第 k 段射线记为 $\rho_k(t) = o_k + t d_k$、$t > 0$、$\|d_k\| = 1$。对式 (11) 的平面表面，候选交点的解析距离为式 (44)。分母为零时按平行射线处理，正距离、孔径归属、面朝向及最近遮挡共同确定有效命中。求交观测量由命中目标身份、重心坐标与传播距离组成，局部形状映射给出命中处的法向。式 (44) 用于描述或验证已选命中的几何量。

镜面反射采用单位法向 $\widehat{n}_k$：

$$t_{kj} = \frac{-\Delta j + h_j - o_{k,z} - a_j^{\mathsf{T}}(o_{k,xy} - c_j)}{d_{k,z} + a_j^{\mathsf{T}} d_{k,xy}}. \tag{44}$$

$$P_k = o_k + t_k d_k, \qquad d_{k+1} = d_k - 2(d_k^{\mathsf{T}}\widehat{n}_k)\widehat{n}_k. \tag{45}$$

$$\Omega_i = \{(x,y,z) : z \ge -\Delta i - s\}, \tag{46}$$

下一段从经数值偏移的 P_k 发射，并再次执行原生最近交点查询。路径 $\gamma = (P_0, \ldots, P_L)$ 保存实际的分支、实例和传播顺序，光程为 $\ell_\gamma = \sum_k t_k$。斜入射或多段光路的光程使用各段实际长度；式 (24) 是竖直入射、单次镜面反射和固定局部探测平面的解析特例。

对初始方向 $d_{i,z} > 0$，时间层构造使未来记录处于起点的下方。多段传播将有效场景限制在式 (46)。并在该边界上的探测终点结束。透镜与后续射线采用同一因果域；越过下边界的路径终止，

或由前缀实例集合 $\mathcal{S}_i$ 构建相应 RT 场景。这样，任意反射方向都只访问当前及历史出现实例。

8.2 共享可移动透镜

透镜参数 $\Lambda = \{\lambda_a\}_{a=1}^{M_{\text{lens}}}$ 包括共享形状、位置、姿态与折射率。透镜在各查询的局部光学坐标系中复用同一模板；局部时间原点与场景变换将其放入式 (46) 的有效区域。移动透镜通过参数更新改变光路的转向、聚焦、可见实例和探测位置。其交点仍由原生 RT 场景求得，表面相互作用按反射或折射规律计算。例如单位入射方向 d、朝向入射侧的法向 n、折射率比 η，在 $c = -n^{\mathsf{T}}d \geq 0$ 且 $1 - \eta^2(1 - c^2) \geq 0$ 时有

$$d' = \eta d + \left(\eta c - \sqrt{1 - \eta^2(1 - c^2)}\right) n. \tag{47}$$

全反射区域采用相应反射规则。共享透镜属于模型参数，历史实例属于上下文状态，两者通过输入相关的交点与传播路径共同影响输出。

8.3 独立光路增强与探测汇合

每条有效光路有独立的对数增强 $g_{ik} = \text{softplus}(\rho_{ik}) \geq 0$，对应增强倍数 $G_{ik} = \exp(g_{ik}) \geq 1$。增强参数由当前输入、命中形状与共享增益映射给出；词元原始范数则初始化独立的发射幅度。物理强度采用乘法增强：式 (48)。g_{ik} 的非负约束使独立增强相对于同一传播条件的单位增益基准增加强度。传播和增强直接作用于每条光路的强度，汇合端积累各路信号。若采用非相干强度或分离的探测通道，内容信号为

$$I_{i\gamma} = I_{i\gamma}^{\text{emit}} \exp\left(\sum_{k\in\gamma} g_{ik} - \mu\ell_\gamma\right) \prod_{k\in\gamma} T_{ik}, \qquad T_{ik} \in [0, 1]. \tag{48}$$

$$z_i = \sum_{\gamma\in\Gamma_i} I_{i\gamma}\, \Phi_\theta(\gamma, \mathcal{S}_i). \tag{49}$$

参考通道可同时保存总强度 $R_i = \sum_\gamma I_{i\gamma}$。共同数值标定用于控制动态范围；内容与参考的比值读出将在后文单独定义。

当额外增益存在时，光程可由显式飞行时间或经增益标定的传播参考恢复；基准强度可解码命题使用其已给出的单位增益条件。几何坐标中的长度尺度变换、单路强度增强和输出比值读出分别承担不同作用。

9 光路承载内容与并行计算

9.1 几何内容的表达自由度

设历史实例的完整几何表示为 $G_j \in \mathbb{R}^p$，它可以包含多个曲面控制点、局部法向场、出现变换和光学响应参数。共享内容探测器给出

$$\Phi_\theta(G_j, \gamma_{ij}) = \mathcal{R}_\theta\big(\Psi_1(G_j, \gamma_{ij}), \ldots, \Psi_Q(G_j, \gamma_{ij})\big) \in \mathbb{R}^{d_v}. \tag{50}$$

历史内容保存于几何与光路状态中，$\mathcal{R}_\theta$ 是共享模型参数。该结构采用几何缓存，逐条历史的值信息由 G_j 与其可观测路径承载。连续恢复一般 d_v 维值向量要求足够的几何自由度和可辨识探测量；例如对开集上的连续单射编码，至少需要 $p \geq d_v$。有限词表的唯一离散地址只要求式 (7)，而上下文内容的连续恢复还要求式 (50) 具有相应容量。前文七参数单面镜给出受约束的解析响应族；多曲面、控制点与多条独立光路提供更丰富的几何内容表示。

9.2 共享 Fourier 投影的分解

对前文三坐标探测模板，设 $W_O \in \mathbb{R}^{m\times D}$，第 k 对频率为 $\omega_k = 2\pi f_k$，轴编号为 d_k。共享输出投影可精确分解为三个一维向量场：

$$\mathcal{F}_a(u) = \sum_{k:d_k=a} \left[W_{O,:,2k}\sin(\omega_k u) + W_{O,:,2k+1}\cos(\omega_k u)\right], \tag{51}$$

$$W_O z_i = I_i \sum_{a=0}^{2} \mathcal{F}_a(u_{i,a}). \tag{52}$$

向量场值直接位于 m 维输出空间。固定模型参数时，可对各场预采样并插值，误差由表格精度与采样间隔度量。这种分解保留原 Fourier 投影的数学表达；输出维数与实例所携带的独立几何自由度分别由探测接口和内容编码决定。

9.3 并行分支与命中需求

设光学分支数为 B，当前原生配置取 $B = 32$。各分支共用词元身份与基础角度码本，通过自身的场景坐标变换、共享或分支探测参数产生光路。同一位置的 B 个初始查询可以并行发射，多段路径还可连接分支。记原生命中形成的可用分支集合为 $\mathcal{H}_i$，根据光路增强与任务相关优先级选择 $\mathcal{B}_i \subseteq \mathcal{H}_i$，并令 $|\mathcal{B}_i| \le K$。各个参与分支计算

$$r_{b,i} = x_i + W_{O,b} z_{b,i} + b_{O,b}, \tag{53}$$

$$m_{b,i} = \mathcal{M}_{\mathrm{RT},b}\big(\mathrm{Norm}_b^{\mathrm{post}}(r_{b,i})\big), \tag{54}$$

$$y_i = \begin{cases} |\mathcal{B}_i|^{-1} \displaystyle\sum_{b\in\mathcal{B}_i} (r_{b,i} + m_{b,i}), & |\mathcal{B}_i| > 0, \\ x_i, & |\mathcal{B}_i| = 0. \end{cases} \tag{55}$$

光路强度按式 (48) 增强，分支均值则在输出接口稳定残差尺度。命中队列决定实际执行的内容变换数量。对已确定的输入状态，各分支写入与查询可以同时展开；若出现形状或角度修正依赖式 (8)，前缀计算保留相应的历史依赖。生成时按依赖顺序追加当前实例并读取下一位置。

10 纯光路前馈变换

10.1 线性透射与平衡探测

将平衡探测扩展到任意有限矩阵 $W \in \mathbb{R}^{n\times m}$。取 $M \ge \max_{r,i}|W_{ri}|$，几何表面保存符号与透射系数 $T_{ri} = |W_{ri}|/M$。输入 x_i 以发射强度 $E_i = M|x_i|$ 进入固定光路。对第 r 个探测器，符号路由给出式 (58)。所有物理强度均非负，输入幅度以 M 增强，有符号结果由探测端的正负通道差形成。表面测量与输入强度分别承载固定参数与当前输入。固定表面的真实 RT 求交和反射测量可缓存为传输系数；后续前向改变发射强度，并复用同一组测量。

命题 4 (平衡光路的线性等价)**.** 在精确透射与线性探测条件下，$\mathcal{O}_W(x) = Wx$。

证明. 每一对通道满足 $I_{ri}^{+} - I_{ri}^{-} = \mathrm{sgn}(W_{ri}x_i)|W_{ri}x_i| = W_{ri}x_i$。沿输入通道求和即得式 (58) 的结论。 □

10.2 Sigmoid 透射与门控耦合

令门控及升维探测信号分别为 $g = \mathcal{O}_{W_g}(x)$、$u = \mathcal{O}_{W_u}(x)$。门控信号控制非线性透射 $T_\sigma(g_r) = \sigma(g_r) = 1/(1+\exp(-g_r))$。两路幅度耦合形成

$$I^+_{ri} = E_i T_{ri} \mathbf{1}_{\{W_{ri}x_i>0\}}, \tag{56}$$

$$I^-_{ri} = E_i T_{ri} \mathbf{1}_{\{W_{ri}x_i<0\}}, \tag{57}$$

$$\mathcal{O}_W(x)_r = \sum_i I^+_{ri} - \sum_i I^-_{ri}. \tag{58}$$

$$A_r = |g_r|\,|u_r|\,T_\sigma(g_r), \tag{59}$$

$$a_r = \operatorname{sgn}(g_r)\operatorname{sgn}(u_r)A_r, \tag{60}$$

$$\mathcal{M}_{\mathrm{RT}}(x) = \mathcal{O}_{W_d}(a). \tag{61}$$

$$\mathcal{M}_{\mathrm{RT}}(x) = W_d\big[\mathrm{SiLU}(W_g x) \odot (W_u x)\big].$$

幅度耦合与透射由探测响应定义，降维端继续使用同一平衡探测算子。

命题 5 (纯光路 SwiGLU 等价)**.** 式 (61) 满足 同组末行的 SwiGLU 等价式。

证明. 由符号与幅度的乘积，$a_r = g_r u_r \sigma(g_r) = \mathrm{SiLU}(g_r)u_r$，再应用平衡光路线性等价命题即得结论。 □

11 权重与状态的等价翻译

11.1 固定传输系数与几何内容

对原模型每个线性映射 W，逐项以式 (58) 建立符号路由和透射系数，使用原始参数的位模式作为固定表面索引。平衡探测保持 Wx，因而各投影、输出门控和前馈变换可按原层顺序组合。对完整注意力，几何写入器同时编码 $W_K x_j$ 的地址信息和 $W_V x_j$ 的内容信息。两组信息由同一历史实例的可逆几何坐标承载，探测器命中后恢复原始高维通道。

对有限 FP32 坐标，写为 $x = (-1)^s 2^e m$，其中 $m \in [1/2, 1)$。令 $B(\cdot)$ 表示截断到 BF16 的有效位模式，

$$m_1 = B(m), \qquad m_2 = B(m - m_1), \tag{62}$$

$$m_3 = m - m_1 - m_2, \qquad \mathcal{C}(x) = (s, e, m_1, m_2, m_3). \tag{63}$$

三个分段覆盖 FP32 的全部有效位，m_3 亦可由 BF16 精确表示；解码取 $(-1)^s 2^e(m_1 + m_2 + m_3)$。零值保留符号标记，次正规数通过有效位移和指数恢复。每个分段对应固定 BF16 表面的几何索引，从实际 RT 测量缓存读取后按位恢复。一个 D 维查询由 $D/2$ 对坐标表示。历史地址与内容按 GQA 的共享组保存，量化映射由式 (104) 定义。源模型的 GQA 共享关系、逐头归一化、旋转位置编码和输出门控按原有参数及顺序保留。每个查询的历史域分成并行光路组，各组沿因果时间表面读取完整有效贡献，通过共同参考通道形成式 (72) 的比值。这一工作点采用完整贡献覆盖；路径增益使用对当前查询共同的尺度，从而保持各贡献间的原始比例。

11.2 递推场的光学状态翻译

原模型的 gated-delta 层先对三组投影施加四点因果卷积与 SiLU，再对每头的查询和键作原有 L_2 标定。记这些信号为 q_t, k_t, v_t，门控系数为式 (65)。递推场 S_t 的光学更新定义为

$$\beta_t = \sigma(W_b x_t), \tag{64}$$

$$\alpha_t = \exp\big[-\exp(A_{\log})\ \mathrm{softplus}(W_a x_t + d_{\mathrm{bias}})\big]\,. \tag{65}$$

$$S_t^- = \alpha_t S_{t-1}, \tag{66}$$

$$m_t = \mathcal{O}_{(S_t^-)^{\mathsf{T}}}(k_t), \tag{67}$$

$$\Delta_t = \beta_t \odot (v_t - m_t), \tag{68}$$

$$S_t = S_t^- + k_t \Delta_t^{\mathsf{T}}, \tag{69}$$

$$o_t = \mathcal{O}_{S_t^{\mathsf{T}}}(q_t/\sqrt{d_k}). \tag{70}$$

场系数以可逆几何索引保存，读取复用固定表面的真实 RT 测量。衰减调节传输，内容差形成写入光强，外积更新场系数。输出随后经过原有逐头 RMS 标定、SiLU 门控和光路输出投影。

命题 6 (递推场的等价)**.** 以相同初始状态和卷积历史开始，式 (70) 与原模型 gated-delta 更新具有相同状态与输出。

证明. 平衡光路线性等价给出 $m_t = (S_t^-)^{\mathsf{T}} k_t$ 和 $o_t = S_t^{\mathsf{T}} q_t/\sqrt{d_k}$。因此每一步的衰减、校正差和外积写入均与原更新相同。由初始状态及逐步归纳，全部状态和输出保持一致。 □

11.3 完整词表的光强读出

对最终高维状态 h, 完整词表探测器使用 $\ell = \mathcal{O}_{W_{\mathrm{LM}}}(h)$。共同增强尺度 C 给出 $I_v = \exp(\ell_v + C)$, 比较对数强度可稳定得到

$$\arg\max_v I_v = \arg\max_v \ell_v.$$

完整分布由同一参考通道读出 $p_v = I_v / \sum_u I_u$。全词表均保留原始方向、范数和系数，几何角度由这些高维参数在前向时形成。各层算子与最终词表读出共同保持原模型映射，其实现精度由逐层数值对照和整段生成比较检验。

12 完整注意力与紧凑贡献摘要

12.1 完整 Transformer 注意力

固定查询位置 i 与查询头 h，令 d_h 为头维度，$\mathcal{J}_i$ 为有效因果历史位置集合。查询、键和值均取位置变换后的坐标。具有 H_Q 个查询头与 H_G 个共享键值头的 GQA 使用 $g(h) = \lfloor h/(H_Q/H_G) \rfloor$, 同组查询头读取相同的 k_j, v_j。完整注意力为

$$s_{ij} = \frac{q_i^{\mathsf{T}} k_j}{\sqrt{d_h}} + b_{ij}, \qquad A_{ij} = \exp(s_{ij}), \tag{71}$$

$$o_i = \frac{\sum_{j\in\mathcal{J}_i} A_{ij} v_j}{\sum_{j\in\mathcal{J}_i} A_{ij}}. \tag{72}$$

$$I_{ij} = c_i A_{ij}, \qquad c_i > 0, \tag{73}$$

$$N_i = \sum_{j\in\mathcal{J}_i} I_{ij} v_j, \qquad R_i = \sum_{j\in\mathcal{J}_i} I_{ij}, \qquad o_i = N_i/R_i. \tag{74}$$

掩码项的强度为零。内容探测与参考探测共享增益 c_i，有符号内容由正、负强度之差读出；全部有效历史贡献进入两个通道。

命题 7 (强度比值的完整注意力等价)**.** 若内容读出为 v_j，各贡献的强度为 $c_i \exp(s_{ij})$，且探测按强度线性相加，则式 (74) 等于式 (72)。

证明. 分子与分母分别为 $c_i \sum_j A_{ij} v_j$ 与 $c_i \sum_j A_{ij}$，约去共同正因子 c_i 即得结论。 □

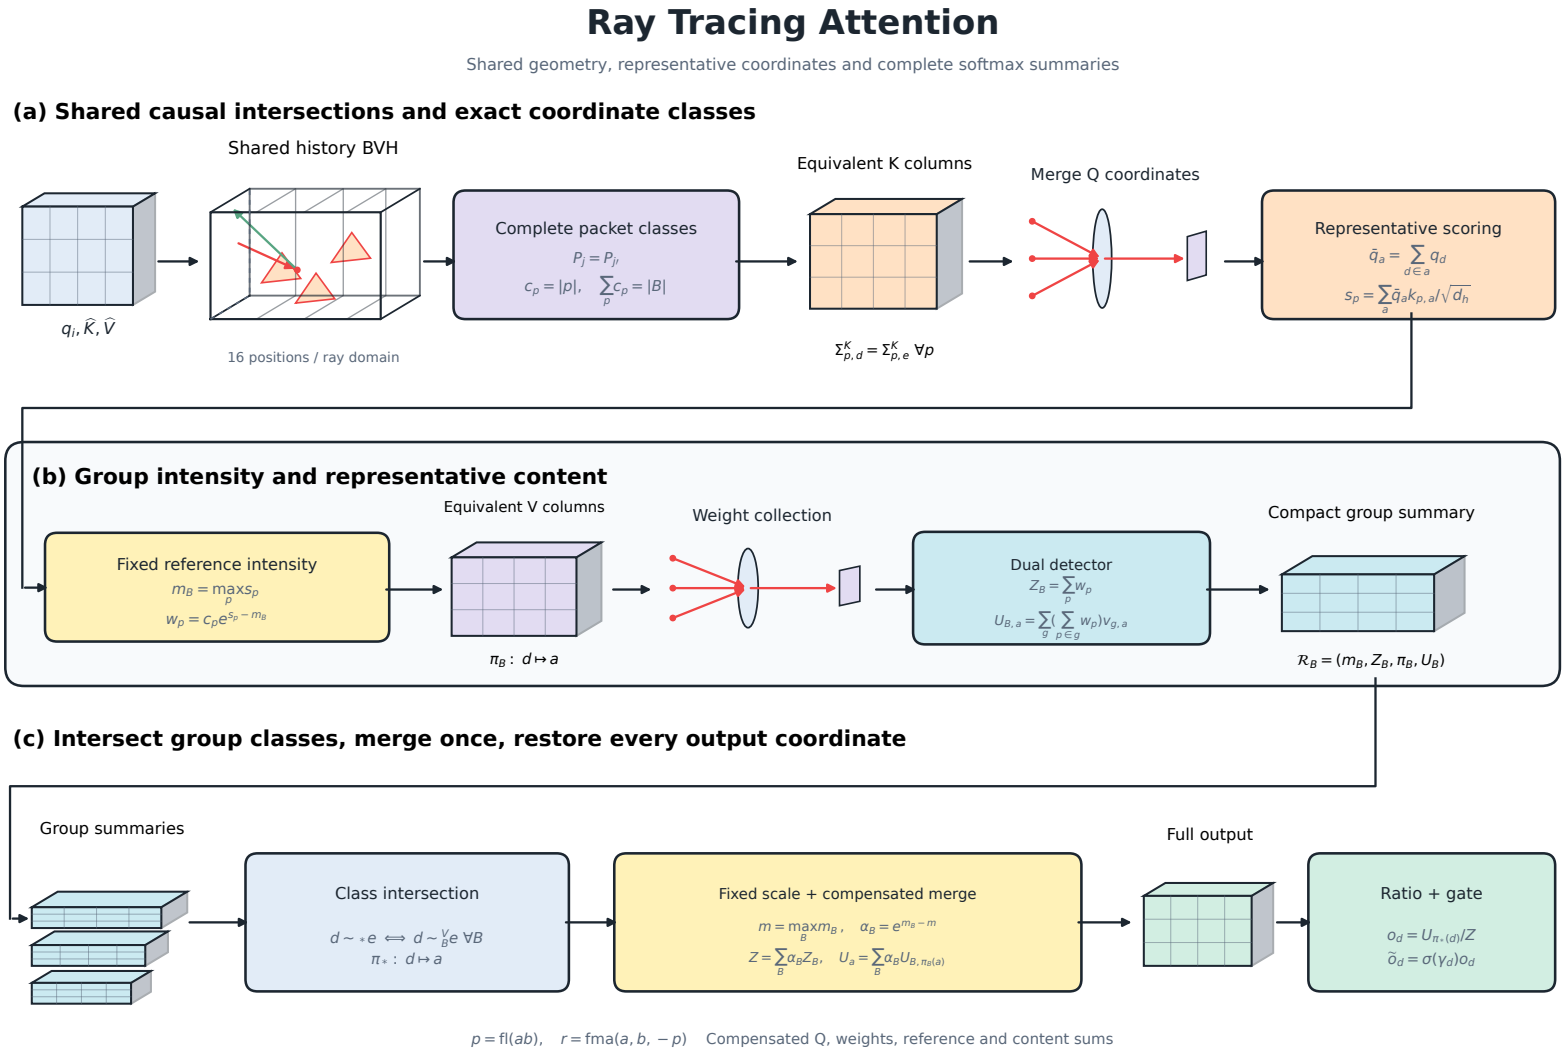


图 5: 紧凑完整注意力的数学结构。完整包重复次数进入强度，键列等价类汇合查询坐标，值列等价类形成有效内容摘要。各历史组在固定最大值下汇合，组间取值列关系的交集，恢复完整输出并施加逐坐标门控。

12.2 历史分组与完整包的重复次数

图 5 展开分组与摘要的连接。将 $\mathcal{J}_i$ 划分为不相交的历史组 B，每组至多 B_0 个位置。当前数学工作点取 $B_0 = 128$，组内每 16 个历史位置形成一个并行求交域，同组各查询头共享这些位置的几何身份。每个位置携带绝对时序标记，几何身份映射到它的完整键值包。

对当前 $b_{ij} = 0$ 的得分，定义同一历史组中的完整包等价关系

$$j \sim_P j' \iff P_j = P_{j'}, \tag{75}$$

$$\mathcal{P}_B = B/\sim_P, \qquad c_p = |p|, \qquad \sum_{p\in\mathcal{P}_B} c_p = |B|. \tag{76}$$

P_j 为整个量化键值包；每类 p 选取最早出现的代表。包相同给出相同的恢复键和值，故它的得分 s_p 与值 v_p 只需形成一次，该类的完整贡献为 $c_p \exp(s_p)$。有位置偏置时，将该偏置的相等关系同时纳入 $\sim_P$。几何覆盖仍保存每次历史出现，重复次数保存各出现的强度总和。

12.3 键列等价与查询坐标合并

令 $\Sigma^K_{p,d}$ 表示量化键坐标恢复后的浮点数值位模式，正零与负零归为同一个数值身份。不同量化表达式恢复成相同数值时具有同一个身份。对组内所有代表包定义

$$d \sim^K_B e \iff \Sigma^K_{p,d} = \Sigma^K_{p,e} \quad \forall p \in \mathcal{P}_B, \tag{77}$$

$$\mathcal{A}^K_B = \{0, \dots, d_h - 1\}/\sim^K_B, \qquad \bar{q}_{i,a} = \sum_{d\in a} q_{i,d}, \tag{78}$$

$$s_p = \frac{1}{\sqrt{d_h}} \sum_{a\in\mathcal{A}^K_B} \bar{q}_{i,a} k_{p,a}. \tag{79}$$

每个等价类用最小坐标作代表。类内全部查询坐标先汇合，每个代表键坐标与类查询和相乘。$\bar{q}_{i,a} = 0$ 的项贡献为零。类的建立使用整组代表历史的相等关系。

命题 8 (分组查询的得分等价)**.** 式 (79) 与完整 $q_i^{\mathsf{T}} k_p/\sqrt{d_h}$ 相等。

证明. 对每类 a，键值 $k_{p,d} = k_{p,a}$，因而 $\sum_{d\in a} q_{i,d} k_{p,d} = (\sum_{d\in a} q_{i,d}) k_{p,a}$。对全部类求和即得到完整内积。 □

12.4 值列等价、共同内容与局部摘要

用 $\Sigma^V_{p,d}$ 表示值坐标恢复后的数值身份，定义 $d \sim^V_B e$ 当且仅当对全部 $p \in \mathcal{P}_B$ 有 $\Sigma^V_{p,d} = \Sigma^V_{p,e}$。令 $\mathcal{A}^V_B$ 为值列等价类，$\pi_B(d)$ 为坐标 d 的类代表。先确定完整组的最大得分，再形成固定尺度下的强度与摘要：

$$m_B = \max_{p\in\mathcal{P}_B} s_p, \qquad w_p = c_p \exp(s_p - m_B), \tag{80}$$

$$Z_B = \sum_{p\in\mathcal{P}_B} w_p, \qquad U_{B,a} = \sum_{p\in\mathcal{P}_B} w_p v_{p,a}, \quad a \in \mathcal{A}^V_B, \tag{81}$$

$$\mathcal{R}_B = (m_B, Z_B, \pi_B, (U_{B,a})_{a\in\mathcal{A}^V_B}). \tag{82}$$

内容分子只保留值列代表，原坐标 d 的分子为 $U_{B,\pi_B(d)}$。对连续代表包中的共同恢复内容组 g，还可合并其权重：

$$v_p = v_g \quad (p \in g), \qquad W_g = \sum_{p \in g} w_p, \tag{83}$$

$$\sum_{p \in g} w_p v_{p,a} = W_g v_{g,a}, \qquad \sum_{p \in g} w_p = W_g. \tag{84}$$

相同得分的指数由同一映射值复用，包的次数 c_p 在形成指数后乘入强度。共同内容的权重汇合与值列汇合分别减少历史加权次数和每次加权的坐标数。

12.5 组间等价关系交集与完整输出

不同历史组可以具有不同的值列等价类。最终坐标关系取所有组关系的交集，令

$$d \sim_*^V e \iff d \sim_B^V e \quad \forall B, \qquad \mathcal{A}_*^V = \{0, \dots, d_h - 1\}/\sim_*^V, \tag{85}$$

$$m = \max_B m_B, \qquad \alpha_B = \exp(m_B - m), \tag{86}$$

$$Z = \sum_B \alpha_B Z_B, \qquad U_a = \sum_B \alpha_B U_{B,\pi_B(a)}, \tag{87}$$

$$o_{i,d} = \frac{U_{\pi_*(d)}}{Z}, \qquad \widetilde{o}_{i,d} = \sigma(\gamma_{i,d}) o_{i,d}. \tag{88}$$

这里 π_* 选择最终关系的最小坐标代表，a 取最终代表坐标。某一组中分开的坐标在最终关系中分别保留。逐坐标输出门控 $\gamma_{i,d}$ 在恢复完整坐标后作用。单组时 $\alpha_B = 1$，直接由局部摘要恢复输出。

命题 9 (紧凑摘要的完整 softmax 等价)**.** 由式 (76)、(79)、(82) 与 (88) 形成的 o_i 等于完整注意力。

证明. 键列分组保持每个代表包的完整得分，包的次数保留所有历史出现。对任意原坐标 d，值列映射给出

$$\sum_B \alpha_B U_{B,\pi_B(d)} = \sum_B \sum_{p \in \mathcal{P}_B} c_p \exp(s_p - m) v_{p,d} = \sum_{j \in \mathcal{J}_i} \exp(s_{ij} - m) v_{j,d},$$
$$\sum_B \alpha_B Z_B = \sum_{j \in \mathcal{J}_i} \exp(s_{ij} - m).$$

交集关系使同一最终类中的上述分子相同。分子与分母约去共同尺度 $\exp(-m)$ 即得式 (72)。 □

12.6 固定尺度与有限精度补偿

每组先确定 m_B，组间先确定 m，随后在固定尺度下归约。查询类求和、参考强度、共同内容权重与内容分子采用补偿递推。用 fl 表示一次浮点舍入，定义

$$y_n = \mathrm{fl}(x_n - c_{n-1}), \qquad s_n = \mathrm{fl}(s_{n-1} + y_n), \tag{89}$$

$$c_n = \mathrm{fl}\big(\mathrm{fl}(s_n - s_{n-1}) - y_n\big), \qquad \widehat{S} = \mathrm{fl}(s_N - c_N), \tag{90}$$

$$p_n = \mathrm{fl}(a_n b_n), \qquad r_n = \mathrm{fma}(a_n, b_n, -p_n). \tag{91}$$

从 $s_0 = c_0 = 0$ 开始，乘积项依次将 p_n 和乘积残差 r_n 纳入补偿递推。组间的 $\alpha_B Z_B$ 与 $\alpha_B U_{B,a}$ 使用同样的乘积残差。实数恒等式描述算子等价，补偿递推描述有限精度的求和顺序。

12.7 稀疏率与实际贡献粒度

记 $P_B = |\mathcal{P}_B|$，K_B 为非零类查询的个数，$V_B = |\mathcal{A}_B^V|$，G_B 为连续共同内容组数。按查询头和历史组统计，逻辑工作量为

$$C_{\mathrm{full}} = d_h \sum_B |B|, \qquad C_{QK} = \sum_B P_B K_B, \qquad C_V = \sum_B G_B V_B, \tag{92}$$

$$D_{\mathrm{local}} = \sum_B V_B, \qquad D_{\mathrm{full}} = d_h\,|\{B\}|, \qquad D_{\mathrm{merged}} = |\mathcal{A}_*^V|, \tag{93}$$

$$\rho_{QK} = 1 - C_{QK}/C_{\mathrm{full}}, \qquad \rho_V = 1 - C_V/C_{\mathrm{full}}, \tag{94}$$

$$\rho_{\mathrm{return}} = 1 - D_{\mathrm{local}}/D_{\mathrm{full}}, \qquad \rho_{\mathrm{merge}} = 1 - D_{\mathrm{merged}}/d_h. \tag{95}$$

小查询坐标的统计定义为 $r_\epsilon = \#\{d : |q_{i,d}| < \epsilon\}/d_h$。乘法数、局部返回维度数、最终合并维度数和小坐标比例分别描述不同粒度。上述摘要携带所有贡献的强度总和与共同参考值，计算规模由历史重复次数和整组列等价关系决定。

13 共享模板、出现实例与路径缓存

13.1 共享边界与跨分支因果寻址

共享缓存由历史边界 BVH $\mathcal{B}_H$ 与因果地址 BVH $\mathcal{B}_Q$ 组成，共同服务同一模型进程中的对话分支。模型、几何版本和因果内容建立复用命名空间。输入端点、输出端点、公共前缀与中间边界进入 $\mathcal{B}_H$；历史按 16 个位置组成不可变块 B_i，保存量化光路包、位置标记和共享 BLAS。前缀 P 的紧凑边界标记为式 (96)。其中 $\mathcal{R}(P)$ 为公共历史块引用，$h_P \in \mathbb{R}^D$ 为最终高维探测行，$\mathcal{Q}_P$ 为已验证的因果地址。各分支接入同一组公共块，完整块直接复用同一 BLAS，尾块承载新增位置；当前递归场 S_{live} 由原生传播维护。

每个解码位置在 $\mathcal{B}_Q$ 查询完整因果身份。命中节点返回 $(s_{t+1}, \mathcal{Q}_{t+1})$，下一步继续按后继地址查询；新光路通过原生 GPU 传播形成所需数值状态并写入新的因果节点。令 $\mathcal{U}$ 为各分支引用的唯一历史块集合，H 为边界数，则

$$\mathcal{M}(P) = \big(\mathrm{id}(P), \mathcal{R}(P), h_P, \mathcal{Q}_P\big), \tag{96}$$

$$M_{\mathrm{shared}} = \sum_{B \in \mathcal{U}} |B| + 4DH + O(H). \tag{97}$$

高维行保留原始数值位模式，量化光路包沿用 Q4_K / Q6_K 编码；$D = 4096$ 时每个高维行占 16384 bytes。

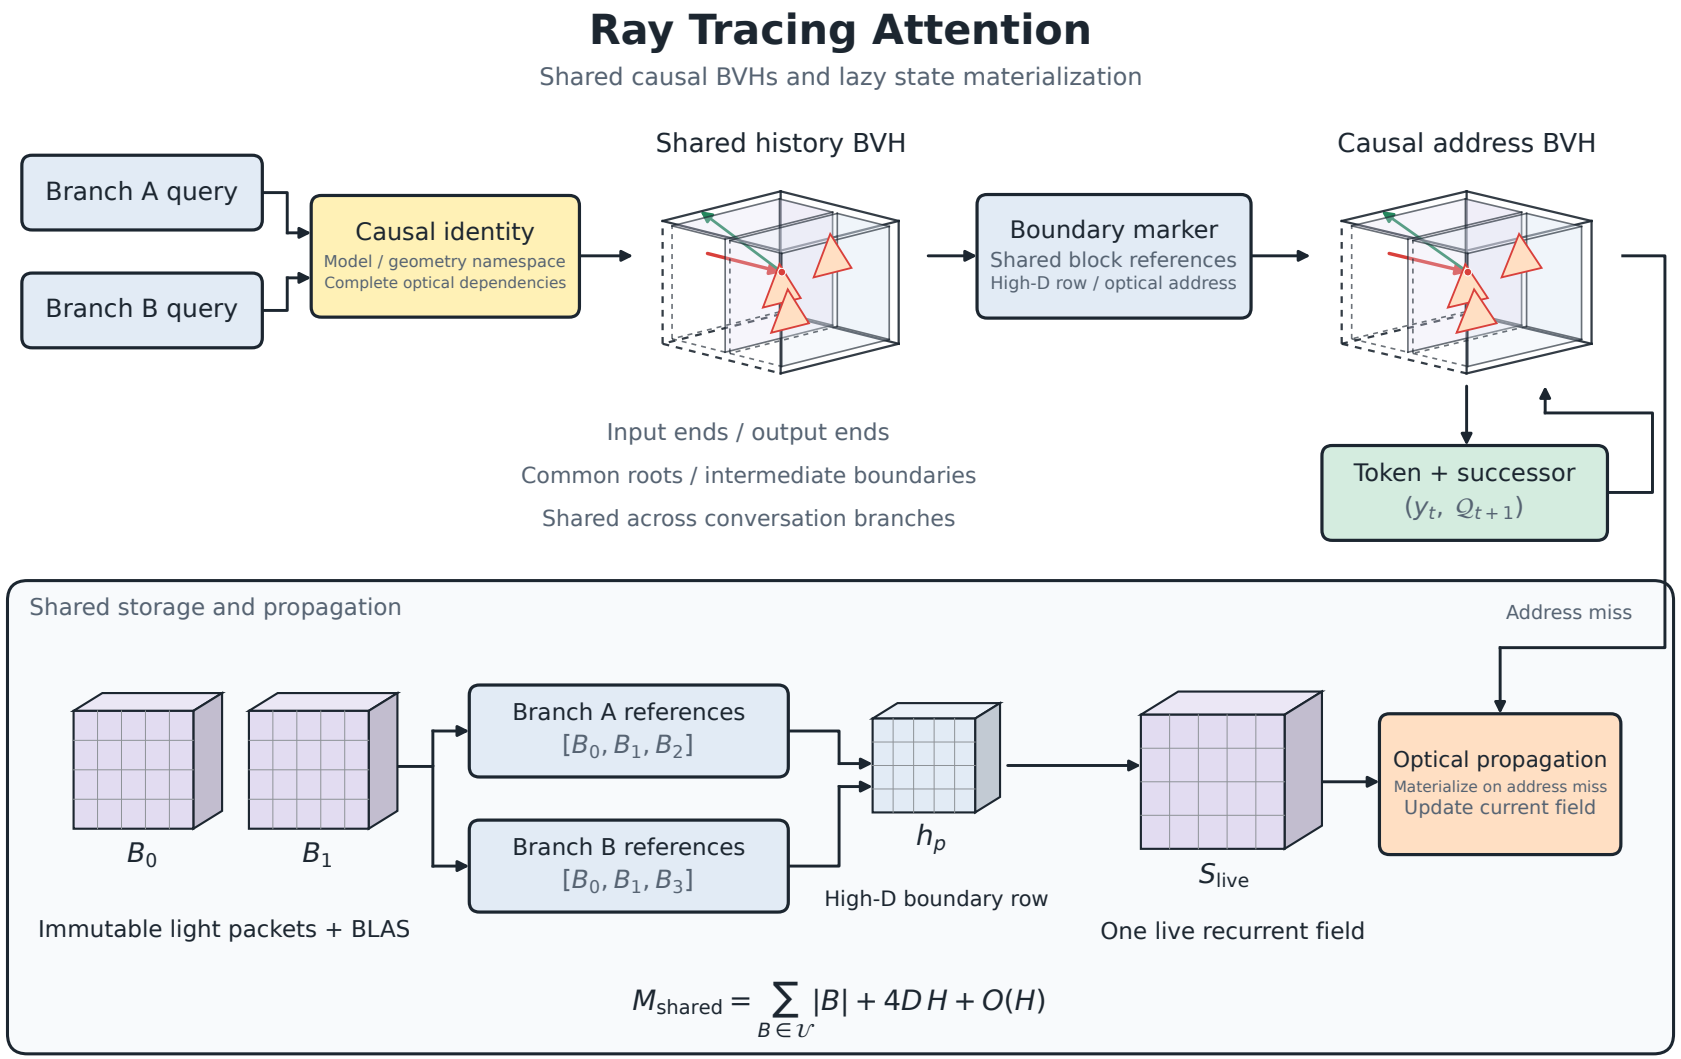


图 6: 共享因果 BVH 算子。公共历史以块引用连接各分支，边界标记提供高维读出行和因果地址，地址树返回词元及后继地址。当前递归场按需参与原生传播。

13.2 模板复用与重复贡献

共享词元模板 T_v 保存基础几何、角度和幅度参数，第 j 次出现实例保存

$$\mathcal{I}_j = (s_j, j, \tau_j, \Delta G_j, \xi_j). \tag{98}$$

其中 τ_j 是位置与姿态变换，ΔG_j 是上下文形状变化，ξ_j 是时序及光路状态。静态模板可作为共享 BLAS，历史出现以 TLAS 实例和必要的上下文几何表示。需要独立变形的实例使用自身的几何数据或形状模板族，实际存储规模取决于这种表示的自由度。

命题 10 (共同内容的强度合并)**.** 对固定查询 i，若出现组 g 中所有项的几何内容读出相同，即 $\Phi_{ij} = \Phi_{ig}$，则令

$$I_{ig} = \sum_{j \in g} I_{ij} \tag{99}$$

$$\sum_{j \in g} I_{ij}\Phi_{ij} = I_{ig}\Phi_{ig}, \qquad \sum_{j \in g} I_{ij} = I_{ig}. \tag{100}$$

可精确保留该组在内容分子与参考分母中的贡献：式 (100)。

如果 m_g 个副本具有相同键、位置作用、得分和内容，该组以 $m_g I_{ij}$ 的增强强度保留完整注意力中的重复贡献。共享模板与合并强度由不同条件控制：词元 ID 定义基础模板身份，当前上下文、时序与有效路径定义贡献是否可合并。各次历史出现保持独立身份，并在满足共同内容条件时压缩其累积读出。

13.3 Q 查询标记与原生路径回执

传统 KV 缓存常以层、头和出现位置组织记录。RT 使用完整查询描述作为 Q 标记：式 (101)。其中包含射线、查询位置、场景身份及几何版本。查询模式包含实例掩码、距离范围、最大段数与面朝向规则。发射前按 $\mathcal{Q}_i$ 查找路径缓存，未命中时交给原生 RT 查询，并保存真实命中与路径回执；缓存体由原生查询返回的几何结果构成。相同词元基础方向可共享码本，完整 Q 标记还包含本次出现和场景状态。新增历史实例或透镜移动更新相关几何版本。Q 标记组织读取身份，历史内容仍由共享词元模板与独立出现实例承载。

13.4 拓扑缓存与数值缓存

一条路径的拓扑记录为式 (102)。共享模板几何、历史出现实例与光路结果缓存构成三个复用层次。拓扑缓存复用命中身份和传播结构，对当前输入相关的射线重新计算交点、法向、长度和增强。Q 路径回执的拓扑部分只依赖几何查询条件，光强可由当前上下文重新计算。其有效域需要保证没有新的最近遮挡或路径切换；可由同一原生 RT 查询验证，或由已验证的稳定可见域证书限定。缓存有效性检查与当前数值重算计入执行开销。

完整数值缓存的依赖键至少包含

$$\mathcal{Q}_i = (o_i, d_i, i, \mathrm{occurrence}_i, \mathrm{sceneID}, \nu_{\mathrm{scene}}, \nu_{\mathrm{lens}}, \mathrm{queryMode}). \tag{101}$$

$$\chi_\gamma = ((\mathrm{instance}_0, \mathrm{primitive}_0), \ldots, (\mathrm{instance}_L, \mathrm{primitive}_L)). \tag{102}$$

$$\mathcal{K}_\gamma = (\mathcal{Q}_i, \nu_{\mathrm{param}}, \nu_{\mathrm{context}}, \nu_{\mathrm{gain}}, \mathrm{detector}, \mathrm{mode}). \tag{103}$$

这里 $\mathcal{Q}_i$ 包含射线起点、方向和查询域，场景版本包括实例生命周期和几何变更，参数版本包括角度、透镜与共享探测映射。上下文、发射与独立增强的状态指纹覆盖所有会改变强度或内容的状

态。依赖一致时才能直接复用完整数值；拓扑一致则允许复用结构并重算当前值。最终词元相同只固定词元身份，路径复用按式 (103) 的依赖关系决定。

13.5 量化历史光路包与即时恢复

当前历史将键地址与值内容分别以 Q4_K 和 Q6_K 保存。令 $\mathcal{E}_4, \mathcal{E}_6$ 为量化编码映射，$\mathcal{D}_4, \mathcal{D}_6$ 为相应的恢复映射。每个历史出现的包与参与注意力的数值为

$$P_j = (\mathcal{E}_4(k_j), \mathcal{E}_6(v_j)), \qquad \widehat{k}_j = \mathcal{D}_4(P_j^K), \quad \widehat{v}_j = \mathcal{D}_6(P_j^V). \tag{104}$$

$$\beta = L_A \left\lceil \frac{H_G d_h}{256} \right\rceil (144 + 210), \tag{105}$$

$$M_{\text{packet}}(C) = \beta C, \qquad M_{\text{live}}(N, C) = \beta \min(N, C). \tag{106}$$

每个 Q4_K 块覆盖 256 个坐标、占 144 bytes；每个 Q6_K 块占 210 bytes。GQA 只保存共享键值头，读取时按 $g(h)$ 映射到查询头。前述完整注意力与紧凑摘要均作用于同一恢复后的 $\widehat{k}, \widehat{v}$。每层输出回到完整高维状态，历史坐标按当前读出需求恢复。递推场继续以式 (63) 对应的可逆坐标表示保存。

13.6 共享历史与容量增长

以 L_A 表示完整注意力层数，C 表示历史容量，每 16 个位置组成一个几何块，则基础历史层次数为

$$n_{\text{blocks}} = L_A \lceil C/16 \rceil, \qquad n_{\text{roots}} = L_A, \tag{107}$$

$$M_{\text{BF16 KV}}(C) = 2 L_A H_G d_h C \cdot 2, \tag{108}$$

$$M_{\text{receipt}}(R, C) = 4 R H_Q \lceil C/B_0 \rceil \left(16 + B_0/32 + \lceil d_h/4 \rceil + \lceil d_h/32 \rceil + d_h\right). \tag{109}$$

R 是同时在途的查询行数。每条摘要的容量包含最大值、参考值、历史覆盖、计数、值列映射、代表标记和内容分子。实际内容分子写入量由式 (95) 的 D_{local} 决定。基础历史块与跨分支共享块分别计入场景存储。当前 $L_A = 8, H_G = 4, d_h = 256$ 给出 $\beta = 11328$ bytes/词元，同架构 BF16 键值载荷为 32768 bytes/词元，历史载荷比例为 354/1024，减少 65.4296875%。

总存储分解为

$$\begin{aligned} M_{\text{total}} = {} & M_{\text{weight}} + M_{\text{recurrent}} + M_{\text{packet}} + M_{\text{geometry}} + M_{\text{workspace}} \\ & + M_{\text{receipt}} + M_{\text{shared}} + M_{\text{causal}} + M_{\text{alignment}}. \end{aligned} \tag{110}$$

静态矩阵表面、词表表面与透镜在同一参数版本内共享。公共历史块以引用连接分支，边界高维行按式 (97) 增长。容量按需增加时，已有包、时序标记与边界引用迁移到新容量；新块接入同一层的历史域。窗口填满后，绝对时序标记确定当前有效位置，当前有效包数保持 C。

13.7 因果缓存的恢复路径

令状态图 $G = (\mathcal{S}, \mathcal{E})$ 的节点为具有完整依赖身份的状态或输出检查点。边对应边界恢复、下一步传播或已保存输出的地址读取，代价为 $c_e \geq 0$。有效起点集合为 $\mathcal{S}_0$，请求目标为 s_*，恢复计划为

$$(s_0, \gamma_*) = \operatorname*{arg\,min}_{s \in \mathcal{S}_0,\ \gamma : s \rightsquigarrow s_*} \sum_{e \in \gamma} c_e. \tag{111}$$

输出节点给出下一词元和后继因果地址，每一步继续进行地址查询。命中时使用已验证的输出与后继身份，新分支通过完整传播形成新的状态。公共历史边界提供共享包与高维读出行，当前递推场

沿其依赖关系恢复和更新。

14 固定矩阵与词表的几何读出

14.1 矩阵与透射的同一前馈算子

对批量高维输入 X，完整前馈映射为

$$G = XW_g^{\mathsf{T}}, \qquad U = XW_u^{\mathsf{T}}, \qquad Y = [\mathrm{SiLU}(G) \odot U]W_d^{\mathsf{T}}. \tag{112}$$

矩阵分块与固定透射分别实现这一映射。对任意输出坐标 r 和输入行 t，两种分解均保留完整内积 $y_{t,r} = \sum_i W_{ri}x_{t,i}$。注意力的分组与前馈的分解分别选择，完整层依赖保持一致。

14.2 固定表面与批量强度

对矩阵 W_ℓ，固定几何身份由接收坐标 r 与系数块 b 构成。同一组支持表面由各层共享，层身份选择各自的原始材料。令 $\mathcal{H}(r)$ 为接收端的完整块命中集合，$\mathcal{I}_b$ 为块内坐标，批量输入的探测表达式为

$$y_{t,r} = \sum_{b\in\mathcal{H}(r)} \sum_{i\in\mathcal{I}_b} \left(E_{t,i}T_{\ell,ri}\mathbf{1}_{W_{\ell,ri}x_{t,i}>0} - E_{t,i}T_{\ell,ri}\mathbf{1}_{W_{\ell,ri}x_{t,i}<0}\right). \tag{113}$$

$E_{t,i} = M_\ell|x_{t,i}|$，$T_{\ell,ri} = |W_{\ell,ri}|/M_\ell$，$M_\ell \geq \max|W_\ell|$。同批输入共享固定表面的几何身份，各输入分别形成强度、非线性门控与输出。gate、up 与 down 按式 (61) 连接，固定材料按原始量化或浮点映射恢复。

14.3 词元身份与光强排序

词表保留词元身份、完整分块方向、幅度及固定系数。对最终高维状态 y_i，第 b 块为 P_by_i，相应权重为 P_bw_v。词元探测汇合全部块的贡献，得到

$$\ell_{iv} = \sum_b (P_by_i)^{\mathsf{T}}(P_bw_v) = y_i^{\mathsf{T}}w_v, \tag{114}$$

$$J_{iv} = \exp(\ell_{iv} + C_i), \qquad \widehat{s}_{i+1} = \arg\max_{v\in\mathcal{W}} J_{iv} = \arg\max_{v\in\mathcal{W}} \ell_{iv}. \tag{115}$$

相同分数按词元身份决胜。输入嵌入与输出头共享参数时，同一份固定载荷服务两个映射。高维恢复、完整层依赖与词表排序共同构成原模型的输出函数。

15 真实 Agent 任务与当前显存测量

15.1 四轮真实项目代码分析与计算量

当前测试模型为 QwenFlash 9B ，使用原始 Q4_K/Q6_K 权重。32 层模型含 8 层完整注意力，16 个查询头、4 个共享键值头、每头 256 维。选择紧凑分组注意力与矩阵前馈映射，历史容量为 8192，查询组为 128，位置批量为 512，因果缓存开启。

四轮真实任务读取当前项目源码，依次分析运行时启动与构建复用、注意力查询粒度、完整包与列等价、因果缓存分支并 review。前轮回复及实际核验回执进入后轮上下文。请求耗时包括前缀处理与完整生成，词元化在请求前完成。

表 1: 四轮真实项目代码分析的首次分支与同分支重放。时间单位为毫秒。

轮次	任务	输入词元	输出词元	首次分支	缓存重放
1	启动与构建复用	1058	115	5569.80	3.18
2	Attention 查询粒度	2558	120	7526.86	3.60
3	完整包与列等价	4096	85	11424.91	3.41
4	因果缓存分支 review	5792	121	20799.59	4.56

四轮共输出 441 个词元，首次分支请求合计 45321.16 ms，同分支重放合计 14.75 ms。重放的 441 次因果地址查询全部命中，输出序列逐词元一致；新增完整注意力计算、QK 乘法和内容加权均为零。

表 2: 四轮代码分析回复结束后的共享边界与设备分配，历史容量为 8192。

轮次	边界数	高维行 bytes	共享块与场景 MiB	设备分配 MiB
1	6	98304	15.70	6096.02
2	14	229376	38.24	6223.46
3	23	376832	61.26	6418.13
4	33	540672	86.63	6562.22

公共块由不同边界引用，高维行按式 (97) 保存。缓存重放沿后继因果地址返回已完成的输出。

15.2 同一编码任务的容量与显存复测

各容量与缓存开关均以独立进程执行同一个区间限制编码请求。使用原完整注意力与矩阵前馈映射，注意力统计关闭，位置批量为 512。输入为 50 个词元，各配置输出 50 个词元，六项测试全部通过。

表 3 的设备分配与历史包来自当前资源测量。驱动峰值每 0.5 秒采样，扣除各进程加载前的显卡基线。同源 GGUF 对照使用单 NVIDIA GPU、Vulkan、F16 键值历史和 512 位置批量。

表 3: 默认矩阵配置的容量测量。存储量以 MiB 表示；RTA 列按缓存开/关排列。

容量	历史包	RTA 设备分配	RTA 驱动新增峰值	同源 Vulkan 峰值
512	5.53	5909.94/5909.94	6341/6387	5203
1024	11.06	5909.94/5909.94	6438/6367	5090
2048	22.12	5932.06/5932.06	6473/6452	5076
4096	44.25	5954.19/5954.19	6442/6388	5159

同架构 BF16 历史载荷在四档容量中分别为 16、32、64、128 MiB，当前量化历史载荷为其 34.5703125%。本次 RTA 的总驻留高于同源 Vulkan 对照。固定系数、递推场、几何、工作区、摘要、共享历史和因果缓存共同构成式 (110) 的总量。

固定系数载荷为 5360.80 MiB，词表场为 232.71 MiB，递推场与批量帧为 75.38 MiB。矩阵前馈配置的透射场为零，固定透射配置的支持场为 46.06 MiB。