Ray Tracing Attention

摘要

量化键值向量中的不同坐标可能具有相同的恢复值。Ray Tracing Attention（RTA）利用这一结构，在每个历史位置和每个共享键值头内分别划分键、值等价类，通过常驻光线追踪几何查找候选，并依据浮点数位模式确定类成员。计算键评分时，先对每类的全部查询坐标求和，再与代表键相乘，从而复用相同键值的乘法。类缓存由代表描述符、FP32 代表值和覆盖全部坐标的打包成员索引组成，可服务多个查询行以及同组查询头。本文建立类映射的内积恒等式，给出静态桶 BVH 的精确性条件，并说明多行共享、环形历史以及 FP32 评分与内容归约的计算过程。值阶段包括完整成员分发和代表坐标两种策略：前者保留恢复值的全部注意力贡献，后者形成稀疏的代表坐标输出。附录进一步讨论反射、透射、强度与探测的几何光路模型。

1 研究问题与贡献

自注意力将查询与有效历史中的键逐一比较，再用归一化权重汇合值向量。在分组查询注意力（GQA）中，多个查询头读取同一个键值头 [1, 2]。这种共享减少了历史载荷，量化则带来另一种可复用结构：同一键向量内部，不同坐标可能恢复为相同数值。RTA 将相同键值合并为一个代表，同时汇总类内全部查询坐标，使键评分保持原内积。在此基础上，紧凑类记录还可以减少重复的索引、解码与调度。

RTA 将计算分为历史写入、精确分类、紧凑存储、键评分和值归约几个阶段。分类只依赖恢复后的 K/V，因此代表集合与成员表可供后续查询共同使用。静态桶 BVH 负责定位候选桶，每个分类域独立更新候选成员链，计算着色器再按完整 FP32 位模式筛选相等值。RT Core 执行 BVH 遍历与候选求交，成员构造和数值运算由计算着色器完成。

本文的主要贡献包括三个方面。首先，逐位置 K 类的完整成员映射给出一种内积重排，在实数算术下保持恢复后量化历史的键评分。其次，静态候选几何与变长类记录形成可复用的执行组织：描述符和代表值按实际代表数存储，成员索引覆盖全部坐标，多个共享查询头与查询行可以读取同一组类记录。最后，本文给出完整 V 与代表 V 两种值归约策略，并说明它们在函数语义、存储布局和有限精度计算上的联系。

附录中的几何光路模型将 RTA 的几何寻址扩展到反射、透射、强度与探测算子，为光路表示和内容读出提供统一的数学描述。

2 符号、输入语义与整体结构

设查询、键和值投影已按源模型顺序完成归一化和位置处理。GQA 的共享映射为

$$r = H_Q/H_G, \qquad g(h) = \lfloor h/r \rfloor. \tag{1}$$

表 1: 主要符号。头内坐标维数与有效代表数分开记号。

符号	含义
d_h, H_Q, H_G	头内维数、查询头数、共享键值头数
$g(h), r$	查询头到共享头的映射及共享比 $r = H_Q/H_G$
$i, j, \mathcal{J}_i$	查询位置、历史绝对位置与有效因果历史集合
$q_{i,h}, \widehat{k}_{j,g}, \widehat{v}_{j,g}$	位置处理后的查询及量化历史恢复值
$C^K_{j,g,a}, C^V_{j,g,a}$	以坐标 a 为代表的键类、值类完整成员集合
$\pi^K_{j,g}, \pi^V_{j,g}$	原坐标到对应类代表的完整映射
$D^K_{j,g}, D^V_{j,g}$	历史位置和共享头的有效代表数
s_{ijh}, w_{ijh}, Z_{ih}	FP32 实现所对应的得分、固定尺度权重与参考分母
$\mu \in \{0,1\}$	代表坐标策略与完整成员分发策略
R_w, R_q, C	历史写入批次行数、共享查询行数与历史容量

对绝对查询位置 i, $\mathcal{J}_i$ 同时满足因果性与当前历史窗口约束。源投影的 k, v 被历史编码映射写入，再由对应解码映射恢复：

$$P_j = (\mathcal{E}_K(k_j), \mathcal{E}_V(v_j)), \qquad \widehat{k}_j = \mathcal{D}_K(P^K_j), \quad \widehat{v}_j = \mathcal{D}_V(P^V_j). \tag{2}$$

以下命题以 $q, \widehat{k}, \widehat{v}$ 为输入，讨论同一组恢复值上的注意力计算。历史编码与解码由 $\mathcal{E}_K, \mathcal{E}_V$ 和 $\mathcal{D}_K, \mathcal{D}_V$ 决定，类划分使用恢复值的精确相等关系。

图 1 给出模型层间连接。完整层输出仍具有源模型的隐藏维数。坐标分块是一种保持通道身份的组织方法。对完整选择器 P_b，满足 $\sum_b P_b^{\mathsf{T}} P_b = I$，因此

$$h = P^{-1}\left(\bigoplus_b P_b h\right), \qquad h^{\mathsf{T}} w = \sum_b (P_b h)^{\mathsf{T}} (P_b w). \tag{3}$$

该恒等式保留所有块及其通道身份。V 策略的输出形状与内容归约分别由坐标映射和成员范围决定。

3 完整注意力及其强度解释

固定查询 i 与查询头 h，完整恢复值注意力为

$$s_{ijh} = \frac{q_{i,h}^{\mathsf{T}} \widehat{k}_{j,g(h)}}{\sqrt{d_h}} + b_{ijh}, \tag{4}$$

$$o^{\text{full}}_{i,h} = \frac{\sum_{j\in\mathcal{J}_i} \exp(s_{ijh}) \widehat{v}_{j,g(h)}}{\sum_{j\in\mathcal{J}_i} \exp(s_{ijh})}. \tag{5}$$

b_{ijh} 表示源算子的得分偏置或掩码。因果掩码对应零权重，未来位置不参与归约。若源模型具有输出 gate，则在内容归约完成后逐坐标施加。

将归一化权重解释为共同增益下的强度，只需要以下代数条件：

$$I_{ijh} = c_{ih} \exp(s_{ijh}), \qquad c_{ih} > 0, \tag{6}$$

$$N_{ih} = \sum_{j\in\mathcal{J}_i} I_{ijh} \widehat{v}_{j,g(h)}, \quad R_{ih} = \sum_{j\in\mathcal{J}_i} I_{ijh}. \tag{7}$$

命题 1 (共同强度尺度)**.** *若所有有效项的内容读出为 $\widehat{v}_j$，强度按式 (7) 给出，且内容与参考通道线性相加，则 $N_{ih}/R_{ih} = o^{\text{full}}_{i,h}$。*

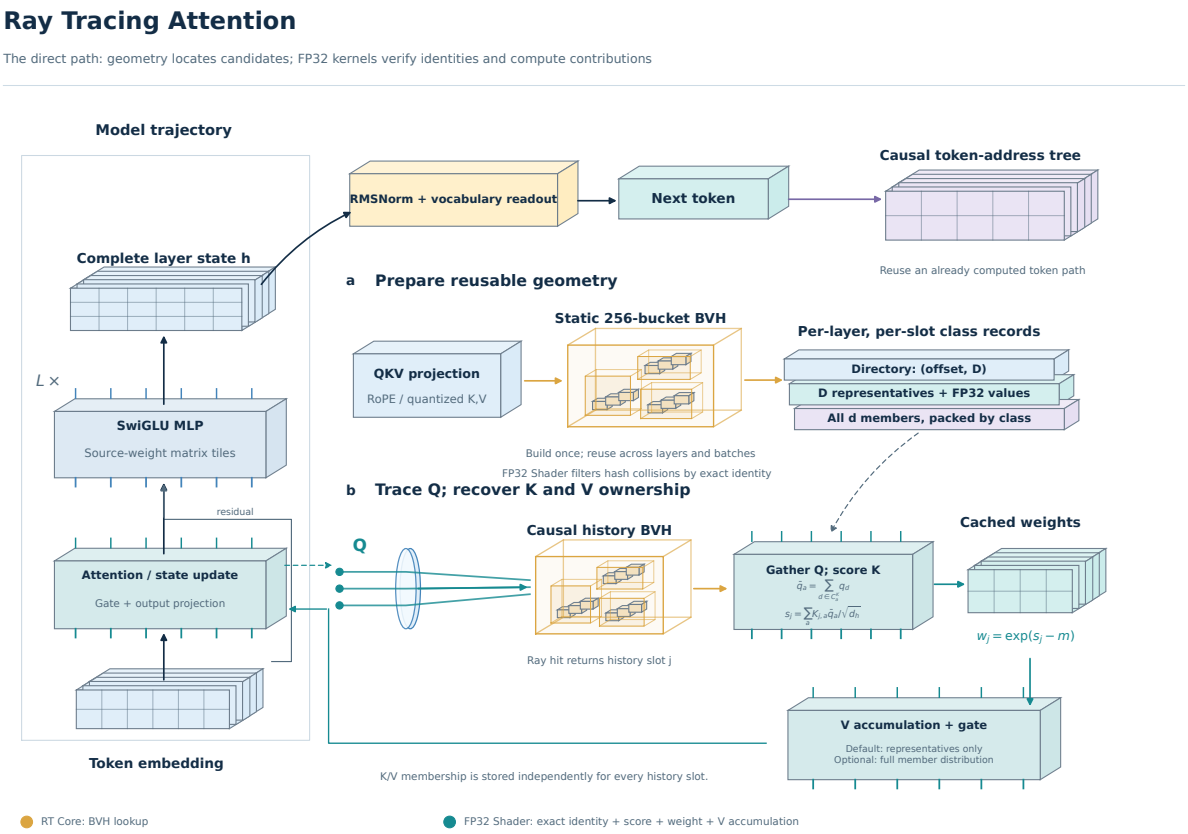


图 1: RTA 的模型级信息流。每层恢复完整高维输出，Attention、递推状态更新与前馈变换按源模型依赖相连。局部类缓存组织历史 K/V 的数值复用，因果状态缓存组织可复用的计算路径。光路与探测术语分别对应几何寻址和数值读出。

证明. 分子和分母共有正因子 c_{ih}，约去该因子即得到式 (5)。 □

这一表示将归一化权重写成共同增益下的强度，并将内容读出与参考通道联系起来。GPU 计算以浮点数保存得分、权重和归约结果；附录中的光学模型则沿用相同的代数结构描述理想传输与探测。

4 逐位置精确等价类与完整成员内积

4.1 相等关系与独立映射

对每个历史位置 j、每个共享键值头 g，定义

$$d \sim^K_{j,g} e \iff \widehat{k}_{j,g,d} = \widehat{k}_{j,g,e}, \tag{8}$$

$$d \sim^V_{j,g} e \iff \widehat{v}_{j,g,d} = \widehat{v}_{j,g,e}. \tag{9}$$

K 和 V 的划分分别建立。不同历史位置也具有独立划分。分类作用于有限 FP32 恢复值：正负零视为同一数值，其余值按完整位模式区分。无穷和 NaN 不参与分类。每个类由精确相等的成员组成。

每类选择最小原坐标作代表。以键为例，令

$$\pi^K_{j,g}(d) = \min\{e : e \sim^K_{j,g} d\}, \tag{10}$$

$$\mathcal{A}^K_{j,g} = \{\pi^K_{j,g}(d) : 0 \le d < d_h\}, \qquad D^K_{j,g} = |\mathcal{A}^K_{j,g}|, \tag{11}$$

$$C^K_{j,g,a} = \{d : \pi^K_{j,g}(d) = a\}, \qquad a \in \mathcal{A}^K_{j,g}. \tag{12}$$

值类及 π^V 同样定义，但不使用 K 的成员表。两个完整映射分别满足幂等性与分区条件：

$$\pi^K(\pi^K(d)) = \pi^K(d), \qquad \bigsqcup_{a \in \mathcal{A}^K} C^K_a = \{0, \dots, d_h - 1\}. \tag{13}$$

因此代表数可以少于 d_h，成员覆盖仍为 d_h。

4.2 类内查询求和

对任意查询头 h，键类查询和为

$$\bar{q}_{i,h;j,a} = \sum_{d \in C^K_{j,g(h),a}} q_{i,h,d}, \tag{14}$$

$$s_{ijh} = \frac{1}{\sqrt{d_h}} \sum_{a \in \mathcal{A}^K_{j,g(h)}} \widehat{k}_{j,g(h),a} \bar{q}_{i,h;j,a} + b_{ijh}. \tag{15}$$

同一类中的查询坐标可以不同，因此查询和由类内全部成员决定，类大小只描述成员数量。当代表键为零时，该类对得分的贡献为零，相应的查询和与乘法可以一并省去。

命题 2 (逐位置键类的内积等价). 对固定恢复后的有限输入，在实数算术下，式 (15) 等于式 (4)。

证明. 每个键类内 $\widehat{k}_{j,g,d} = \widehat{k}_{j,g,a}$。由式 (13) 的完整不交分区，

$$\sum_{d=0}^{d_h-1} q_{i,h,d} \widehat{k}_{j,g,d} = \sum_{a \in \mathcal{A}^K_{j,g}} \sum_{d \in C^K_{j,g,a}} q_{i,h,d} \widehat{k}_{j,g,d}$$

$$= \sum_{a \in \mathcal{A}^K_{j,g}} \widehat{k}_{j,g,a} \sum_{d \in C^K_{j,g,a}} q_{i,h,d}.$$

除以相同 $\sqrt{d_h}$ 并加入同一偏置得到结论。 □

例如 $\widehat{k}_j = (2,2,0,3)$ 与 $q_i = (1,4,-2,2)$ 的内积可重排为 $2(1+4)+0(-2)+3(2) = 16$。在邻近位置 $\widehat{k}_{j+1} = (2,0,2,3)$，同值成员变为 $\{0,2\}$，查询和也随之改为 $q_{i,0} + q_{i,2}$。因此，跨位置共享的是几何与索引结构，每个位置仍按自己的成员表汇总查询。

4.3 逻辑减算与必需的成员工作

对一个查询头和一个历史位置，稠密内积包含 d_h 个逻辑乘积。按类重排后，非零键代表至多贡献 $D^K_{j,g}$ 个乘积，类内查询坐标的读取与求和则按成员数保留。除乘法外，执行成本还包括描述符读取、成员汇合、寄存器与共享内存占用、补偿指令和同步。

$$C^{\text{dense}}_{QK} = d_h|\mathcal{J}_i|, \qquad C^{\text{class}}_{QK} \le \sum_{j \in \mathcal{J}_i} D^K_{j,g(h)}. \tag{16}$$

式 (16) 统计键内积的逻辑乘积，用于描述类划分带来的乘法复用。

5 静态桶 BVH 与精确分类

5.1 候选几何和数值身份

设 $\nu(x)$ 为有限 FP32 数值的规范化位模式：正负零均映射到零，其余值保留完整位模式。散列函数 H 将 $\nu(x)$ 映射到 B_H 个候选桶；一种具体构造取 $B_H = 256$。每个桶具有一个固定包围盒，形成常驻 BLAS/TLAS。这套几何在首次使用时构建，后续批次不因数值变化重建或调整包围盒。改变的是各个分类域自己的桶头和成员链。

分类域由历史批内位置、K/V 类型和共享头共同定义。对该域的每个坐标 d，从量化包恢复 x_d，把坐标索引加入桶 $H(\nu(x_d))$。查询射线命中同一个固定桶图元后，计算着色器遍历这个域的候选成员，接受候选 e 当且仅当

$$H(\nu(x_e)) = H(\nu(x_d)), \qquad \nu(x_e) = \nu(x_d). \tag{17}$$

第一项定位候选；第二项决定精确相等。不同值落入同桶时仍是不同类。桶几何共享而域成员不共享，因而不同位置、不同 K/V 类型和不同头不会相互合并。

命题 3 (候选过滤的正确性)**.** *若每个坐标恰好进入其散列桶，桶查询能定位对应固定桶，且完整遍历该域的候选链，则式 (17) 返回与有限 FP32 数值相等关系完全相同的类。*

证明. 相等规范化位模式必有相同桶，所以不会漏掉真正成员。所有被接受的候选又必须有相同完整位模式，所以碰撞不会加入错误成员。在每个接受集合中取最小坐标及递增成员顺序，所得代表和成员表与定义一致。 □

BVH 只负责候选访问。记录构造按坐标身份选择代表与后继，并按原坐标顺序排列成员，同时维护覆盖范围、索引和成员数量。候选筛选与数值归约在计算着色器中完成。

5.2 构建成本、域隔离与同步

写入 R_w 个历史位置时，一层分类的查询数为

$$N_{\text{rays}} = 2R_w H_G d_h. \tag{18}$$

因子 2 对应独立的 K 和 V 域。分类先于查询完成，生成的类记录可服务后续查询行和 GQA 查询头。历史投影和量化写入先完成，再产生候选链，随后进行 RT 查询、紧凑构造与常驻写入。各阶段之间的可见性和完成条件是复用同一工作区的前提。

各层可以共享批次临时区：类记录写入常驻载荷后，后续消费者读取对应的历史目录与载荷，临时区继续服务正在构造的域。缓冲区覆盖安排在消费者完成之后，目录则在载荷写入完成后发布。静态 BVH 保持几何复用，同步与缓冲区生命周期由运行时管理。

6 实际代表数驱动的紧凑记录

6.1 描述符、代表值与完整成员分配

每个域保留一个目录项，记录其常驻载荷偏移与实际代表数 D。域载荷由 D 个描述符、D 个原始 FP32 代表值，以及完整打包成员索引组成。第 ℓ 个描述符包含

$$\delta_\ell = (\text{root}_\ell, \text{offset}_\ell, \text{count}_\ell), \qquad 0 \le \ell < D. \tag{19}$$

根坐标属于所在域的代表集合，描述符序号与原坐标身份分别保存。成员片段从 offset_ℓ 开始，长度为 count_ℓ，包括代表本身并按原坐标递增排列。

$$\sum_{\ell=0}^{D-1} \text{count}_\ell = d_h, \qquad 1 \le \text{count}_\ell \le d_h. \tag{20}$$

当 $d_h = 256$ 时，代表坐标和成员偏移分别用 8 位，成员数量用 9 位，以表示单个类覆盖全部 256 维的情况。每个原坐标的成员索引用 1 字节，四个索引打包进一个 32 位字。因此，D 决定描述符和代表值的数量，成员索引始终覆盖全部 d_h 个坐标。

以该布局计，一个域的有用载荷为

$$M_{\text{domain}} = 4D + 4D + d_h \quad \text{bytes}, \qquad d_h = 256. \tag{21}$$

目录、对齐、可复用空闲空间和临时工作区不计入该式。新增记录按所在域的实际代表数 D 分配载荷；历史覆盖、缩小请求、环形槽覆写和容量扩展同步更新域身份与偏移。

常驻记录只保存代表值和成员索引。键阶段读取代表 K 值与成员索引，值阶段读取代表 V 值及成员分配。紧凑记录也可展开为逐坐标的代表、后继和次数关系，便于实现与调试；评分主循环则直接遍历描述符和打包成员索引。

6.2 有效维度循环与值的共享

后续键评分直接遍历 D^K 个描述符，不再逐个坐标寻找哪些坐标是代表。它读取一个代表值后，通过对应完整成员片段形成 $\bar{q}$，再以式 (15) 形成完整得分。值记录加载阶段同样遍历 D^V 个描述符和值。完整策略另外遍历其全部成员；代表策略只写根坐标。这既避免了反复解码同一量化恢复值，也避免了反复扫描所有原坐标以寻找类代表。

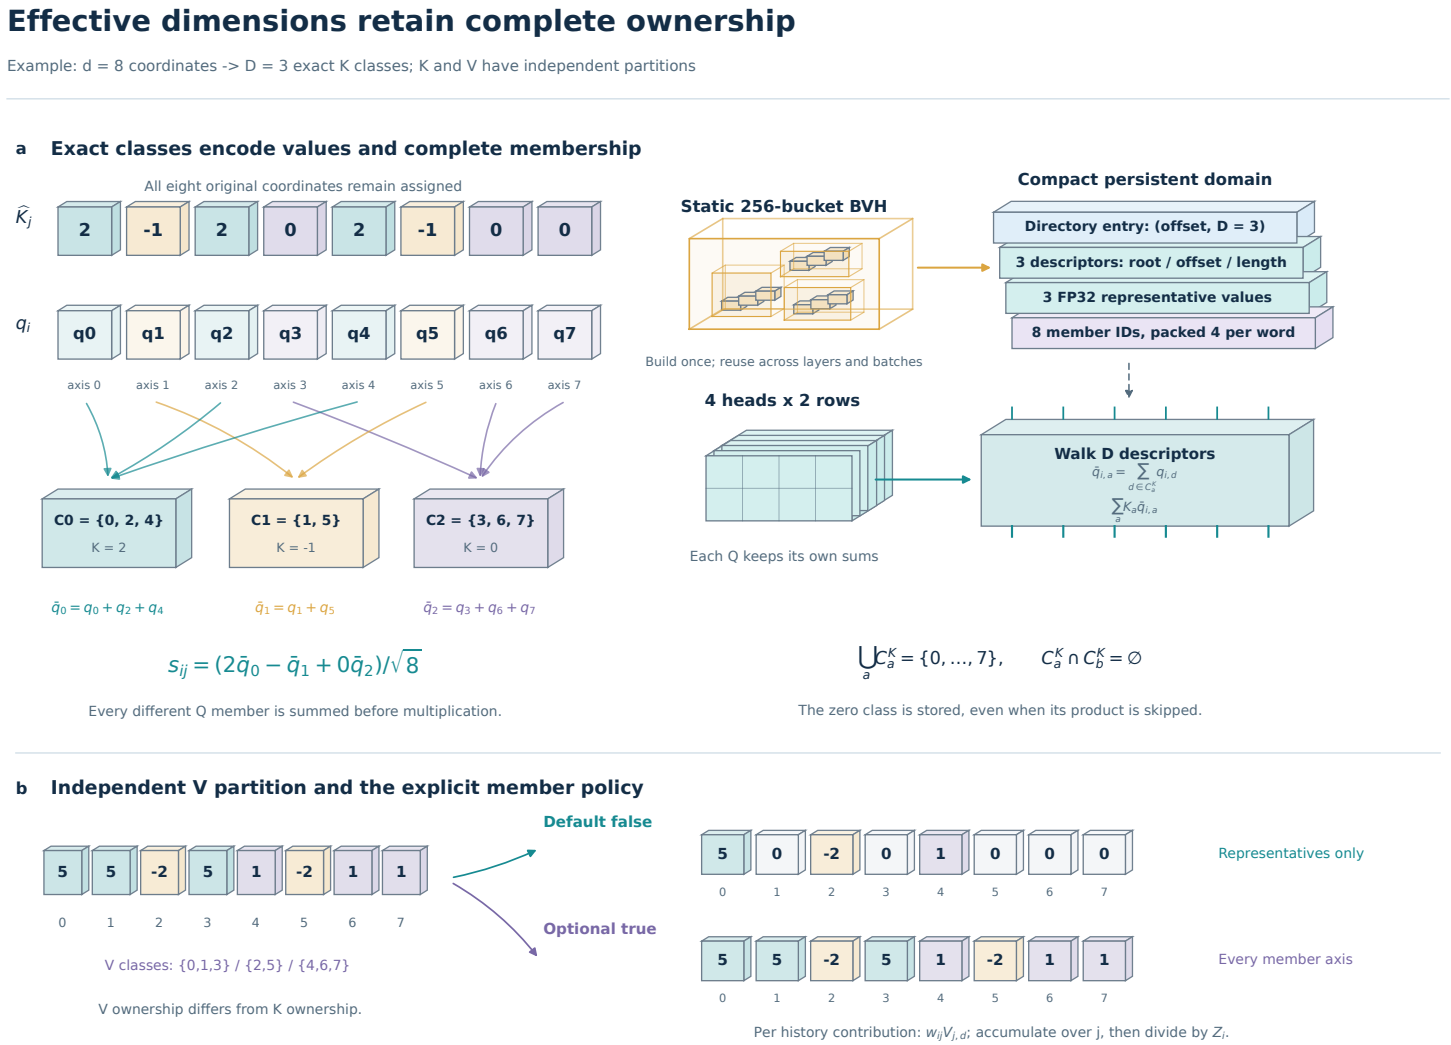


图 2: 逐位置 K/V 精确分类、变长类记录与多行键评分的连接。有效代表描述符和值按实际 D 遍历，打包成员仍完整覆盖原坐标。K 类汇合所有成员 Q；V 类分别执行代表坐标策略或完整成员分发。

当 $D = d_h$ 时，每个坐标都是代表，记录中仍包含成员索引、分类结果和目录。值加载循环遍历 D^V 个代表，完整 V 策略的加权乘加则按有效成员坐标执行。整体开销由输入的重复结构、记录复用次数和 GPU 资源占用共同决定。

7 多查询行与 GQA 头共享

7.1 共享记录，独立查询和

同一历史位置与共享头 (j, g) 的类结构能服务 r 个查询头。令 R_q 为同时处理的查询行数；对一个类，写成矩阵形式

$$\bar{Q}_{j,g,a}[u, h'] = \sum_{d \in C^K_{j,g,a}} Q[u, h', d], \quad 0 \le u < R_q, \quad 0 \le h' < r. \tag{22}$$

描述符、成员片段和代表键值读取可共享，矩阵中的每个元素仍是自己的完整成员和。例如，取 $r = 4$ 与 $R_q = 2$ 时，一次类读取服务两行各四个查询头。这八个查询通道共用类记录，并分别计算自己的成员查询和。

历史维度也可以分给不同子组处理。每个位置保留自己的得分与因果身份，并行分工不合并历史出现。查询坐标常驻共享区，成员索引用打包表访问；代表值和成员读取在共享头与查询行之间摊销。共享行数可以结合寄存器压力、共享内存占用和同步开销调节。

7.2 尾行、环形历史与回退

两个相邻查询行可以复用共同历史段，较新查询行再处理额外的因果项。每行按自己的 $\mathcal{J}_i$ 初始化得分、覆盖和权重；尾部只有一行时，只激活对应行。专用布局采用 $d_h = 256$ 及固定的 GQA 共享比，其余配置由通用路径处理。

两行路径要求共同历史段能够用同一覆盖规则表示。历史窗口已满、环形槽位跨界或有效域不一致时，改用单行路径，分别按绝对位置读取槽位，并保留每行的全部有效历史。因果绝对位置、物理环形槽和评分缓存偏移分别计算。

$$\mathrm{slot}(j) = j \bmod C, \qquad j \in \mathcal{J}_i \Longrightarrow \mathrm{time}(\mathrm{slot}(j)) = j. \tag{23}$$

历史身份由绝对位置和槽位时间戳共同确定。容量增长或覆写后的目录和成员载荷仍满足式 (20) 与式 (23)。

8 FP32 权重与两种值策略

8.1 固定尺度归一化

评分阶段保存各有效位置的得分，再求同一查询的最大值，随后在固定尺度下形成 FP32 权重与分母：

$$m_{ih} = \max_{j \in \mathcal{J}_i} s_{ijh}, \tag{24}$$

$$w_{ijh} = \exp(s_{ijh} - m_{ih}), \qquad Z_{ih} = \sum_{j \in \mathcal{J}_i} w_{ijh}. \tag{25}$$

有效项至少有一个时，实数算术下 $Z_{ih} > 0$。得分和权重按历史位置保存，供两种值归约策略共同使用。

8.2 完整成员分发策略

取 $\mu = 1$。对每个历史位置读取各 V 类的代表值，由完整成员表恢复每个原坐标对应的代表身份，并累计全部原坐标的加权贡献。在实数算术下，若 $d \in C^V_{j,g,a}$，

$$U^{(1)}_{ihd} = \sum_{j \in \mathcal{J}_i} w_{ijh} \widehat{v}_{j,g(h),\pi^V_{j,g(h)}(d)}, \quad o^{(1)}_{ihd} = U^{(1)}_{ihd} / Z_{ih}. \tag{26}$$

命题 4 (完整 V 策略的注意力等价)**.** *若 K 类保持式 (15) 的完整成员内积，V 类分别构成原坐标的完整分区，且所有有效历史项参与归约，则 $o^{(1)} = o^{\mathrm{full}}$，相等性针对同一恢复量化输入的实数算子。*

证明. 类映射保证 $\widehat{v}_{j,g,\pi^V_{j,g}(d)} = \widehat{v}_{j,g,d}$。因此式 (26) 的分子是全部原坐标的完整加权和；由键类内积等价与共同固定尺度，分母也相同，得到式 (5)。 □

在浮点实现中，每个成员坐标保留独立的历史累加状态，代表值读取则由类内成员共享。V 模块先读取 D^V 个代表值并建立坐标到代表的映射，随后对每个有效成员坐标执行权重与代表值的 FP32 乘加。完整策略处理全部成员坐标，代表策略只处理根坐标。因此，完整策略复用的是代表值读取，乘加次数由成员总数决定。类划分随历史位置更新，完整分发也按各位置的成员映射依次进行。

8.3 默认代表坐标策略

取 $\mu = 0$。每位置只把代表 V 贡献累加到该类根坐标。令对角选择矩阵 $S_{j,g}$ 的第 d 个对角元为 $\mathbf{1}_{\{d=\pi^V_{j,g}(d)\}}$，则其精确参考定义为

$$o^{(0)}_{i,h} = \frac{\sum_{j \in \mathcal{J}_i} w_{ijh} S_{j,g(h)} \widehat{v}_{j,g(h)}}{Z_{ih}}. \tag{27}$$

该选择随历史位置变化。分母和 K 评分保持完整，分子由各历史位置的根坐标贡献组成，由此形成代表坐标值算子。

例如，历史只有一个位置且 $\widehat{v} = (1, 1)$，两个坐标同属以 0 为代表的类。完整策略输出 $(1, 1)$，代表策略输出 $(1, 0)$，因为权重和分母均为 1。这个例子展示了两种策略在内容归约上的差别。

若源模型有逐坐标 gate，两个策略都在归约和形状恢复后施加

$$\widetilde{o}^{(\mu)}_{ihd} = \sigma(\gamma_{ihd}) o^{(\mu)}_{ihd}. \tag{28}$$

两种策略采用相同的 gate 形式，区别仅在于归约阶段参与累加的 V 坐标。

9 有限精度计算

9.1 乘积残差和补偿归约

实数恒等式定义目标算子，有限精度实现则进一步规定数据格式和归约顺序。评分、指数输入、缓存权重、分母和值加权均使用 FP32，成员查询和与恢复 K 直接参与 FP32 评分。矩阵投影与前馈层沿用各自的源格式和计算路径。

为控制消去和长归约的误差，采用补偿加法与 FMA 乘积残差 [7, 8]。记 fl 为一次浮点舍入，补偿状态从 $s_0 = c_0 = 0$ 开始，

$$y_n = \mathrm{fl}(x_n - c_{n-1}), \qquad s_n = \mathrm{fl}(s_{n-1} + y_n), \tag{29}$$

$$c_n = \mathrm{fl}\big(\mathrm{fl}(s_n - s_{n-1}) - y_n\big), \qquad \widehat{S} = \mathrm{fl}(s_N - c_N), \tag{30}$$

$$p_n = \mathrm{fl}(a_n b_n), \qquad r_n = \mathrm{fma}(a_n, b_n, -p_n). \tag{31}$$

保留乘积残差的路径分别累计 p_n 和 r_n；成员查询和、键类乘积、权重分母及值内容归约具有各自的状态。K 路径对成员和及类乘积进行补偿，类乘积保留 FMA 残差。不同线程的类部分和按树合并时同样维护补偿状态。共享两行与单行路径采用相同的成员补偿规则；每个查询头独立判断零成员和，跳过零乘积时保留原有补偿状态。例如，同一类内依次汇合 10^8、八个 1 和 -10^8 时，实数和为 8，普通 FP32 顺序加法可能得到 0，补偿加法则保留这些小项的贡献。

V 路径采用分块累加：成员映射恢复代表值后，每个有效成员坐标执行 FP32 融合乘加，先累计最多 64 个历史项的局部和，再将局部和并入补偿状态并清空局部和。分母同样使用补偿归约。若 c_d 表示轴 d 的局部和，一个块内更新与块末合并为

$$c_d \leftarrow \mathrm{fma}(w_j, \widehat{v}_{j,\pi_j^V(d)}, c_d), \qquad (s_d, e_d) \leftarrow \mathrm{CompAdd}(s_d, e_d, c_d), \quad c_d \leftarrow 0. \tag{32}$$

其中 CompAdd 表示式 (31) 的补偿加法。块补偿与逐乘积残差补偿采用不同的舍入次序。等价类的成员由位模式精确确定，最终浮点结果则由上述数据格式、归约顺序和补偿规则共同决定。

10 模型层、前馈变换与词表读出

10.1 保留源算子的依赖

局部 K 类重排完整键评分中的读取与乘积复用；V 类按既定的完整成员或代表坐标策略组织内容归约。每层的归一化、QKV 投影、位置变换、输出 gate、输出投影和残差仍按源模型规定连接。完整注意力层与递推层分别维护自己的历史状态。对于带门控 delta 递推的混合架构，记源模型处理后的信号为 q_t, k_t, v_t，

$$\beta_t = \sigma(W_b x_t), \quad \alpha_t = \exp[-\exp(A_{\log})\,\mathrm{softplus}(W_a x_t + d_{\mathrm{bias}})], \tag{33}$$

$$S_t^- = \alpha_t S_{t-1}, \quad \Delta_t = \beta_t \odot \big(v_t - (S_t^-)^{\mathsf{T}} k_t\big), \tag{34}$$

$$S_t = S_t^- + k_t \Delta_t^{\mathsf{T}}, \qquad o_t = S_t^{\mathsf{T}} q_t / \sqrt{d_k}. \tag{35}$$

卷积历史、头标定和输出门控由相应层定义。在 GPU 计算中，状态 S_t 由数值缓冲区保存，并按式 (35) 更新。

10.2 矩阵前馈和条件化光学解释

完整 SwiGLU 前馈为 [6]

$$z = \mathrm{SiLU}(W_g x) \odot (W_u x), \qquad y = W_d z. \tag{36}$$

批量矩阵、量化块解码和单行向量归约可以表达同一算子，有限精度格式由相应计算路径决定。矩阵前馈沿用数值计算路径，局部 Attention 的类记录负责 K/V 的组织与复用。对于非整批行数，可以缩小矩阵 tile，使调度与实际行数匹配。

附录的平衡探测模型给出另一种表示：将 $W_{ri}x_i$ 的正负贡献分开累计，令共同增强与传输尺度约去，在线性传输与符号路由条件下得到 Wx。模型保留源权重及其坐标身份，RT 命中用于寻址和读取组织，数值阶段完成乘加。

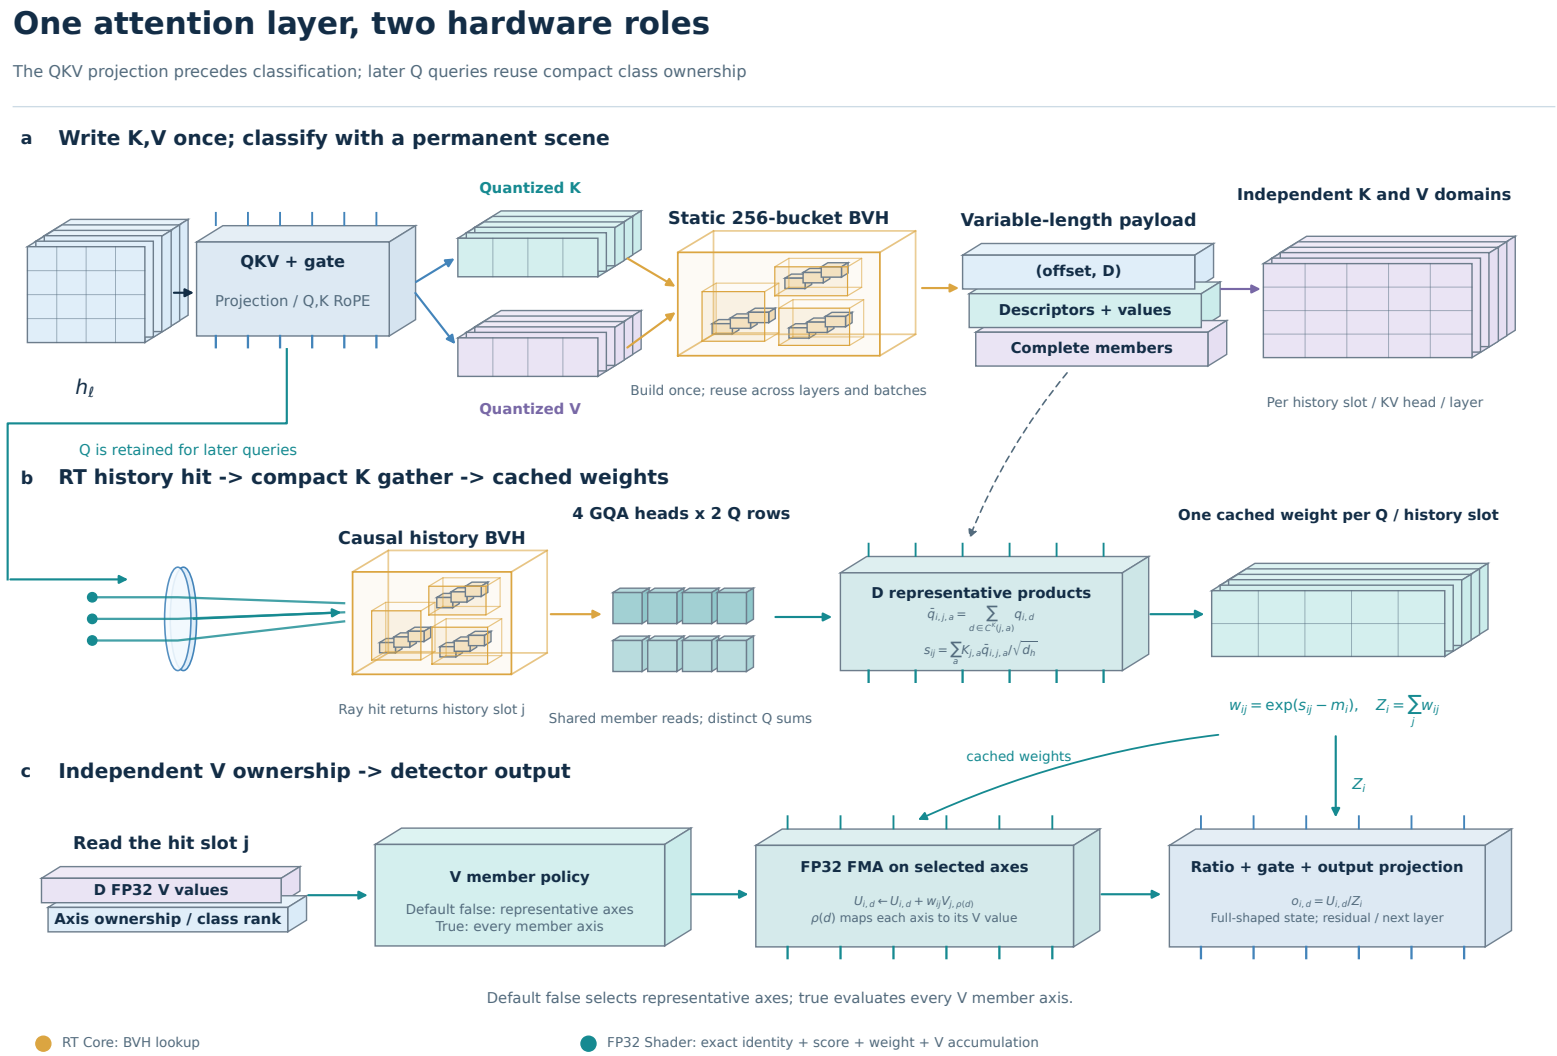


图 3: 单层局部 Attention 的 K/V 分类、完整 K 成员汇合、FP32 权重缓存与逐轴 V 累加。独立 V 类提供原坐标对应的代表值；默认策略选择代表轴，完整策略处理全部成员轴。gate 和输出投影随后按源模型依赖执行。

10.3 完整词表与坐标身份

对最终高维状态 h 与词表第 v 个权重向量 w_v，

$$\ell_v = h^{\mathsf{T}} w_v = \sum_b (P_b h)^{\mathsf{T}} (P_b w_v), \tag{37}$$

$$J_v = \exp(\ell_v + c), \qquad \arg\max_v J_v = \arg\max_v \ell_v. \tag{38}$$

式 (38) 汇合词元的全部权重块，得到完整高维分数。对一个双坐标片段，其点积可写为幅度与余弦角度的乘积；各片段的幅度、符号与身份共同构成最终词元得分。几何命中返回词元及块身份，数值阶段读取对应的原系数并汇合分数。输入嵌入与输出头共享参数时可以共享同一载荷，这种载荷复用与历史局部类复用属于不同结构。

11 因果状态复用与历史生命周期

模型级因果缓存与局部 K/V 类缓存分别维护计算路径和数值结构。局部类由恢复值决定，服务后续注意力计算；因果状态节点记录可复用的输入与输出路径。新历史写入时直接建立精确类并使用紧凑评分。恢复历史时，数值字段与历史身份相同的有效域目录和类载荷继续复用，缺失记录或身份变化的历史则重新分类。域目录和记录状态共同标明类载荷的完整性。下一词元的复用身份包括完整输入、先前输出、绝对位置、模型与运行时数值策略以及停止条件。

$$\mathcal{Q}_t = (\text{input}_{\le t}, \text{output}_{<t}, t, \text{model}, \text{policy}, \text{stop}). \tag{39}$$

值策略与源参数也纳入复用命名空间，使每条上下文路径对应完整的计算状态。

公共历史块通过不可变引用连接多个分支，边界检查点保存继续计算所需的高维状态、递推历史和有效历史引用。已有输出路径命中时，节点返回词元和后继身份；新分支继续计算尚未覆盖的状态。历史容量增长时，目录和载荷在旧缓冲区使用结束后按原分配边界迁移。窗口覆写使旧槽位身份失效，仍被引用的分支则保留对应内容。

路径拓扑缓存管理命中身份与可见结构，数值复用同时记录查询、权重、内容和输出策略。静态桶 BVH 跨批次保持几何不变，K/V 成员关系随历史值更新，查询权重则在评分阶段生成。几何、类记录、模型状态与最终词元构成四个复用层次。

12 相关工作与讨论

GQA 通过多个查询头共享 K/V 头减少历史载荷 [2]。RTA 进一步利用共享头内部、各历史位置的精确数值重复，两种共享可以结合使用。FlashAttention 及其后续工作通过 IO 感知的分块和归约组织完整 Attention[3, 4]，RTA 则通过等价类成员映射复用相同键值的乘法。PagedAttention 以分页和块复用管理推理历史 [5]，RTA 的变长载荷按每个域的实际代表数组织数值类记录。

光线追踪通过层次包围体加速几何候选访问 [9, 10]。在 RTA 中，静态桶几何提供候选身份，完整位模式过滤确定精确类成员。直接散列、排序和位掩码也可用于精确索引，它们与静态 BVH 构成不同的实现选择。

光学神经计算利用特定器件与编码实现矩阵或衍射变换 [11, 12]。RTA 附录的反射与平衡探测模型延续这一表示思路，讨论几何自由度、探测量和内容读出之间的关系。

RTA 的计算组织与输入的重复结构密切相关。代表数接近全维时，成员索引、分类和目录维护占据主要开销；重复值较多且记录被多次复用时，代表值与结构读取的共享更为充分。完整 V 与代表 V 具有不同的成员范围和函数语义，可分别适用于完整内容归约与稀疏坐标读出。

13 结论

RTA 以精确数值等价类组织量化历史，在保留完整成员查询和的同时复用重复键乘法。静态候选 BVH 与完整 FP32 位模式过滤构造独立的 K/V 类，实际代表数决定描述符和值的存储，打包成员索引覆盖全部原坐标。同一组类记录可服务多个 GQA 查询头和查询行，并与环形历史及因果状态缓存配合。完整 V 策略保持同一恢复量化输入的全注意力实数算子，代表 V 策略则给出由根坐标贡献构成的值算子。这些组件共同形成从精确分类、紧凑存储到数值归约的完整计算路径。

A 整列等价与跨组摘要：一种扩展算法

本节将逐位置数值类扩展到整列等价与跨组摘要。将有效历史划分为不交组 B；若某个完整包在组内出现多次，且各次出现具有相同的数值和位置作用，则将其归为 p 并记录次数 c_p。共用代表得分与内容的条件包括键、值以及得分偏置或位置作用相同。

$$\sum_p c_p = |B|, \qquad \sum_{j\in p} \exp(s_j) v_j = c_p \exp(s_p) v_p. \tag{40}$$

完整包的数值与位置作用共同决定这一分组。

整组列关系要求各个组内历史项都满足相等：

$$d \sim_B^K e \iff \widehat{k}_{p,d} = \widehat{k}_{p,e}\ \forall p \in B, \quad d \sim_B^V e \iff \widehat{v}_{p,d} = \widehat{v}_{p,e}\ \forall p \in B. \tag{41}$$

它比逐位置相等更强。同组键列类的全部 Q 成员仍需汇合；V 列类只在整列相等时允许共用一个跨历史的分子。记 V 列代表映射为 π_B，在固定最大值得分下形成

$$m_B = \max_p s_p, \quad w_p = c_p \exp(s_p - m_B), \tag{42}$$

$$Z_B = \sum_p w_p, \qquad U_{B,a} = \sum_p w_p v_{p,a}, \tag{43}$$

$$\mathcal{R}_B = (m_B, Z_B, \pi_B, (U_{B,a})_a). \tag{44}$$

不同组的列划分可能不同。取全部组相等关系的交集，以 π_* 表示最终代表映射，得到

$$m = \max_B m_B, \qquad \alpha_B = \exp(m_B - m), \tag{45}$$

$$Z = \sum_B \alpha_B Z_B, \qquad U_d = \sum_B \alpha_B U_{B,\pi_B(d)}, \qquad o_d = U_d / Z. \tag{46}$$

每个原坐标按自己在各组的映射取分子，各组保留独立的列划分。

命题 5 (扩展摘要的完整贡献)**.** *若完整包次数覆盖所有出现、整列关系精确、每个原坐标按各组映射恢复，则式 (46) 在实数算术下给出完整 Attention。*

证明. 对任意 d，分子为 $\sum_j \exp(s_j - m) v_{j,d}$，分母为 $\sum_j \exp(s_j - m)$。共同因子约去即得到完整归一化结果。 □

该命题采用完整 V 贡献。若结合正文的代表坐标策略，先将各位置的值向量替换为 $S_{j,g}\widehat{v}_{j,g}$，再使用相同的分组与汇合公式。

B 几何光路补充模型

以下各节建立单路径镜面、曲面、Fourier 探测、软发射和理想平衡透射模型，描述几何寻址、传播与读出的数学形式。单条最近命中路径构成读取原语，完整 Attention 则由全部有效历史的强度与内容汇合得到。高维内容通过几何参数、片段身份和探测通道共同表示。附录中 D 在需要时表示探测通道数，与正文每域有效代表数 D^K, D^V 区分。

B.1 补充模型的坐标与身份

在以下单路径模型中，x_i 表示输入状态，s_i 表示词元身份，g_j 表示一次历史出现的几何参数，S_j 表示其表面。二维发射地址另记为 $q_i \in \mathbb{R}^2$，其含义与正文注意力的高维查询 $q_{i,h}$ 不同。几何发射映射和共享探测映射可以具有参数 θ，用于描述地址与探测模式的变化。

对一个双坐标片段的有限局部参数 $t \in \mathbb{R}^2$，定义半球方向图

$$d(t) = \frac{(t_1, t_2, 1)}{\sqrt{1 + \|t\|^2}}, \qquad \theta(t) = (\operatorname{atan2}(t_2, t_1), \arctan \|t\|)\,. \tag{47}$$

若 $\|t\| \le \tan \beta_{\max}$ 且 $\beta_{\max} < \pi/2$，则该方向留在给定半球中。局部方向描述片段的几何关系，幅度、符号与完整片段身份随记录保存。

$$\mathrm{Address}(v, b, p) = (v, b, p), \qquad (v, b, p) \neq (u, c, r) \Longrightarrow \mathrm{Address}(v, b, p) \neq \mathrm{Address}(u, c, r). \tag{48}$$

这里 v, b, p 分别是词元、块和片段身份。相同二维方向可以共享图元，高维内容由完整地址区分。

对单位基础方向 d_v，令 $T_v \in \mathbb{R}^{3\times 2}$ 的列为其正交切平面基。一个受限的上下文方向修正模型为

$$\epsilon_i = \epsilon_{\max} \tanh \mathcal{A}_\theta(x_i, h_i^{\mathrm{ctx}}, \theta_v), \qquad d_i = \frac{d_v + T_v \epsilon_i}{\|d_v + T_v \epsilon_i\|}. \tag{49}$$

由 $d_v^{\mathsf{T}} T_v = 0$ 可得 $\angle(d_i, d_v) = \arctan \|\epsilon_i\|$。该式给出有界寻址构造，方向修正幅度由 $\epsilon_{\max}$ 控制。

C 几何记忆与因果时间轴

C.1 有限镜面的参数化

基本记录采用七个几何参数：式 (50)。$c_j \in \mathbb{R}^2$ 是镜面中心，$a_j \in \mathbb{R}^2$ 决定倾角，h_j 是相对高度，$r_j \in \mathbb{R}^2_{>0}$ 是半孔径。记平面坐标 $\xi = (x, y)$，镜面定义为式 (51)。不等式按坐标分别成立。镜面朝 $-z$ 一侧反射，另一侧透射。

一组具体的有界写入映射为式 (54)。取

$$g_j = (c_{jx}, c_{jy}, a_{jx}, a_{jy}, h_j, r_{jx}, r_{jy}). \tag{50}$$

$$S_j: \quad z = -\Delta j + h_j - a_j^{\mathsf{T}}(\xi - c_j), \qquad |\xi - c_j| \le r_j. \tag{51}$$

$$w_j = W_G \,\mathrm{Norm}(x_j) + b_G \in \mathbb{R}^7, \tag{52}$$

$$c_j = \tanh(w_{j,1:2}), \qquad a_j = A \tanh(w_{j,3:4}), \tag{53}$$

$$h_j = H \tanh(w_{j,5}), \qquad r_j = r_{\min} + (r_{\max} - r_{\min})\sigma(w_{j,6:7}), \tag{54}$$

$$A = H = \frac{1}{4}, \qquad r_{\min} = \frac{1}{40}, \qquad r_{\max} = \frac{1}{2}, \qquad \Delta = 4. \tag{55}$$

中心与孔径决定可访问区域，倾角决定反射方向，高度决定传播距离。这些量共同定义同一块几何记忆。

C.2　竖直射线的解析坐标模板

为得到闭式光路，先采用竖直入射的局部模板。发射器将当前输入映射到二维平面地址：式 (56)。令发射器位于当前时间层的下方，固定间距 $s = 2$：

$$q_i = \tanh\big(W_E\,\mathrm{Norm}(x_i) + b_E\big) \in (-1, 1)^2. \tag{56}$$

$$o_i = (q_{ix}, q_{iy}, -\Delta i - s), \qquad d = (0, 0, 1), \qquad \rho_i(t) = o_i + td, \quad t > 0. \tag{57}$$

二维地址承担这一模板的语义寻址，纵向坐标承担顺序与因果关系。一般角度射线沿式 (47)–(49) 发射，其求交与传播在后文定义。

C.3　因果性的几何构造

令镜面相对于时间层的最大高度幅度为 同组的高度幅度式。于是每个表面都满足

$$B_z = H + 2Ar_{\max} = \frac{1}{2}.$$

$$-\Delta j - B_z \le z(S_j) \le -\Delta j + B_z. \tag{58}$$

命题 6 (因果可见性)**.** *当 $B_z < s < \Delta - B_z$ 时，查询 i 的全部历史镜面位于入射方向前方，全部未来镜面位于起点后方。*

证明. 对 $j \le i$，镜面的最低点与起点之间的纵向距离至少为 同组的历史距离下界。对 $j \ge i+1$，镜面的最高点与起点之间的距离至多为

$$\Delta(i - j) + s - B_z \ge s - B_z > 0.$$

$$\Delta(i - j) + s + B_z \le -\Delta + s + B_z < 0.$$

式 (55) 取值下，两侧各有 1.5 的严格间隔。 □

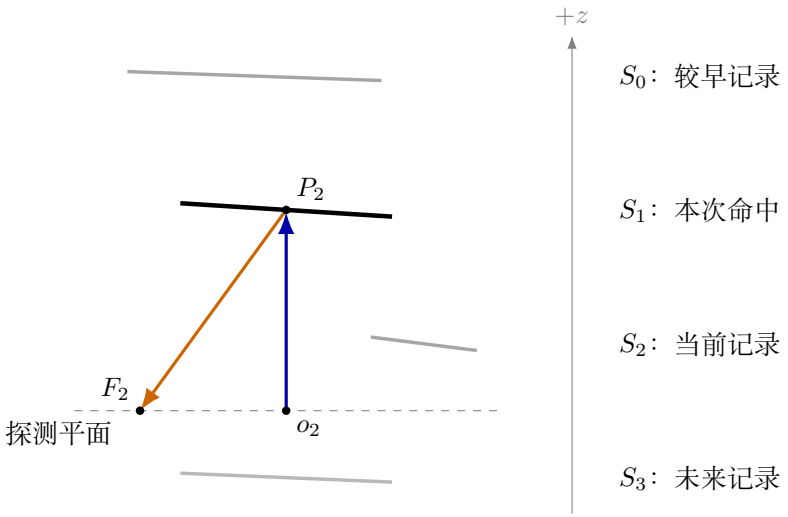


图 4: 时间层与单条光路的截面示意。查询地址穿过当前镜面的孔径之外，在较早镜面上反射；未来记录位于发射器后方。

C.4　空间地址上的最近写入

记孔径区域 同组的孔径定义。当 $q_i \in \mathcal{A}_j$ 时，入口距离由平面方程直接给出：式 (59)。设可访问记录集合为 同组的可访问集合定义。读取索引为

$$\mathcal{A}_j = \{\xi : |\xi - c_j| \le r_j\}.$$

$$\lambda_{ij} = \Delta(i-j) + s + h_j - a_j^{\mathsf{T}}(q_i - c_j). \tag{59}$$

$$\mathcal{V}_i(q_i) = \{j \le i : q_i \in \mathcal{A}_j\}.$$

$$j_i^* = \arg\min_{j \in \mathcal{V}_i(q_i)} \lambda_{ij}. \tag{60}$$

$$j_i^* = \max \mathcal{V}_i(q_i). \tag{61}$$

$$\mathcal{D}_{ij} = \mathcal{A}_j \setminus \bigcup_{j<k\le i} \mathcal{A}_k. \tag{62}$$

集合为空时，以 $\perp$ 表示空路径，并令其探测响应为零。

由于相邻时间层的间隔 Δ 大于 $2B_z$，式 (60) 等价于式 (61)。这是一种带空间地址的覆盖式记忆：同一地址由最近覆盖它的表面响应，不同孔径区域保存各自的可见历史。

对于固定查询时刻 i，记录 j 的可见地址域为式 (62)。这些区域将发射平面划分为由不同记录响应的部分。BVH 将该几何集合组织为空间层次，按照射线与包围区域的相交关系完成定位，最近交点直接确定读取路径。式 (60) 和式 (62) 定义几何语义；运行时的候选、交点与遮挡由几何求交 Core/BVH 求得。

D 单路径反射与完整光程

D.1 命中点与出射方向

记本次命中参数为 $a = a_{j_i^*}$、$\lambda = \lambda_{ij_i^*}$。在发射器局部坐标系中，入射点为原点，命中点为 同组的命中点式。取 $n = (a_x, a_y, 1)$。反射方向由

$$P = (0, 0, \lambda).$$

$$r = d - 2\frac{n^{\mathsf{T}}d}{n^{\mathsf{T}}n}n = \left(-\frac{2a}{1+\|a\|^2}, \frac{\|a\|^2-1}{1+\|a\|^2}\right) \tag{63}$$

给出，且 $\|r\| = 1$。参数域 (55) 保证 $\|a\|^2 \le 1/8$，所以 $r_z < 0$。射线沿同一条反射路径返回探测平面。

D.2 固定局部探测平面

探测器固定在发射器局部坐标系的 $z = 0$ 平面，其全局位置随时间原点平移。令返回距离为 η，则 同组的回程距离式。相对发射位置的落点及往返光程为

$$\lambda + \eta r_z = 0, \qquad \eta = \lambda\frac{1+\|a\|^2}{1-\|a\|^2}.$$

$$\boxed{F_{xy} = -\frac{2\lambda a}{1-\|a\|^2}, \qquad \ell = \lambda + \eta = \frac{2\lambda}{1-\|a\|^2}.} \tag{64}$$

因而 $F_{xy} = -\ell a$。倾角写入探测器落点，高度与记录距离写入飞行时间，两者由同一次几何命中联合读出。

D.3 回程的几何可达性

命题 7 (单面镜的直接回程)**.** *设场景内任意镜面倾角 a, b 均满足各坐标绝对值不超过 $1/4$。由倾角 a 产生的反射方向，在其他镜面上均从透射侧通过。*

证明. 用 $\tilde{n}_b = (b_x, b_y, 1)$ 表示另一镜面的法向。根据式 (63)，

$$\tilde{n}_b^{\mathsf{T}} r = \frac{\|a\|^2 - 1 - 2b^{\mathsf{T}} a}{1 + \|a\|^2} \le \frac{-5/8}{1 + \|a\|^2} < 0.$$

其他镜面的反射正面朝 $-\tilde{n}_b$，因此回程与其外向反射法向的内积为正，对应背面透射。整条返回光路由式 (64) 确定。 □

D.4 传播能量

在均匀介质中，采用光程衰减系数 $\mu > 0$，单位发射与单位表面增益的基准强度为

$$E_i = \exp(-\mu \ell_i). \tag{65}$$

一个具体取值为 $\mu = 1/4096$。这使路径长度同时表现为时间观测和强度观测。发射、表面相互作用与探测共同构成一次完整的有向几何读取。路径增强在这一传播因子上乘以独立增益。

E 共享探测器与多通道编码

E.1 路径观测

定义归一化光路观测

$$u_i = \left(\frac{F_{ix}}{1 + \ell_i}, \frac{F_{iy}}{1 + \ell_i}, \log_2(1 + \ell_i) \right) \in \mathbb{R}^3. \tag{66}$$

$$z_{i,k} = E_i b_k(u_i).$$

前两项描述落点，第三项描述飞行距离的对数尺度。探测器采用对所有记录共享的基函数 $b_k(u)$，产生 同组的通道响应式。输出宽度由探测模式的数量确定，每个模式观测同一条入射与反射光路。

E.2 一组具体的 Fourier 探测模式

令输出维数 $D \ge 4$ 为偶数，模式编号 $k = 0, \dots, D/2 - 1$。取

$$d_k = k \bmod 3, \qquad f_k = \frac{\lfloor k/3 \rfloor + 1}{4}.$$

$$z_{i,2k} = E_i \sin(2\pi f_k u_{i,d_k}), \tag{67}$$

$$z_{i,2k+1} = E_i \cos(2\pi f_k u_{i,d_k}). \tag{68}$$

完整响应定义为式 (68)。$D = 256$ 对应 128 对正弦与余弦响应。较低频率描述光路的整体变化，较高频率提供更细的响应结构。共享线性输出投影将这些模式组合为模型的残差分支信号。

命题 8 (基准强度下的光路可解码性)**.** 对 $\ell > 0$、$\mu > 0$，采用式 (65) 的已标定基准强度时，式 (68) 的前两个空间模式及其共同强度可以恢复 ℓ 与 F_{xy}。

证明. 由第一对响应恢复强度：同组的强度与光程恢复式。对任意单位方向传播到探测平面的光路，$|F_x|, |F_y| \le \ell$，所以 $|u_x|, |u_y| < 1$。第一组空间频率为 $1/4$，相位落在 $(-\pi/2, \pi/2)$ 内，故

$$E = \sqrt{z_0^2 + z_1^2}, \qquad \ell = -\frac{1}{\mu} \log E.$$

$$u_x = \frac{2}{\pi} \operatorname{atan2}(z_0, z_1), \qquad u_y = \frac{2}{\pi} \operatorname{atan2}(z_2, z_3), \qquad F_{xy} = (1 + \ell)(u_x, u_y).$$

在镜面模板下，进一步由 $a = -F_{xy}/\ell$ 与 $\lambda = \ell(1 - \|a\|^2)/2$ 恢复命中倾角和入口距离。 □

这个构造把形状响应、传播距离与有符号输出连接起来。能量控制共同幅度，探测基函数提供各输出通道的空间与时间响应。

E.3 平衡探测的有符号读出

对任一探测模式 $b_c(u) \in [-1,1]$，将对应份额的光强分配到正、负两支：

$$I_c^+ = \frac{E}{2D}\big(1 + b_c(u)\big), \qquad I_c^- = \frac{E}{2D}\big(1 - b_c(u)\big). \tag{69}$$

$$z_c = D(I_c^+ - I_c^-) = E\, b_c(u). \tag{70}$$

两支均为非负强度，全部通道的强度总和为 E。统一标定后的平衡差给出式 (70)。空间与飞行时间决定共享模板的透射比例，平衡差形成模型使用的有符号特征。

F 曲面几何的统一表达

F.1 从平面到形状场

几何记忆还可以表示为有限孔径上的高度场：式 (71)。约束取为式 (72)。这些条件保持时间层的因果间隔和反射法向的角度范围。

一条竖直射线在其查询地址处读取

$$S_j: \quad z = -\Delta j + H_j(\xi), \qquad \xi \in \mathcal{A}_j. \tag{71}$$

$$|H_j(\xi)| \le B_z, \qquad |\partial_x H_j(\xi)|,\ |\partial_y H_j(\xi)| \le A. \tag{72}$$

$$\lambda_{ij} = \Delta(i-j) + s + H_j(q_i), \qquad a_{ij} = -\nabla H_j(q_i). \tag{73}$$

将它们代入式 (64)，即可得到同一探测规则下的光路。曲面在不同地址提供不同的高度与法向响应，从而将一条历史记录表示为可被查询位置采样的几何函数。

F.2 控制点写入

例如，采用次数为 (p,q) 的张量积 Bézier 高度场。在孔径内定义局部坐标 同组的局部坐标式。令 $B_a^p(s) = \binom{p}{a} s^a (1-s)^{p-a}$，写入

$$s_x = \frac{\xi_x - c_{jx} + r_{jx}}{2r_{jx}}, \qquad s_y = \frac{\xi_y - c_{jy} + r_{jy}}{2r_{jy}}.$$

$$H_j(\xi) = \sum_{a=0}^{p}\sum_{b=0}^{q} \beta_{j,ab} B_a^p(s_x) B_b^q(s_y). \tag{74}$$

控制系数 $\beta_{j,ab}$ 是曲面的形状坐标。Bernstein 基函数的非负性和分割统一性给出 同组的幅度界。同时，

$$|H_j| \le \max_{a,b} |\beta_{j,ab}|.$$

$$|\partial_x H_j| \le \frac{p}{2r_{jx}} \max_{a,b} |\beta_{j,a+1,b} - \beta_{j,ab}|, \tag{75}$$

$$|\partial_y H_j| \le \frac{q}{2r_{jy}} \max_{a,b} |\beta_{j,a,b+1} - \beta_{j,ab}|. \tag{76}$$

因此，控制点的幅度与相邻差分约束直接实现式 (72)。平面、分片平面和光滑曲面由此共享同一套时间轴、入口查询与探测定义。几何表示的细节通过命中位置处的高度和局部法向进入读出。

G　发射模板与单路径软读取

G.1　发射位置的概率模板

令 $p_i(q)$ 为查询 i 在发射平面上的概率密度。它描述语义地址附近的入射分布。一次读取从该模板取一个位置：同组的发射位置式。记录 j 被读取的概率为式 (77)。设 $\mathcal{D}_{i\perp}$ 为孔径并集之外的区域，则 同组的概率归一化式。

在概率意义下，探测响应的完整期望为

$$q_i \sim p_i(q), \qquad \rho_i(t) = (q_i, -\Delta i - s) + td.$$

$$\alpha_{ij} = \int_{\mathcal{D}_{ij}} p_i(q)\,\mathrm{d}q. \tag{77}$$

$$\sum_{j\le i} \alpha_{ij} + \alpha_{i\perp} = 1.$$

$$\overline{z}_i = \sum_{j\le i} \int_{\mathcal{D}_{ij}} p_i(q)\, e^{-\mu \ell_{ij}(q)} \Phi_D\big(u_{ij}(q)\big)\,\mathrm{d}q. \tag{78}$$

$$\eta_i \sim \mathcal{N}(m_i, \Sigma_i), \qquad q_i = \tanh \eta_i, \qquad (m_i, \Sigma_i) = \mathcal{E}_\theta(x_i). \tag{79}$$

这里 Φ_D 表示式 (68) 中的单位幅度模式。一次采样产生一个 z_i，其期望正是式 (78)。可见区域的概率质量决定记录的参与程度，光路决定具体的信号内容。

一种带有限束宽的发射模板为式 (79)。例如可取 $\Sigma_i = \mathrm{diag}(\mathrm{softplus}(s_i)^2)$，其中 s_i 由发射器同时给出。中心 m_i 给出查询地址，协方差 Σ_i 给出射线束的空间范围。将分布集中到中心位置，得到确定性的中心射线读取。

G.2　单次方向采样的漫反射模板

在命中点处，可围绕镜面方向 r 规定一个半角为 Θ 的散射锥。令 (t_1, t_2, r) 为正交标架，出射方向写为式 (80)。相对于立体角 $\mathrm{d}\omega = \sin\theta\,\mathrm{d}\theta\,\mathrm{d}\phi$，归一化余弦模板为式 (81)。令 u, v 为两个独立均匀随机数，使用

$$\omega = \cos\theta\, r + \sin\theta(\cos\phi\, t_1 + \sin\phi\, t_2). \tag{80}$$

$$p_\Theta(\theta, \phi) = \frac{\cos\theta}{\pi \sin^2\Theta} \mathbf{1}_{\{0\le\theta\le\Theta\}}, \quad 0 \le \phi < 2\pi. \tag{81}$$

$$\theta = \arcsin(\sin\Theta\sqrt{u}), \qquad \phi = 2\pi v$$

即可取一个出射方向。$\Theta = 0$ 对应中心镜面方向。

记法向最大偏角为 $\beta = \arctan(\sqrt{2}A)$。取式 (82) 中的约束，便保持出射方向朝向探测器，并从场景其他镜面的透射侧通过。例如 $A = 1/4$ 时可取 $\Theta \le \pi/12$。

给定本次采样的 ω，完整返回光路为

$$3\beta + \Theta < \frac{\pi}{2}, \tag{82}$$

$$\eta = \frac{\lambda}{-\omega_z}, \qquad F_{xy} = \eta\omega_{xy}, \qquad \ell = \lambda + \eta. \tag{83}$$

同一条路径在表面上完成一次方向选择，再进入共享探测规则。对发射位置和出射方向同时取期望，式 (78) 的被积项相应增加对散射模板的期望。这把确定性反射和单路径漫反射纳入统一的传播模型。

H 角度光路、共享透镜与独立增强

H.1 一般射线与多段传播

第 k 段射线记为 $\rho_k(t) = o_k + td_k$、$t > 0$、$\|d_k\| = 1$。对式 (51) 的平面表面，候选交点的解析距离为式 (84)。分母为零时按平行射线处理，正距离、孔径归属、面朝向及最近遮挡共同确定有效命中。求交观测量由命中目标身份、重心坐标与传播距离组成，局部形状映射给出命中处的法向。式 (84) 描述已选命中的几何量。

镜面反射采用单位法向 $\widehat{n}_k$：

$$t_{kj} = \frac{-\Delta j + h_j - o_{k,z} - a_j^{\mathsf{T}}(o_{k,xy} - c_j)}{d_{k,z} + a_j^{\mathsf{T}} d_{k,xy}}. \tag{84}$$

$$P_k = o_k + t_k d_k, \qquad d_{k+1} = d_k - 2(d_k^{\mathsf{T}}\widehat{n}_k)\widehat{n}_k. \tag{85}$$

$$\Omega_i = \{(x, y, z) : z \geq -\Delta i - s\}, \tag{86}$$

下一段从经数值偏移的 P_k 发射，并再次执行原生最近交点查询。路径 $\gamma = (P_0, \ldots, P_L)$ 保存实际的分支、实例和传播顺序，光程为 $\ell_\gamma = \sum_k t_k$。斜入射或多段光路的光程使用各段实际长度；式 (64) 是竖直入射、单次镜面反射和固定局部探测平面的解析特例。

对初始方向 $d_{i,z} > 0$，时间层构造使未来记录处于起点的下方。多段传播将有效场景限制在式 (86)。并在该边界上的探测终点结束。透镜与后续射线采用同一因果域；越过下边界的路径终止，或由前缀实例集合 $\mathcal{S}_i$ 构建相应 RT 场景。这样，任意反射方向都只访问当前及历史出现实例。

H.2 共享可移动透镜

透镜参数 $\Lambda = \{\lambda_a\}_{a=1}^{M_{\text{lens}}}$ 包括共享形状、位置、姿态与折射率。透镜在各查询的局部光学坐标系中复用同一模板；局部时间原点与场景变换将其放入式 (86) 的有效区域。移动透镜通过参数更新改变光路的转向、聚焦、可见实例和探测位置。其交点仍由几何求交场景求得，表面相互作用按反射或折射规律计算。例如单位入射方向 d、朝向入射侧的法向 n、折射率比 η，在 $c = -n^{\mathsf{T}}d \geq 0$ 且 $1 - \eta^2(1 - c^2) \geq 0$ 时有

$$d' = \eta d + \left(\eta c - \sqrt{1 - \eta^2(1 - c^2)}\right) n. \tag{87}$$

全反射区域采用相应反射规则。共享透镜属于模型参数，历史实例属于上下文状态，两者通过输入相关的交点与传播路径共同影响输出。

H.3 独立光路增强与探测汇合

每条有效光路有独立的对数增强 $g_{ik} = \text{softplus}(\rho_{ik}) \geq 0$，对应增强倍数 $G_{ik} = \exp(g_{ik}) \geq 1$。增强参数由当前输入、命中形状与共享增益映射给出；词元原始范数则初始化独立的发射幅度。物理强度采用乘法增强：式 (88)。g_{ik} 的非负约束使独立增强相对于同一传播条件的单位增益基准增加强度。传播和增强直接作用于每条光路的强度，汇合端积累各路信号。若采用非相干强度或分离的探测通道，内容信号为

$$I_{i\gamma} = I_{i\gamma}^{\text{emit}} \exp\left(\sum_{k\in\gamma} g_{ik} - \mu\ell_\gamma\right) \prod_{k\in\gamma} T_{ik}, \qquad T_{ik} \in [0, 1]. \tag{88}$$

$$z_i = \sum_{\gamma\in\Gamma_i} I_{i\gamma}\, \Phi_\theta(\gamma, \mathcal{S}_i). \tag{89}$$

参考通道可同时保存总强度 $R_i = \sum_\gamma I_{i\gamma}$。共同数值标定用于控制动态范围；在 $R_i > 0$ 时，内

容读出定义为 z_i/R_i，内容和参考通道共有的强度因子在这一比值中约去。

当额外增益存在时，光程可由显式飞行时间或经增益标定的传播参考恢复；基准强度可解码命题使用其已给出的单位增益条件。几何坐标中的长度尺度变换、单路强度增强和输出比值读出分别承担不同作用。

I 光路承载内容与并行计算

I.1 几何内容的表达自由度

设历史实例的完整几何表示为 $G_j \in \mathbb{R}^p$，它可以包含多个曲面控制点、局部法向场、出现变换和光学响应参数。共享内容探测器给出

$$\Phi_\theta(G_j,\gamma_{ij}) = \mathcal{R}_\theta\big(\Psi_1(G_j,\gamma_{ij}),\dots,\Psi_Q(G_j,\gamma_{ij})\big) \in \mathbb{R}^{d_v}. \tag{90}$$

历史内容保存于几何与光路状态中，$\mathcal{R}_\theta$ 是共享模型参数。该假设性结构采用几何缓存，逐条历史的值信息由 G_j 与其可观测路径承载。连续恢复一般 d_v 维值向量要求足够的几何自由度和可辨识探测量；例如对开集上的连续单射编码，至少需要 $p \ge d_v$。有限词表的唯一离散地址只要求式 (48)，而上下文内容的连续恢复还要求式 (90) 具有相应容量。前文七参数单面镜给出受约束的解析响应族；多曲面、控制点与多条独立光路提供更丰富的几何内容表示。

I.2 共享 Fourier 投影的分解

对前文三坐标探测模板，设 $W_O \in \mathbb{R}^{m\times D}$，第 k 对频率为 $\omega_k = 2\pi f_k$，轴编号为 d_k。共享输出投影可精确分解为三个一维向量场：

$$\mathcal{F}_a(u) = \sum_{k:d_k=a} \left[W_{O,:,2k}\sin(\omega_k u) + W_{O,:,2k+1}\cos(\omega_k u)\right], \tag{91}$$

$$W_O z_i = I_i \sum_{a=0}^{2} \mathcal{F}_a(u_{i,a}). \tag{92}$$

向量场值直接位于 m 维输出空间。固定模型参数时，可对各场预采样并插值，误差由表格精度与采样间隔度量。这种分解保留原 Fourier 投影的数学表达；输出维数与实例所携带的独立几何自由度分别由探测接口和内容编码决定。

J 纯光路前馈变换

J.1 线性透射与平衡探测

将平衡探测扩展到任意有限矩阵 $W \in \mathbb{R}^{n\times m}$。取 $M > 0$ 且 $M \ge \max_{r,i}|W_{ri}|$，几何表面保存符号与透射系数 $T_{ri} = |W_{ri}|/M$。输入 x_i 以发射强度 $E_i = M|x_i|$ 进入固定光路。对第 r 个探测器，符号路由给出

$$I^+_{ri} = E_i T_{ri} \mathbf{1}_{\{W_{ri}x_i>0\}}, \tag{93}$$

$$I^-_{ri} = E_i T_{ri} \mathbf{1}_{\{W_{ri}x_i<0\}}, \tag{94}$$

$$\mathcal{O}_W(x)_r = \sum_i I^+_{ri} - \sum_i I^-_{ri}. \tag{95}$$

所有物理强度均非负，输入幅度以 M 增强，有符号结果由探测端的正负通道差形成。表面测量与输入强度分别承载固定参数与当前输入。在理想传输模型中，固定表面的求交与反射关系可作为共享传输系数；后续前向改变发射强度，并复用同一组测量。

命题 9 (平衡光路的线性等价)**.** *在精确透射与线性探测条件下，* $\mathcal{O}_W(x) = Wx$。

证明. 每一对通道满足 $I_{ri}^{+} - I_{ri}^{-} = \operatorname{sgn}(W_{ri}x_i)|W_{ri}x_i| = W_{ri}x_i$。沿输入通道求和即得式 (95) 的结论。 □

J.2 Sigmoid 透射与门控耦合

令门控及升维探测信号分别为 $g = \mathcal{O}_{W_g}(x)$、$u = \mathcal{O}_{W_u}(x)$。门控信号控制非线性透射 $T_\sigma(g_r) = \sigma(g_r) = 1/(1+\exp(-g_r))$。两路幅度耦合形成

$$A_r = |g_r|\,|u_r|\,T_\sigma(g_r), \tag{96}$$

$$a_r = \operatorname{sgn}(g_r)\operatorname{sgn}(u_r)A_r, \tag{97}$$

$$\mathcal{M}_{\mathrm{RT}}(x) = \mathcal{O}_{W_d}(a). \tag{98}$$

$$\mathcal{M}_{\mathrm{RT}}(x) = W_d\big[\mathrm{SiLU}(W_g x) \odot (W_u x)\big].$$

幅度耦合与透射由探测响应定义，降维端继续使用同一平衡探测算子。

命题 10 (纯光路 SwiGLU 等价)**.** *式 (98) 满足 同组末行的 SwiGLU 等价式。*

证明. 由符号与幅度的乘积，$a_r = g_r u_r \sigma(g_r) = \mathrm{SiLU}(g_r)u_r$，再应用平衡光路线性等价命题即得结论。 □

参考文献

[1] A. Vaswani et al. Attention Is All You Need. NeurIPS, 2017. https://arxiv.org/abs/1706.03762.

[2] J. Ainslie et al. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints. EMNLP, 2023. https://arxiv.org/abs/2305.13245.

[3] T. Dao, D. Fu, S. Ermon, A. Rudra, C. Ré. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. NeurIPS, 2022. https://arxiv.org/abs/2205.14135.

[4] T. Dao. FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning. ICLR, 2024. https://arxiv.org/abs/2307.08691.

[5] W. Kwon et al. Efficient Memory Management for Large Language Model Serving with PagedAttention. SOSP, 2023. https://arxiv.org/abs/2309.06180.

[6] N. Shazeer. GLU Variants Improve Transformer. 2020. https://arxiv.org/abs/2002.05202.

[7] W. Kahan. Pracniques: Further Remarks on Reducing Truncation Errors. Communications of the ACM, 8(1):40, 1965. https://doi.org/10.1145/363707.363723.

[8] D. Goldberg. What Every Computer Scientist Should Know About Floating-Point Arithmetic. ACM Computing Surveys, 23(1):5–48, 1991. https://doi.org/10.1145/103162.103163.

[9] I. Wald. On Fast Construction of SAH-Based Bounding Volume Hierarchies. IEEE Symposium on Interactive Ray Tracing, 2007. https://doi.org/10.1109/RT.2007.4342597.

[10] Khronos Group. Vulkan Specification, ray query and acceleration structure chapters. https://registry.khronos.org/vulkan/specs/latest/html/vkspec.html. Accessed 2026-11-12.

[11] Y. Shen et al. Deep Learning with Coherent Nanophotonic Circuits. Nature Photonics, 11:441–446, 2017. https://doi.org/10.1038/nphoton.2017.93.

[12] X. Lin et al. All-Optical Machine Learning Using Diffractive Deep Neural Networks. Science, 361(6406):1004–1008, 2018. https://doi.org/10.1126/science.aat8084.