Ray Tracing Attention：词表角度、因果几何与光路计算

摘要

Ray Tracing Attention（RTA）将高维状态拆分为完整坐标块，以各块的局部角度与幅度形成光路，以历史出现实例保存上下文，由原生光线追踪的交点、遮挡和路径形成读取信号。LM Head 按同一坐标分块编译，保留词元身份、原始量化系数与各包的幅度。当前输入通过编译后的发射映射形成查询，固定传输系数、共享透镜与光路增强共同形成探测信号。历史内容由表面形状、路径状态和探测响应承载，模型采用几何状态缓存。本文给出因果几何、单路径解析式、并行传播、共享内容读出与路径缓存的统一定义，并给出内容信号与参考信号比值实现完整 softmax 注意力的充分条件。分块拼接与逆变换在各层恢复完整高维状态，固定权重与完整块贡献共同保持原模型算子。

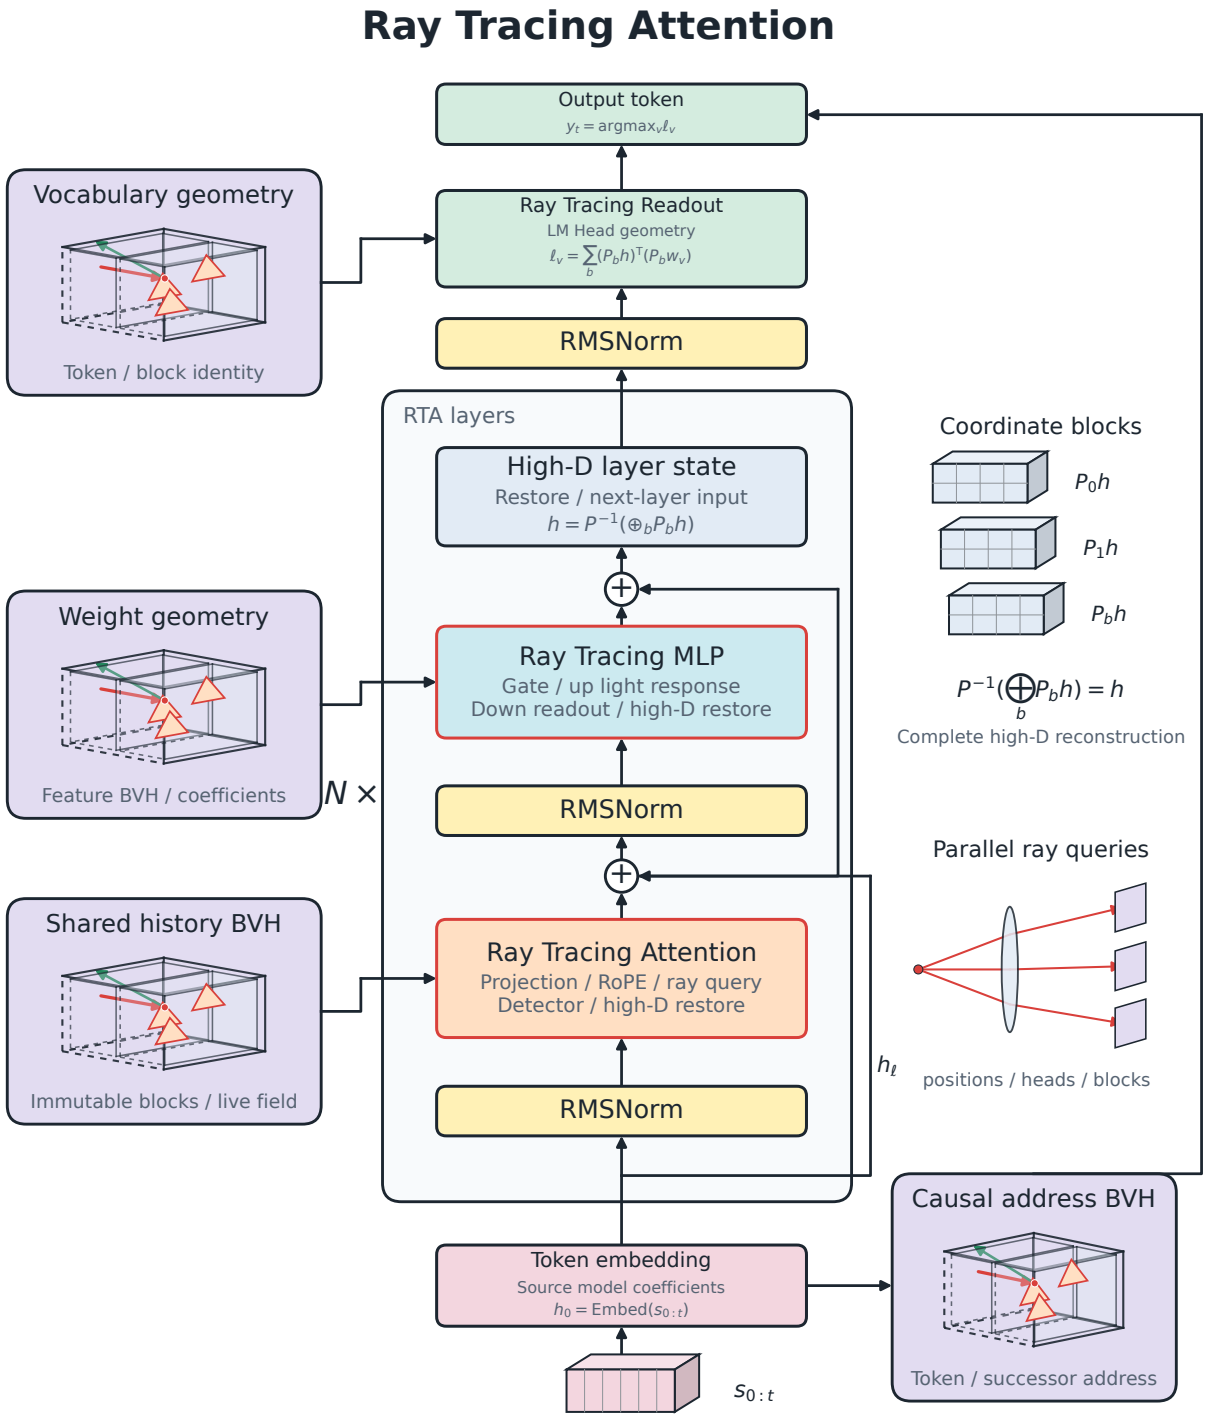


图 1: Ray Tracing Attention 总体算子结构。词元嵌入经过重复 N 层的归一化、Attention、MLP、残差汇合和高维恢复，再由词表光学读出确定输出词元。几何权重与上下文以立体 BVH 表示，坐标分块和并行光线以张量及空间光路表示；各层沿恢复后的完整高维状态连接。

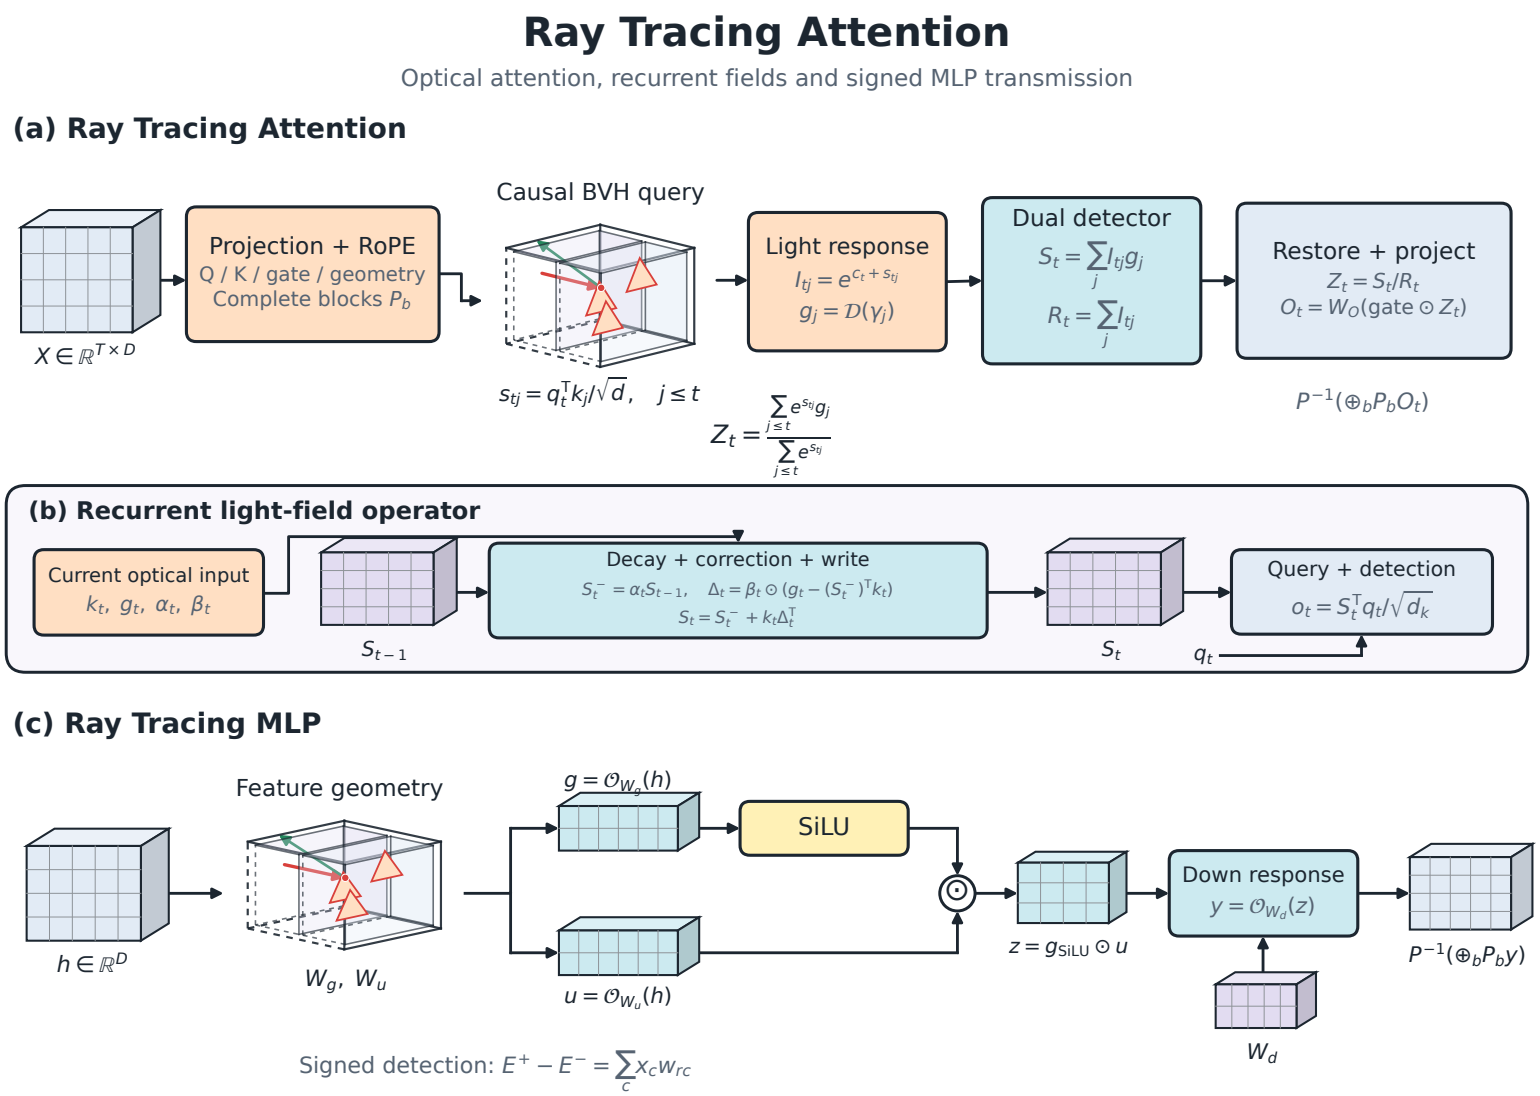


图 2: Attention、递推光场与 MLP 算子。完整注意力由因果几何查询、增强光强、内容与参考探测、比值读出及输出投影组成。递推光场由衰减、校正差和外积写入更新。MLP 将 gate/up 光学响应经 SiLU 与逐分量相乘连接到 down 传输，有符号探测恢复原乘加。

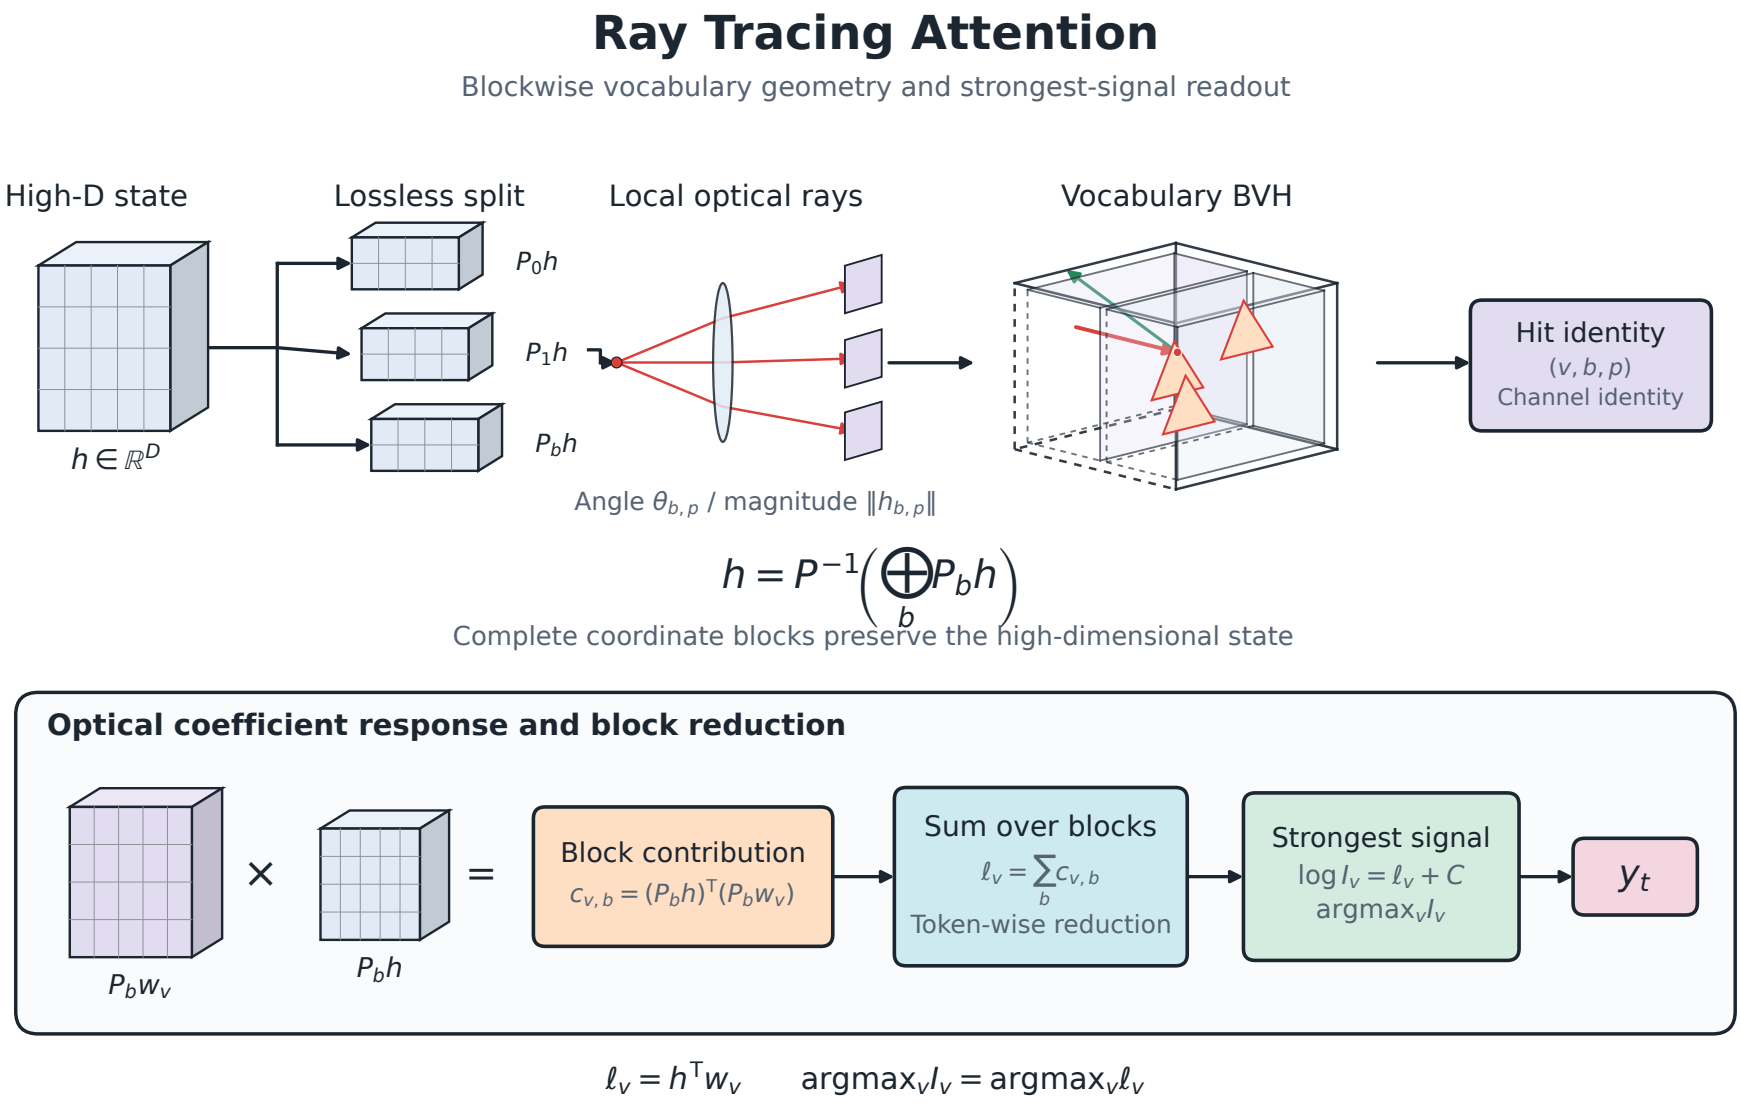


图 3: 分块词表几何与光学读出算子。完整高维状态分为保持通道身份的坐标块，局部角度与幅度形成光线，词表 BVH 求交给出词元、块和包身份。光学系数响应按词元汇合完整块贡献，恢复 LM Head 分数，并以增强光强的最大信号确定输出。

1 整体定义

图 1 展示整体信息流：并行光线查询在层内汇合，各层以恢复后的高维状态相连。图 2 展开 Attention、递推光场和 MLP 的数学算子；图 3 展开完整分块词表几何、光学系数响应和最大信号选词。

设输入词元为 $s_0, \dots, s_{N-1} \in \mathcal{W}$，词表大小为 $V = |\mathcal{W}|$，位置从 0 开始编号。$x_i \in \mathbb{R}^m$ 表示当前输入状态，h_i^{ctx} 表示从已有 RT 光路读取的上下文状态。共享词元参数给出基础方向与模板几何；几何写入器 $\mathcal{G}_\theta$ 把本次出现的内容、位置和上下文写入独立表面实例 S_i。发射器 $\mathcal{E}_\theta$ 围绕词元基础方向产生当前射线。模型在一个 token 上的完整读取为

$$\boxed{x_i \;\longmapsto\; (o_i, d_i) \;\longmapsto\; P_i \in S_{j_i^*} \;\longmapsto\; \gamma_i \;\longmapsto\; z_i = \mathcal{D}(\gamma_i) \;\longmapsto\; y_i.} \tag{1}$$

其中 P_i 是最近可见交点，γ_i 是从发射器经命中表面返回探测器的光路，$\mathcal{D}$ 是全体记录共享的探测规则。每个 token 对应一个入射查询，光路中的传播状态承载后续读出。

符号	含义
$g_j,\ S_j$	第 j 条记录的几何参数与表面
$q_i,\ o_i,\ d$	平面发射位置、三维起点与单位入射方向
$j_i^*,\ P_i,\ \lambda_i$	命中记录、交点与入口传播距离
$r_i,\ F_i,\ \ell_i$	出射方向、探测器相对落点与完整光程
$\Phi_D,\ z_i$	D 通道共享探测映射及其响应
$\theta_{v,b,p},\ n_{v,b,p}$	词元 v 在块 b、包 p 中的局部角度与幅度
$P_b,\ P^{-1}$	完整坐标选择器与拼接后的高维逆变换
$h_i^{\mathrm{ctx}},\ \mathcal{S}_i$	RT 上下文读出及截至位置 i 的几何实例状态

状态的顺序更新写为

$$g_i = \mathcal{G}_\theta(s_i, x_i, h_i^{\mathrm{ctx}}), \qquad \mathcal{S}_i = \mathcal{S}_{i-1} \cup \{S(g_i, i)\}. \tag{2}$$

写入器规定内容在空间中的形状，发射器规定读取地址，传播规律规定命中内容怎样形成探测信号。式 (1) 描述一条基本光路；多分支与多段光路在后文沿同一接口组合。历史状态由几何实例、时序身份和光路状态构成，内容读取采用共享几何探测映射。

2 分块词表几何与共享码本

2.1 可逆坐标分块与高维恢复

设当前层状态为 $h \in \mathbb{R}^m$。编译器定义可逆坐标变换 P，按不重叠、无遗漏的选择器 E_b 取出分块 $P_b = E_b P$。将所有块按编译顺序直接拼接，即得到

$$\widetilde{h} = Ph = \bigoplus_{b=0}^{B_P-1} P_b h, \qquad \boxed{h = P^{-1}\left(\bigoplus_b P_b h\right)}. \tag{3}$$

当前实现采用原始坐标顺序的完整选择器，一个计算块包含 256 个坐标，并进一步分成 128 个双坐标光路包。分块数为 $B_P = m/256$；块索引、包索引和块内坐标共同确定原始通道。各包以原始有限数值的位模式保存，拼接恢复包括符号、指数、有效位与有符号零。几何角度、幅度和固定响应由对应包形成，完整包载荷承载高维信息。

对任意可逆 P，输出头同步变换为 $\widetilde{W}_{\mathrm{LM}} = W_{\mathrm{LM}}P^{-1}$。对当前完整坐标选择器或坐标置换，有 $\sum_b P_b^{\mathsf{T}} P_b = I$，因此

$$h^{\mathsf{T}} w_v = \sum_b (P_b h)^{\mathsf{T}} (P_b w_v). \tag{4}$$

每层光路分别读取对应块，探测结果按块与通道身份写回，由式 (3) 恢复当前层的完整高维状态，再进入下一层。词表输出端对同一词元汇合各块贡献，随后确定最大信号的词元。

2.2 LM Head 的分块方向与尺度

设原模型的无偏置输出头为 $W_{\mathrm{LM}} \in \mathbb{R}^{V\times m}$，第 v 行为 w_v^{T}。记块内第 p 个双坐标包为 $h_{b,p}$ 与 $w_{v,b,p}$，定义局部幅度 $n_{v,b,p} = \|w_{v,b,p}\|$。完整词表分数满足

$$\ell_v = h^{\mathsf{T}} w_v = \sum_{b,p} \|h_{b,p}\|\, n_{v,b,p} \cos\angle(h_{b,p}, w_{v,b,p}), \qquad \|w_v\|^2 = \sum_{b,p} n_{v,b,p}^2. \tag{5}$$

角度由各个双坐标包产生，幅度保留该包的分数尺度。零幅度包贡献为零，并保留其词元与坐标身份。

导出时按原始词表顺序读取全部 V 行，保留原始量化块、系数位模式和词元身份。编译资产记录每个 256 坐标块的起始通道、长度与双坐标包索引。模型前向时由对应块的当前数值形成局部几何，固定参数下复用首次前向得到的几何实例与共享响应测量。输入嵌入与输出头共享权重时复用同一份固定载荷。

2.3 局部光学坐标与复合身份

对一个固定双坐标包 $\xi_{v,b,p}$，局部光学坐标记为 $t_{v,b,p} \in \mathbb{R}^2$。方向由同一半球坐标图形成：

$$d_{v,b,p} = \frac{(t_{v,b,p,1}, t_{v,b,p,2}, 1)}{\sqrt{1 + \|t_{v,b,p}\|^2}}, \qquad \theta_{v,b,p} = \left(\operatorname{atan2}(t_{v,b,p,2}, t_{v,b,p,1}), \arctan\|t_{v,b,p}\|\right). \tag{6}$$

取 $\|t_{v,b,p}\| \le \tan\beta_{\max}$、$\beta_{\max} < \pi/2$。原始包与幅度同时保存，局部坐标图由包的数值生成。后文描述固定块中的单条光路时，省略 b, p 下标。

块实例以复合身份寻址：

$$\mathrm{Address}(v,b,p) = (v,b,p), \qquad (v,b,p) \neq (u,c,r) \Longrightarrow \mathrm{Address}(v,b,p) \neq \mathrm{Address}(u,c,r). \tag{7}$$

相同局部方向可以复用同一基础图元，词元 ID、分块 ID 与包索引保持独立。原生图元 ID 确定块域与词元，固定系数块与双坐标包确定其完整通道载荷。命中回执按块分别保存，并按词元身份汇合探测信号。

2.4 稳定基础方向与上下文修正

在读取位置 i，首先用词元基础射线从历史场景 $\mathcal{S}_{i-1}$ 得到上下文：

$$\gamma_i^{\mathrm{ctx}} = \mathrm{TraceRT}(\mathcal{S}_{i-1}, s_i, \theta_{s_i}), \qquad h_i^{\mathrm{ctx}} = \mathcal{D}_{\mathrm{ctx}}(\gamma_i^{\mathrm{ctx}}). \tag{8}$$

再在 d_{s_i} 的切平面中给出小幅修正。令 $T_v \in \mathbb{R}^{3\times 2}$ 的列为该切平面的正交基，则

$$\epsilon_i = \epsilon_{\max} \tanh \mathcal{A}_\theta(x_i, h_i^{\mathrm{ctx}}, \theta_{s_i}), \qquad d_i = \frac{d_{s_i} + T_{s_i}\epsilon_i}{\|d_{s_i} + T_{s_i}\epsilon_i\|}. \tag{9}$$

因为 $d_{s_i}^{\mathsf{T}} T_{s_i} = 0$，方向改变量满足 $\angle(d_i, d_{s_i}) = \arctan\|\epsilon_i\|$。取 $\beta_{\max} + \arctan(\sqrt{2}\epsilon_{\max}) < \pi/2$ 保持因果方向，由 $\|\epsilon_i\| \le \sqrt{2}\epsilon_{\max}$ 控制局部范围，保持词元基础方向稳定，同时让当前语境改变有效寻址。

同一词元的多次出现共用 θ_v 和基础模板，每次出现分别保存位置 j、上下文形状 g_j 和时序身份。例如同一主体的较新事实可以写入本次上下文光路覆盖的地址域，查询的角度修正与原生最近命中共同定位当前有效记录。这种更新保留词元基础身份，并以历史实例之间的光路关系表达事实变化。

3 几何记忆与因果时间轴

3.1 有限镜面的参数化

基本记录采用七个几何参数：

$$g_j = (c_{jx}, c_{jy}, a_{jx}, a_{jy}, h_j, r_{jx}, r_{jy}). \tag{10}$$

$c_j \in \mathbb{R}^2$ 是镜面中心，$a_j \in \mathbb{R}^2$ 决定倾角，h_j 是相对高度，$r_j \in \mathbb{R}^2_{>0}$ 是半孔径。记平面坐标 $\xi = (x, y)$，镜面定义为

$$S_j: \quad z = -\Delta j + h_j - a_j^{\mathsf{T}}(\xi - c_j), \qquad |\xi - c_j| \le r_j. \tag{11}$$

不等式按坐标分别成立。镜面朝 $-z$ 一侧反射，另一侧透射。

一组具体的有界写入映射为

$$w_j = W_G \,\mathrm{Norm}(x_j) + b_G \in \mathbb{R}^7, \tag{12}$$

$$c_j = \tanh(w_{j,1:2}), \qquad a_j = A\tanh(w_{j,3:4}), \tag{13}$$

$$h_j = H\tanh(w_{j,5}), \qquad r_j = r_{\min} + (r_{\max} - r_{\min})\sigma(w_{j,6:7}), \tag{14}$$

取

$$A = H = \frac{1}{4}, \qquad r_{\min} = \frac{1}{40}, \qquad r_{\max} = \frac{1}{2}, \qquad \Delta = 4. \tag{15}$$

中心与孔径决定可访问区域，倾角决定反射方向，高度决定传播距离。这些量共同定义同一块几何记忆。

3.2 竖直射线的解析坐标模板

为得到可直接验证的闭式光路，先采用竖直入射的局部模板。发射器将当前输入映射到二维平面地址：

$$q_i = \tanh\big(W_E \,\mathrm{Norm}(x_i) + b_E\big) \in (-1, 1)^2. \tag{16}$$

令发射器位于当前时间层的下方，固定间距 $s = 2$：

$$o_i = (q_{ix}, q_{iy}, -\Delta i - s), \qquad d = (0, 0, 1), \qquad \rho_i(t) = o_i + td, \quad t > 0. \tag{17}$$

二维地址承担这一模板的语义寻址，纵向坐标承担顺序与因果关系。一般角度射线沿式 (6)–(9) 发射，其求交与传播在后文定义。

3.3 因果性的几何构造

令镜面相对于时间层的最大高度幅度为

$$B_z = H + 2Ar_{\max} = \frac{1}{2}.$$

于是每个表面都满足

$$-\Delta j - B_z \le z(S_j) \le -\Delta j + B_z. \tag{18}$$

命题 1 (因果可见性)**.** 当 $B_z < s < \Delta - B_z$ 时，查询 i 的全部历史镜面位于入射方向前方，全部未来镜面位于起点后方。

证明. 对 $j \le i$，镜面的最低点与起点之间的纵向距离至少为

$$\Delta(i-j) + s - B_z \ge s - B_z > 0.$$

对 $j \ge i+1$，镜面的最高点与起点之间的距离至多为

$$\Delta(i-j) + s + B_z \le -\Delta + s + B_z < 0.$$

式 (15) 取值下，两侧各有 1.5 的严格间隔。 □

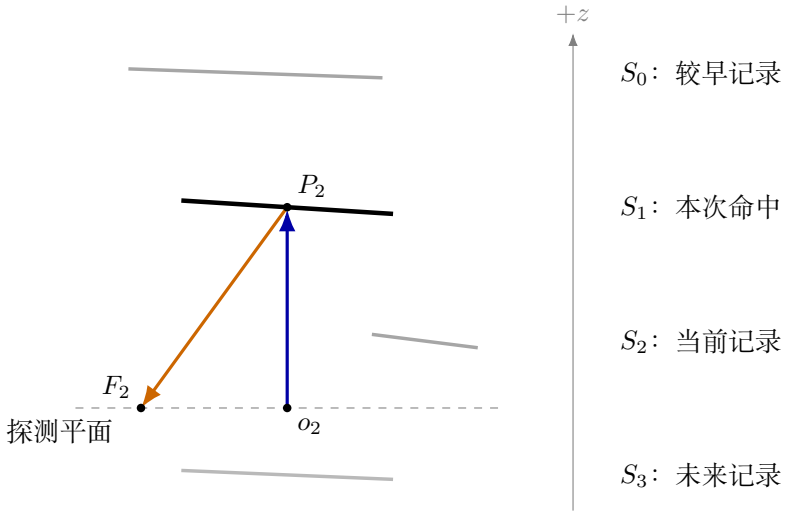


图 4: 时间层与单条光路的截面示意。查询地址穿过当前镜面的孔径之外，在较早镜面上反射；未来记录位于发射器后方。

3.4　空间地址上的最近写入

记孔径区域

$$\mathcal{A}_j = \{\xi : |\xi - c_j| \le r_j\}.$$

当 $q_i \in \mathcal{A}_j$ 时，入口距离由平面方程直接给出：

$$\lambda_{ij} = \Delta(i-j) + s + h_j - a_j^{\top}(q_i - c_j). \tag{19}$$

设可访问记录集合为

$$\mathcal{V}_i(q_i) = \{j \le i : q_i \in \mathcal{A}_j\}.$$

读取索引为

$$j_i^{*} = \arg\min_{j \in \mathcal{V}_i(q_i)} \lambda_{ij}. \tag{20}$$

集合为空时，以 $\perp$ 表示空路径，并令其探测响应为零。

由于相邻时间层的间隔 Δ 大于 $2B_z$，式 (20) 等价于

$$j_i^* = \max \mathcal{V}_i(q_i). \tag{21}$$

这是一种带空间地址的覆盖式记忆：同一地址由最近覆盖它的表面响应，不同孔径区域保存各自的可见历史。

对于固定查询时刻 i，记录 j 的可见地址域为

$$\mathcal{D}_{ij} = \mathcal{A}_j \setminus \bigcup_{j<k\le i} \mathcal{A}_k. \tag{22}$$

这些区域将发射平面划分为由不同记录响应的部分。BVH 将该几何集合组织为空间层次，按照射线与包围区域的相交关系完成定位，最近交点直接确定读取路径。式 (20) 和式 (22) 定义几何语义；运行时的候选、交点与遮挡由原生 RT Core/BVH 求得。

4 单路径反射与完整光程

4.1 命中点与出射方向

记本次命中参数为 $a = a_{j_i^*}$、$\lambda = \lambda_{ij_i^*}$。在发射器局部坐标系中，入射点为原点，命中点为

$$P = (0, 0, \lambda).$$

取 $n = (a_x, a_y, 1)$。反射方向由

$$r = d - 2\frac{n^{\mathsf{T}} d}{n^{\mathsf{T}} n} n = \left(-\frac{2a}{1 + \|a\|^2}, \frac{\|a\|^2 - 1}{1 + \|a\|^2} \right) \tag{23}$$

给出，且 $\|r\| = 1$。参数域 (15) 保证 $\|a\|^2 \le 1/8$，所以 $r_z < 0$。射线沿同一条反射路径返回探测平面。

4.2 固定局部探测平面

探测器固定在发射器局部坐标系的 $z = 0$ 平面，其全局位置随时间原点平移。令返回距离为 η，则

$$\lambda + \eta r_z = 0, \qquad \eta = \lambda \frac{1 + \|a\|^2}{1 - \|a\|^2}.$$

相对发射位置的落点及往返光程为

$$\boxed{F_{xy} = -\frac{2\lambda a}{1 - \|a\|^2}, \qquad \ell = \lambda + \eta = \frac{2\lambda}{1 - \|a\|^2}.} \tag{24}$$

因而 $F_{xy} = -\ell a$。倾角写入探测器落点，高度与记录距离写入飞行时间，两者由同一次几何命中联合读出。

4.3 回程的几何可达性

命题 2 (单面镜的直接回程)**.** 设场景内任意镜面倾角 a, b 均满足各坐标绝对值不超过 $1/4$。由倾角 a 产生的反射方向，在其他镜面上均从透射侧通过。

证明. 用 $\tilde{n}_b = (b_x, b_y, 1)$ 表示另一镜面的法向。根据式 (23)，

$$\tilde{n}_b^{\mathsf{T}} r = \frac{\|a\|^2 - 1 - 2b^{\mathsf{T}} a}{1 + \|a\|^2} \le \frac{-5/8}{1 + \|a\|^2} < 0.$$

其他镜面的反射正面朝 $-\tilde{n}_b$，因此回程与其外向反射法向的内积为正，对应背面透射。整条返回光路由式 (24) 确定。 □

4.4 传播能量

在均匀介质中，采用光程衰减系数 $\mu > 0$，单位发射与单位表面增益的基准强度为

$$E_i = \exp(-\mu \ell_i). \tag{25}$$

一个具体取值为 $\mu = 1/4096$。这使路径长度同时表现为时间观测和强度观测。发射、表面相互作用与探测共同构成一次完整的有向几何读取。路径增强在这一传播因子上乘以独立增益。

5 共享探测器与多通道编码

5.1 路径观测

定义归一化光路观测

$$u_i = \left(\frac{F_{ix}}{1+\ell_i}, \frac{F_{iy}}{1+\ell_i}, \log_2(1+\ell_i) \right) \in \mathbb{R}^3. \tag{26}$$

前两项描述落点，第三项描述飞行距离的对数尺度。探测器采用对所有记录共享的基函数 $b_k(u)$，产生

$$z_{i,k} = E_i b_k(u_i).$$

输出宽度由探测模式的数量确定，每个模式观测同一条入射与反射光路。

5.2 一组具体的 Fourier 探测模式

令输出维数 $D \geq 4$ 为偶数，模式编号 $k = 0, \ldots, D/2 - 1$。取

$$d_k = k \bmod 3, \qquad f_k = \frac{\lfloor k/3 \rfloor + 1}{4}.$$

完整响应定义为

$$z_{i,2k} = E_i \sin(2\pi f_k u_{i,d_k}), \tag{27}$$

$$z_{i,2k+1} = E_i \cos(2\pi f_k u_{i,d_k}). \tag{28}$$

$D = 256$ 对应 128 对正弦与余弦响应。较低频率描述光路的整体变化，较高频率提供更细的响应结构。共享线性输出投影将这些模式组合为模型的残差分支信号。

命题 3 (基准强度下的光路可解码性)**.** 对 $\ell > 0$、$\mu > 0$，采用式 (25) 的已标定基准强度时，式 (28) 的前两个空间模式及其共同强度可以恢复 ℓ 与 F_{xy}。

证明. 由第一对响应恢复强度：

$$E = \sqrt{z_0^2 + z_1^2}, \qquad \ell = -\frac{1}{\mu} \log E.$$

对任意单位方向传播到探测平面的光路，$|F_x|, |F_y| \leq \ell$，所以 $|u_x|, |u_y| < 1$。第一组空间频率为 $1/4$，相位落在 $(-\pi/2, \pi/2)$ 内，故

$$u_x = \frac{2}{\pi} \operatorname{atan2}(z_0, z_1), \qquad u_y = \frac{2}{\pi} \operatorname{atan2}(z_2, z_3), \qquad F_{xy} = (1+\ell)(u_x, u_y).$$

在镜面模板下，进一步由 $a = -F_{xy}/\ell$ 与 $\lambda = \ell(1 - \|a\|^2)/2$ 恢复命中倾角和入口距离。 □

这个构造把形状响应、传播距离与有符号输出连接起来。能量控制共同幅度，探测基函数提供各输出通道的空间与时间响应。

5.3 平衡探测的有符号读出

对任一探测模式 $b_c(u) \in [-1,1]$，将对应份额的光强分配到正、负两支：

$$I_c^+ = \frac{E}{2D}\big(1 + b_c(u)\big), \qquad I_c^- = \frac{E}{2D}\big(1 - b_c(u)\big). \tag{29}$$

两支均为非负强度，全部通道的强度总和为 E。统一标定后的平衡差给出

$$z_c = D(I_c^+ - I_c^-) = E\, b_c(u). \tag{30}$$

空间与飞行时间决定共享模板的透射比例，平衡差形成模型使用的有符号特征。

6 曲面几何的统一表达

6.1 从平面到形状场

几何记忆还可以表示为有限孔径上的高度场：

$$S_j: \quad z = -\Delta j + H_j(\xi), \qquad \xi \in \mathcal{A}_j. \tag{31}$$

约束取为

$$|H_j(\xi)| \le B_z, \qquad |\partial_x H_j(\xi)|,\ |\partial_y H_j(\xi)| \le A. \tag{32}$$

这些条件保持时间层的因果间隔和反射法向的角度范围。

一条竖直射线在其查询地址处读取

$$\lambda_{ij} = \Delta(i-j) + s + H_j(q_i), \qquad a_{ij} = -\nabla H_j(q_i). \tag{33}$$

将它们代入式 (24)，即可得到同一探测规则下的光路。曲面在不同地址提供不同的高度与法向响应，从而将一条历史记录表示为可被查询位置采样的几何函数。

6.2 控制点写入

例如，采用次数为 (p,q) 的张量积 Bézier 高度场。在孔径内定义局部坐标

$$s_x = \frac{\xi_x - c_{jx} + r_{jx}}{2r_{jx}}, \qquad s_y = \frac{\xi_y - c_{jy} + r_{jy}}{2r_{jy}}.$$

令 $B_a^p(s) = \binom{p}{a} s^a (1-s)^{p-a}$，写入

$$H_j(\xi) = \sum_{a=0}^{p}\sum_{b=0}^{q} \beta_{j,ab} B_a^p(s_x) B_b^q(s_y). \tag{34}$$

控制系数 $\beta_{j,ab}$ 是曲面的形状坐标。Bernstein 基函数的非负性和分割统一性给出

$$|H_j| \le \max_{a,b} |\beta_{j,ab}|.$$

同时，

$$|\partial_x H_j| \le \frac{p}{2r_{jx}} \max_{a,b} |\beta_{j,a+1,b} - \beta_{j,ab}|, \tag{35}$$

$$|\partial_y H_j| \le \frac{q}{2r_{jy}} \max_{a,b} |\beta_{j,a,b+1} - \beta_{j,ab}|. \tag{36}$$

因此，控制点的幅度与相邻差分约束直接实现式 (32)。平面、分片平面和光滑曲面由此共享同一套时间轴、入口查询与探测定义。几何表示的细节通过命中位置处的高度和局部法向进入读出。

7 发射模板与单路径软读取

7.1 发射位置的概率模板

令 $p_i(q)$ 为查询 i 在发射平面上的概率密度。它描述语义地址附近的入射分布。一次读取从该模板取一个位置：

$$q_i \sim p_i(q), \qquad \rho_i(t) = (q_i, -\Delta i - s) + td.$$

记录 j 被读取的概率为

$$\alpha_{ij} = \int_{\mathcal{D}_{ij}} p_i(q)\,\mathrm{d}q. \tag{37}$$

设 $\mathcal{D}_{i\perp}$ 为孔径并集之外的区域，则

$$\sum_{j\le i} \alpha_{ij} + \alpha_{i\perp} = 1.$$

在概率意义下，探测响应的完整期望为

$$\overline{z}_i = \sum_{j\le i} \int_{\mathcal{D}_{ij}} p_i(q)\, e^{-\mu \ell_{ij}(q)} \Phi_D\big(u_{ij}(q)\big)\,\mathrm{d}q. \tag{38}$$

这里 Φ_D 表示式 (28) 中的单位幅度模式。一次采样产生一个 z_i，其期望正是式 (38)。可见区域的概率质量决定记录的参与程度，光路决定具体的信号内容。

一种带有限束宽的发射模板为

$$\eta_i \sim \mathcal{N}(m_i, \Sigma_i), \qquad q_i = \tanh \eta_i, \qquad (m_i, \Sigma_i) = \mathcal{E}_\theta(x_i). \tag{39}$$

例如可取 $\Sigma_i = \mathrm{diag}(\mathrm{softplus}(s_i)^2)$，其中 s_i 由发射器同时给出。中心 m_i 给出查询地址，协方差 Σ_i 给出射线束的空间范围。将分布集中到中心位置，得到确定性的中心射线读取。

7.2 单次方向采样的漫反射模板

在命中点处，可围绕镜面方向 r 规定一个半角为 Θ 的散射锥。令 (t_1, t_2, r) 为正交标架，出射方向写为

$$\omega = \cos\theta\, r + \sin\theta(\cos\phi\, t_1 + \sin\phi\, t_2). \tag{40}$$

相对于立体角 $\mathrm{d}\omega = \sin\theta\,\mathrm{d}\theta\,\mathrm{d}\phi$，归一化余弦模板为

$$p_\Theta(\theta, \phi) = \frac{\cos\theta}{\pi \sin^2\Theta} \mathbf{1}_{\{0\le\theta\le\Theta\}}, \quad 0 \le \phi < 2\pi. \tag{41}$$

令 u, v 为两个独立均匀随机数，使用

$$\theta = \arcsin(\sin\Theta\sqrt{u}), \qquad \phi = 2\pi v$$

即可取一个出射方向。$\Theta = 0$ 对应中心镜面方向。

记法向最大偏角为 $\beta = \arctan(\sqrt{2}A)$。取

$$3\beta + \Theta < \frac{\pi}{2}, \tag{42}$$

便保持出射方向朝向探测器，并从场景其他镜面的透射侧通过。例如 $A = 1/4$ 时可取 $\Theta \le \pi/12$。

给定本次采样的 ω，完整返回光路为

$$\eta = \frac{\lambda}{-\omega_z}, \qquad F_{xy} = \eta\omega_{xy}, \qquad \ell = \lambda + \eta. \tag{43}$$

同一条路径在表面上完成一次方向选择，再进入共享探测规则。对发射位置和出射方向同时取期望，式 (38) 的被积项相应增加对散射模板的期望。这把确定性反射和单路径漫反射纳入统一的传播模型。

8 角度光路、共享透镜与独立增强

8.1 一般射线与多段传播

第 k 段射线记为 $\rho_k(t) = o_k + td_k$、$t > 0$、$\|d_k\| = 1$。对式 (11) 的平面表面，候选交点的解析距离为

$$t_{kj} = \frac{-\Delta j + h_j - o_{k,z} - a_j^{\mathsf{T}}(o_{k,xy} - c_j)}{d_{k,z} + a_j^{\mathsf{T}} d_{k,xy}}. \tag{44}$$

分母为零时按平行射线处理，正距离、孔径归属、面朝向及最近遮挡共同确定有效命中。原生 RT 查询返回命中实例 ID、图元 ID、重心坐标与距离，着色计算再取得该命中的局部形状和法向。式 (44) 用于描述或验证已选命中的几何量。

镜面反射采用单位法向 $\widehat{n}_k$：

$$P_k = o_k + t_k d_k, \qquad d_{k+1} = d_k - 2(d_k^{\mathsf{T}}\widehat{n}_k)\widehat{n}_k. \tag{45}$$

下一段从经数值偏移的 P_k 发射，并再次执行原生最近交点查询。路径 $\gamma = (P_0, \ldots, P_L)$ 保存实际的分支、实例和传播顺序，光程为 $\ell_\gamma = \sum_k t_k$。斜入射或多段光路的光程使用各段实际长度；式 (24) 是竖直入射、单次镜面反射和固定局部探测平面的解析特例。

对初始方向 $d_{i,z} > 0$，时间层构造使未来记录处于起点的下方。多段传播将有效场景限制在

$$\Omega_i = \{(x, y, z) : z \geq -\Delta i - s\}, \tag{46}$$

并在该边界上的探测终点结束。透镜与后续射线采用同一因果域；越过下边界的路径终止，或由前缀实例集合 $\mathcal{S}_i$ 构建相应 RT 场景。这样，任意反射方向都只访问当前及历史出现实例。

8.2 共享可移动透镜

透镜参数 $\Lambda = \{\lambda_a\}_{a=1}^{M_{\text{lens}}}$ 包括共享形状、位置、姿态与折射率。透镜在各查询的局部光学坐标系中复用同一模板；局部时间原点与场景变换将其放入式 (46) 的有效区域。移动透镜通过参数更新改变光路的转向、聚焦、可见实例和探测位置。其交点仍由原生 RT 场景求得，表面相互作用按反射或折射规律计算。例如单位入射方向 d、朝向入射侧的法向 n、折射率比 η，在 $c = -n^{\mathsf{T}}d \geq 0$ 且 $1 - \eta^2(1 - c^2) \geq 0$ 时有

$$d' = \eta d + \left(\eta c - \sqrt{1 - \eta^2(1 - c^2)}\right) n. \tag{47}$$

全反射区域采用相应反射规则。共享透镜属于模型参数，历史实例属于上下文状态，两者通过输入相关的交点与传播路径共同影响输出。

8.3 独立光路增强与探测汇合

每条有效光路有独立的对数增强 $g_{ik} = \text{softplus}(\rho_{ik}) \geq 0$，对应增强倍数 $G_{ik} = \exp(g_{ik}) \geq 1$。增强参数由当前输入、命中形状与共享增益映射给出；词元原始范数则初始化独立的发射幅度。物理

强度采用乘法增强：

$$I_{i\gamma} = I_{i\gamma}^{\mathrm{emit}} \exp\left(\sum_{k\in\gamma} g_{ik} - \mu\ell_\gamma\right) \prod_{k\in\gamma} T_{ik}, \qquad T_{ik} \in [0,1]. \tag{48}$$

g_{ik} 的非负约束使独立增强相对于同一传播条件的单位增益基准增加强度。传播和增强直接作用于每条光路的强度，汇合端积累各路信号。若采用非相干强度或分离的探测通道，内容信号为

$$z_i = \sum_{\gamma\in\Gamma_i} I_{i\gamma}\, \Phi_\theta(\gamma, \mathcal{S}_i). \tag{49}$$

参考通道可同时保存总强度 $R_i = \sum_\gamma I_{i\gamma}$。共同数值标定用于控制动态范围；内容与参考的比值读出将在后文单独定义。

当额外增益存在时，光程可由显式飞行时间或经增益标定的传播参考恢复；基准强度可解码命题使用其已给出的单位增益条件。几何坐标中的长度尺度变换、单路强度增强和输出比值读出分别承担不同作用。

9 光路承载内容与并行计算

9.1 几何内容的表达自由度

设历史实例的完整几何表示为 $G_j \in \mathbb{R}^p$，它可以包含多个曲面控制点、局部法向场、出现变换和光学响应参数。共享内容探测器给出

$$\Phi_\theta(G_j, \gamma_{ij}) = \mathcal{R}_\theta\big(\Psi_1(G_j, \gamma_{ij}), \ldots, \Psi_Q(G_j, \gamma_{ij})\big) \in \mathbb{R}^{d_v}. \tag{50}$$

历史内容保存于几何与光路状态中，$\mathcal{R}_\theta$ 是共享模型参数。该结构采用几何缓存，逐条历史的值信息由 G_j 与其可观测路径承载。连续恢复一般 d_v 维值向量要求足够的几何自由度和可辨识探测量；例如对开集上的连续单射编码，至少需要 $p \geq d_v$。有限词表的唯一离散地址只要求式 (7)，而上下文内容的连续恢复还要求式 (50) 具有相应容量。前文七参数单面镜给出受约束的解析响应族；多曲面、控制点与多条独立光路提供更丰富的几何内容表示。

9.2 共享 Fourier 投影的分解

对前文三坐标探测模板，设 $W_O \in \mathbb{R}^{m\times D}$，第 k 对频率为 $\omega_k = 2\pi f_k$，轴编号为 d_k。共享输出投影可精确分解为三个一维向量场：

$$\mathcal{F}_a(u) = \sum_{k:d_k=a} \left[W_{O,:,2k} \sin(\omega_k u) + W_{O,:,2k+1} \cos(\omega_k u)\right], \tag{51}$$

$$W_O z_i = I_i \sum_{a=0}^{2} \mathcal{F}_a(u_{i,a}). \tag{52}$$

向量场值直接位于 m 维输出空间。固定模型参数时，可对各场预采样并插值，误差由表格精度与采样间隔度量。这种分解保留原 Fourier 投影的数学表达；输出维数与实例所携带的独立几何自由度分别由探测接口和内容编码决定。

9.3 并行分支与命中需求

设光学分支数为 B，当前原生配置取 $B = 32$。各分支共用词元身份与基础角度码本，通过自身的场景坐标变换、共享或分支探测参数产生光路。同一位置的 B 个初始查询可以并行发射，多

段路径还可连接分支。记原生命中形成的可用分支集合为 $\mathcal{H}_i$，根据光路增强与任务相关优先级选择 $\mathcal{B}_i \subseteq \mathcal{H}_i$，并令 $|\mathcal{B}_i| \le K$。各个参与分支计算

$$r_{b,i} = x_i + W_{O,b} z_{b,i} + b_{O,b}, \tag{53}$$

$$m_{b,i} = \mathcal{M}_{\mathrm{RT},b}\big(\mathrm{Norm}_b^{\mathrm{post}}(r_{b,i})\big), \tag{54}$$

$$y_i = \begin{cases} |\mathcal{B}_i|^{-1} \displaystyle\sum_{b\in\mathcal{B}_i} (r_{b,i} + m_{b,i}), & |\mathcal{B}_i| > 0, \\ x_i, & |\mathcal{B}_i| = 0. \end{cases} \tag{55}$$

光路强度按式 (48) 增强，分支均值则在输出接口稳定残差尺度。命中队列决定实际执行的内容变换数量。对已确定的输入状态，各分支写入与查询可以同时展开；若出现形状或角度修正依赖式 (8)，前缀计算保留相应的历史依赖。生成时按依赖顺序追加当前实例并读取下一位置。

10 纯光路前馈变换

10.1 线性透射与平衡探测

将平衡探测扩展到任意有限矩阵 $W \in \mathbb{R}^{n\times m}$。取 $M \ge \max_{r,i} |W_{ri}|$，几何表面保存符号与透射系数 $T_{ri} = |W_{ri}|/M$。输入 x_i 以发射强度 $E_i = M|x_i|$ 进入固定光路。对第 r 个探测器，符号路由给出

$$I_{ri}^{+} = E_i T_{ri} \mathbf{1}_{\{W_{ri}x_i>0\}}, \tag{56}$$

$$I_{ri}^{-} = E_i T_{ri} \mathbf{1}_{\{W_{ri}x_i<0\}}, \tag{57}$$

$$\mathcal{O}_W(x)_r = \sum_i I_{ri}^{+} - \sum_i I_{ri}^{-}. \tag{58}$$

所有物理强度均非负，输入幅度以 M 增强，有符号结果由探测端的正负通道差形成。表面测量与输入强度分别承载固定参数与当前输入。固定表面的真实 RT 求交和反射测量可缓存为传输系数；后续前向改变发射强度，并复用同一组测量。

命题 4 (平衡光路的线性等价)**.** 在精确透射与线性探测条件下，$\mathcal{O}_W(x) = Wx$。

证明. 每一对通道满足 $I_{ri}^{+} - I_{ri}^{-} = \mathrm{sgn}(W_{ri}x_i)|W_{ri}x_i| = W_{ri}x_i$。沿输入通道求和即得式 (58) 的结论。 □

10.2 Sigmoid 透射与门控耦合

令门控及升维探测信号分别为 $g = \mathcal{O}_{W_g}(x)$、$u = \mathcal{O}_{W_u}(x)$。门控信号控制非线性透射 $T_\sigma(g_r) = \sigma(g_r) = 1/(1+\exp(-g_r))$。两路幅度耦合形成

$$A_r = |g_r|\,|u_r|\,T_\sigma(g_r), \tag{59}$$

$$a_r = \mathrm{sgn}(g_r)\,\mathrm{sgn}(u_r) A_r, \tag{60}$$

$$\mathcal{M}_{\mathrm{RT}}(x) = \mathcal{O}_{W_d}(a). \tag{61}$$

幅度耦合与透射由计算光路的探测响应定义，原生着色器实现其数值规律。降维端继续使用同一平衡探测算子。

命题 5 (纯光路 SwiGLU 等价)**.** 式 (61) 满足

$$\mathcal{M}_{\mathrm{RT}}(x) = W_d\big[\mathrm{SiLU}(W_g x) \odot (W_u x)\big].$$

证明. 由符号与幅度的乘积，$a_r = g_r u_r \sigma(g_r) = \mathrm{SiLU}(g_r) u_r$，再应用平衡光路线性等价命题即得结论。 □

当前 2B 配置取 $m = 2048$、升维通道数 6144、$M = 32$。24 层分别保留原模型的门控、升维和降维参数，以几何索引与首次真实 RT 测量连接固定光路，前向经非负强度归约、符号差和门控耦合完成计算。全部 24 层与原始 BF16 参数的 FP32 SwiGLU 对照中，最大输出绝对误差为 9.31×10^{-7}，最大相对误差为 1.88×10^{-6}。这一比较直接验证前馈光路的数值关系。

11 权重与状态的等价翻译

11.1 固定传输系数与几何内容

对原模型每个线性映射 W，逐项以式 (58) 建立符号路由和透射系数，使用原始参数的位模式作为固定表面索引。平衡探测保持 Wx，因而各投影、输出门控和前馈变换可按原层顺序组合。对完整注意力，几何写入器同时编码 $W_K x_j$ 的地址信息和 $W_V x_j$ 的内容信息。两组信息由同一历史实例的可逆几何坐标承载，探测器命中后恢复原始高维通道。

对有限 FP32 坐标，写为 $x = (-1)^s 2^e m$，其中 $m \in [1/2, 1)$。令 $B(\cdot)$ 表示截断到 BF16 的有效位模式，

$$m_1 = B(m), \qquad m_2 = B(m - m_1), \tag{62}$$

$$m_3 = m - m_1 - m_2, \qquad \mathcal{C}(x) = (s, e, m_1, m_2, m_3). \tag{63}$$

三个分段覆盖 FP32 的全部有效位，m_3 亦可由 BF16 精确表示；解码取 $(-1)^s 2^e (m_1 + m_2 + m_3)$。零值保留符号标记，次正规数通过有效位移和指数恢复。每个分段对应固定 BF16 表面的几何索引，从实际 RT 测量缓存读取后按位恢复。当前 2048 维查询使用 1024 对坐标。历史地址与内容按 GQA 的共享组保存，各组坐标用式 (63) 的可逆编码表示。源模型的 GQA 共享关系、逐头归一化、旋转位置编码和输出门控按原有参数及顺序保留。一次查询发射一条基本入口光路，沿因果时间表面连续读取完整有效贡献，通过共同参考通道形成式 (71) 的比值。这一工作点采用完整贡献覆盖；路径增益使用对当前查询共同的尺度，从而保持各贡献间的原始比例。

11.2 递推场的光学状态翻译

原模型的 gated-delta 层先对三组投影施加四点因果卷积与 SiLU，再对每头的查询和键作原有 L_2 标定。记这些信号为 q_t, k_t, v_t，门控系数为

$$\beta_t = \sigma(W_b x_t), \tag{64}$$

$$\alpha_t = \exp\big[-\exp(A_{\log})\ \mathrm{softplus}(W_a x_t + d_{\mathrm{bias}})\big]\,. \tag{65}$$

递推场 S_t 的光学更新定义为

$$S_t^- = \alpha_t S_{t-1}, \tag{66}$$

$$m_t = \mathcal{O}_{(S_t^-)^{\mathsf{T}}}(k_t), \tag{67}$$

$$\Delta_t = \beta_t \odot (v_t - m_t), \tag{68}$$

$$S_t = S_t^- + k_t \Delta_t^{\mathsf{T}}, \tag{69}$$

$$o_t = \mathcal{O}_{S_t^{\mathsf{T}}}(q_t/\sqrt{d_k}). \tag{70}$$

场系数以可逆几何索引保存，读取复用固定表面的真实 RT 测量。衰减调节传输，内容差形成写入光强，外积更新场系数。输出随后经过原有逐头 RMS 标定、SiLU 门控和光路输出投影。

命题 6 (递推场的等价)**.** 以相同初始状态和卷积历史开始，式 (70) 与原模型 gated-delta 更新具有相同状态与输出。

证明. 平衡光路线性等价给出 $m_t = (S_t^-)^{\mathsf{T}} k_t$ 和 $o_t = S_t^{\mathsf{T}} q_t/\sqrt{d_k}$。因此每一步的衰减、校正差和外积写入均与原更新相同。由初始状态及逐步归纳，全部状态和输出保持一致。 □

11.3 完整词表的光强读出

对最终高维状态 h，完整词表探测器使用 $\ell = \mathcal{O}_{W_{\mathrm{LM}}}(h)$。共同增强尺度 C 给出 $I_v = \exp(\ell_v + C)$，比较对数强度可稳定得到

$$\arg\max_v I_v = \arg\max_v \ell_v.$$

完整分布由同一参考通道读出 $p_v = I_v / \sum_u I_u$。全词表均保留原始方向、范数和系数，几何角度由这些高维参数在前向时形成。各层算子与最终词表读出共同保持原模型映射，其实现精度由逐层数值对照和整段生成比较检验。

12 完整注意力、强度比值与选择模型

12.1 完整 Transformer 注意力

对一个 full-attention 头，令

$$s_{ij} = \frac{q_i^{\mathsf{T}} k_j}{\sqrt{d_k}} + b_{ij}, \qquad A_{ij} = \exp(s_{ij}), \qquad o_i = \frac{\sum_{j \le i} A_{ij} v_j}{\sum_{j \le i} A_{ij}}. \tag{71}$$

掩码项以 $A_{ij} = 0$ 表示。这一算子同时包含得分、全部有效项的加权值与共同分母。本机 Qwen3.5 2B 配置包含 6 个 full-attention 层与 18 个线性注意力层；式 (71) 的算子命题针对完整 softmax 头。整体等价验证以原模型实际各层及最终输出为参照。

12.2 内容与参考通道的充分条件

命题 7 (强度比值的完整注意力等价)**.** 固定查询 i。若光路系统满足以下条件，则经标定的内容信号与参考信号比值等于式 (71)：

1. 每个 $A_{ij} > 0$ 的项均有完整贡献；等价分组时保留该组贡献的精确总和。
2. 存在对所有贡献项共同的 $c_i > 0$，使有效强度为 $I_{ij} = c_i A_{ij}$。
3. 几何内容读出满足 $\Phi_\theta(G_j, \gamma_{ij}) = v_j$，且内容与参考通道使用相同的路径增益与标定。
4. 各路在探测端按强度线性相加，有符号内容由平衡探测或等效标定通道读出。

证明. 经标定后，内容信号与参考信号为

$$N_i = \sum_{j \le i} I_{ij} v_j = c_i \sum_{j \le i} A_{ij} v_j, \qquad R_i = \sum_{j \le i} I_{ij} = c_i \sum_{j \le i} A_{ij}. \tag{72}$$

由 $R_i > 0$ 得 $N_i/R_i = o_i$。有界有符号通道可分为非负正、负光强并在探测端取经标定的差，从而保持同一个线性分子。 □

因此，强度层只进行增强与传播，归一化由共同参考信号的比值完成。严格等价同时要求完整权重覆盖和原值信息的几何恢复。各坐标块提供局部几何初始化，完整块贡献按式 (4) 汇合，内容恢复遵循式 (3)。

12.3 最近命中与稀疏候选

最近交点模型输出一个可见记录的几何内容，多分支模型输出有限路径集合 $\mathcal{C}_i$ 的聚合内容。这是由原生 RT 可见性支撑的选择模型。若在候选内保留完整分数和值，可定义

$$o_i^{\mathcal{C}} = \frac{\sum_{j\in\mathcal{C}_i} A_{ij} v_j}{\sum_{j\in\mathcal{C}_i} A_{ij}}, \qquad \varepsilon_i = \frac{\sum_{j\notin\mathcal{C}_i} A_{ij}}{\sum_{j\le i} A_{ij}}. \tag{73}$$

对非空候选且 $\|v_j\| \le M_v$，精确保留候选内得分和值时，有

$$\|o_i - o_i^{\mathcal{C}}\| \le 2M_v\varepsilon_i. \tag{74}$$

这是因为完整输出为 $(1-\varepsilon_i)o_i^{\mathcal{C}} + \varepsilon_i o_i^{\mathrm{rest}}$，两个条件均值的范数都不超过 M_v。几何分数与内容的数值误差，用原模型分支误差、输出分布距离和任务表现共同度量。单次概率模板采样的期望由式 (38) 给出，其统计目标由发射密度、可见区域和几何内容共同确定。

13 共享模板、出现实例与路径缓存

13.1 共享边界与跨分支因果寻址

共享缓存由历史边界 BVH $\mathcal{B}_H$ 与因果地址 BVH $\mathcal{B}_Q$ 组成，共同服务同一模型进程中的对话分支。模型、几何版本和因果内容建立复用命名空间。输入端点、输出端点、公共前缀与中间边界进入 $\mathcal{B}_H$；历史按 16 个位置组成不可变块 B_i，保存量化光路包、位置标记和共享 BLAS。前缀 P 的紧凑边界标记为

$$\mathcal{M}(P) = \big(\mathrm{id}(P), \mathcal{R}(P), h_P, \mathcal{Q}_P\big), \tag{75}$$

其中 $\mathcal{R}(P)$ 为公共历史块引用，$h_P \in \mathbb{R}^D$ 为最终高维探测行，$\mathcal{Q}_P$ 为已验证的因果地址。各分支接入同一组公共块，完整块直接复用同一 BLAS，尾块承载新增位置；当前递归场 S_{live} 由原生传播维护。

每个解码位置在 $\mathcal{B}_Q$ 查询完整因果身份。命中节点返回 $(s_{t+1}, \mathcal{Q}_{t+1})$，下一步继续按后继地址查询；新光路通过原生 GPU 传播形成所需数值状态并写入新的因果节点。令 $\mathcal{U}$ 为各分支引用的唯一历史块集合，H 为边界数，则

$$M_{\mathrm{shared}} = \sum_{B\in\mathcal{U}} |B| + 4DH + O(H). \tag{76}$$

高维行保留原始数值位模式，量化光路包沿用 Q4_K / Q6_K 编码；$D = 4096$ 时每个高维行占 16384 bytes。

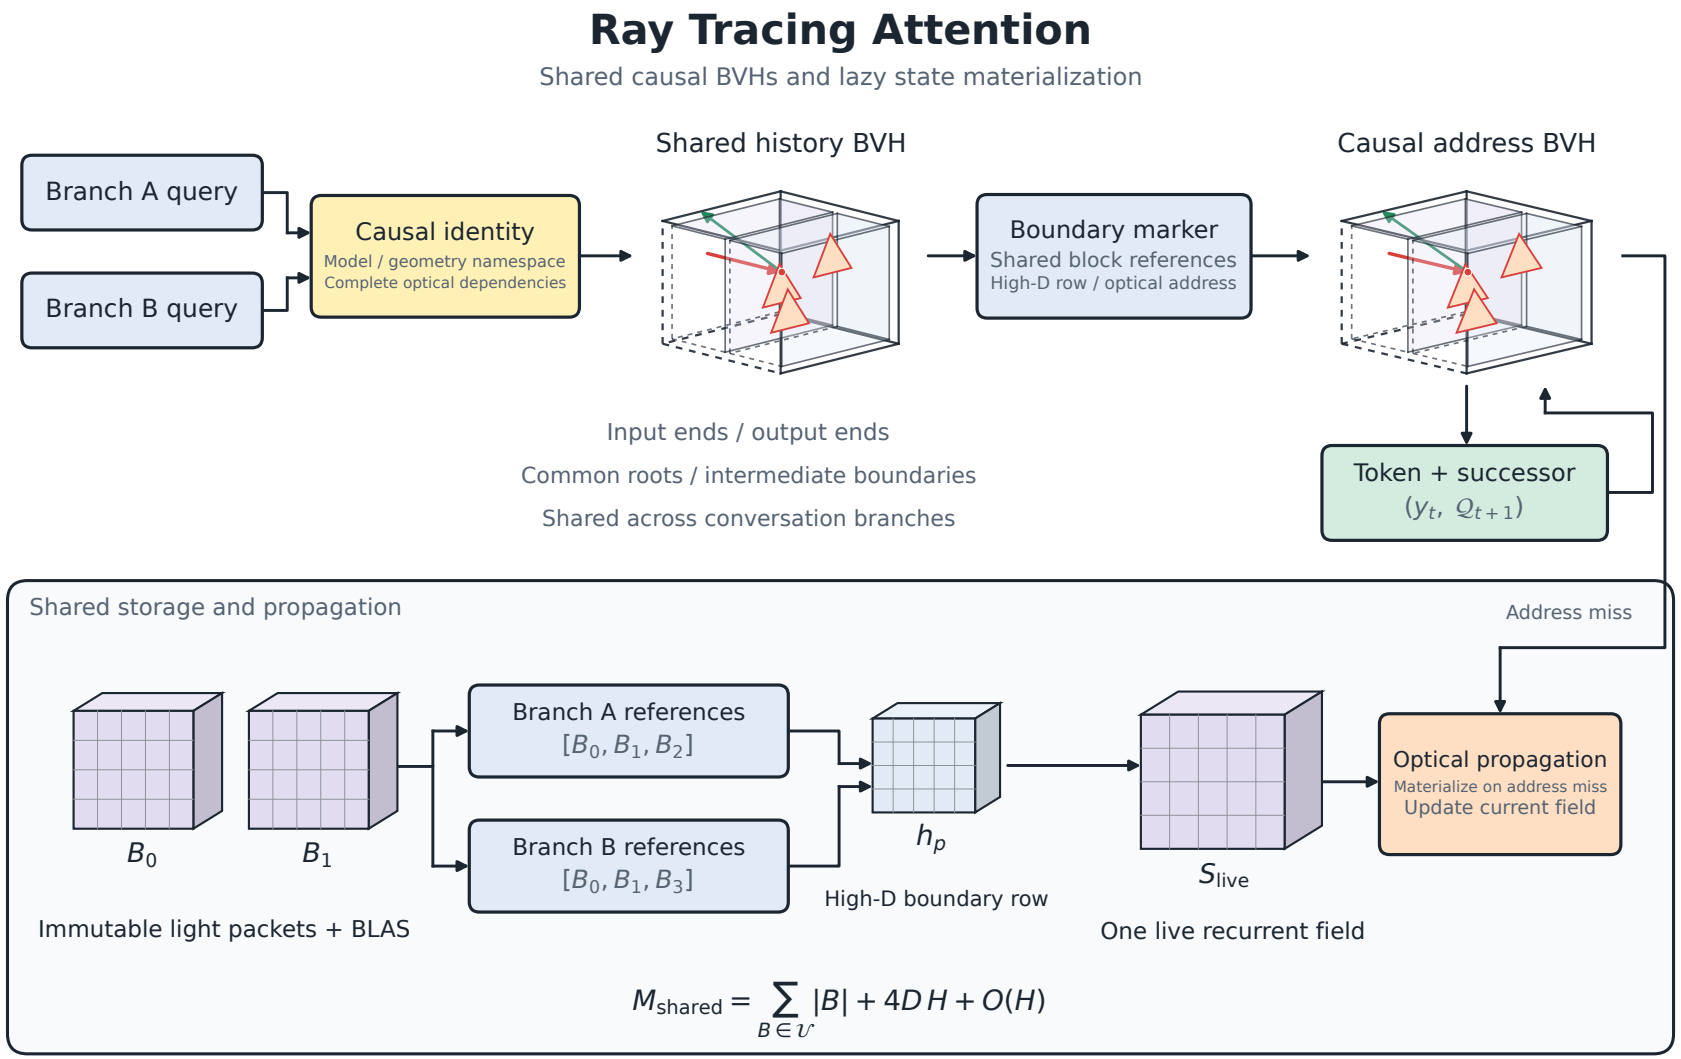


图 5: 共享因果 BVH 算子。公共历史以块引用连接各分支，边界标记提供高维读出行和因果地址，地址树返回词元及后继地址。当前递归场按需参与原生传播。

13.2 模板复用与重复贡献

共享词元模板 T_v 保存基础几何、角度和幅度参数，第 j 次出现实例保存

$$\mathcal{I}_j = (s_j, j, \tau_j, \Delta G_j, \xi_j). \tag{77}$$

其中 τ_j 是位置与姿态变换，ΔG_j 是上下文形状变化，ξ_j 是时序及光路状态。静态模板可作为共享 BLAS，历史出现以 TLAS 实例和必要的上下文几何表示。需要独立变形的实例使用自身的几何数据或形状模板族，实际存储规模取决于这种表示的自由度。

命题 8 (共同内容的强度合并)**.** 对固定查询 i，若出现组 g 中所有项的几何内容读出相同，即 $\Phi_{ij} = \Phi_{ig}$，则令

$$I_{ig} = \sum_{j \in g} I_{ij} \tag{78}$$

可精确保留该组在内容分子与参考分母中的贡献：

$$\sum_{j \in g} I_{ij}\Phi_{ij} = I_{ig}\Phi_{ig}, \qquad \sum_{j \in g} I_{ij} = I_{ig}. \tag{79}$$

如果 m_g 个副本具有相同键、位置作用、得分和内容，该组以 $m_g I_{ij}$ 的增强强度保留完整注意力中的重复贡献。共享模板与合并强度由不同条件控制：词元 ID 定义基础模板身份，当前上下文、时序与有效路径定义贡献是否可合并。各次历史出现保持独立身份，并在满足共同内容条件时压缩其累积读出。

13.3 Q 查询标记与原生路径回执

传统 KV 缓存常以层、头和出现位置组织记录。RT 使用完整查询描述作为 Q 标记：

$$\mathcal{Q}_i = (o_i, d_i, i, \mathrm{occurrence}_i, \mathrm{sceneID}, \nu_{\mathrm{scene}}, \nu_{\mathrm{lens}}, \mathrm{queryMode}). \tag{80}$$

其中包含射线、查询位置、场景身份及几何版本。查询模式包含实例掩码、距离范围、最大段数与面朝向规则。发射前按 $\mathcal{Q}_i$ 查找路径缓存，未命中时交给原生 RT 查询，并保存真实命中与路径回执；缓存体由原生查询返回的几何结果构成。相同词元基础方向可共享码本，完整 Q 标记还包含本次出现和场景状态。新增历史实例或透镜移动更新相关几何版本。Q 标记组织读取身份，历史内容仍由共享词元模板与独立出现实例承载。

13.4 拓扑缓存与数值缓存

一条路径的拓扑记录为

$$\chi_\gamma = ((\mathrm{instance}_0, \mathrm{primitive}_0), \ldots, (\mathrm{instance}_L, \mathrm{primitive}_L)). \tag{81}$$

共享模板几何、历史出现实例与光路结果缓存构成三个复用层次。拓扑缓存复用命中身份和传播结构，对当前输入相关的射线重新计算交点、法向、长度和增强。Q 路径回执的拓扑部分只依赖几何查询条件，光强可由当前上下文重新计算。其有效域需要保证没有新的最近遮挡或路径切换；可由同一原生 RT 查询验证，或由已验证的稳定可见域证书限定。缓存有效性检查与当前数值重算计入执行开销。

完整数值缓存的依赖键至少包含

$$\mathcal{K}_\gamma = (\mathcal{Q}_i, \nu_{\mathrm{param}}, \nu_{\mathrm{context}}, \nu_{\mathrm{gain}}, \mathrm{detector}, \mathrm{mode}). \tag{82}$$

这里 $\mathcal{Q}_i$ 包含射线起点、方向和查询域，场景版本包括实例生命周期和几何变更，参数版本包括角度、透镜与共享探测映射。上下文、发射与独立增强的状态指纹覆盖所有会改变强度或内容的状态。依赖一致时才能直接复用完整数值；拓扑一致则允许复用结构并重算当前值。最终词元相同只固定词元身份，路径复用按式 (82) 的依赖关系决定。

13.5 紧凑数值光路包与即时恢复

每个历史出现的原生命中回执提供层、共享组、时序槽位和表面身份。数值载荷以规范光路包保存有限 FP32 坐标的完整位模式。令 bits_{32} 与 float_{32} 为互逆的位重解释，一对坐标的包与恢复为

$$P(x_0, x_1) = \big(\mathrm{bits}_{32}(x_0), \mathrm{bits}_{32}(x_1)\big), \qquad D(P(x_0, x_1)) = (x_0, x_1). \tag{83}$$

由包中的符号、指数和有效位可重建式 (63) 的三个 BF16 表面引用；直接位恢复是该编码的精确逆映射。回执定位数值包，探测时恢复当前需要的通道。各层完整高维输出由探测器即时形成，并作为下一层输入。历史常驻存储保留共享数值包，恢复出的高维历史通道使用瞬时寄存器。

具有 H_Q 个查询头、H_G 个共享组的 GQA，令 $g(h) = \lfloor h/(H_Q/H_G) \rfloor$。头 h 读取组 $g(h)$ 的同一地址与内容包，共享关系与源模型一致。数值包占用为

$$M_{\mathrm{packet}}(C) = L_A C \, (2 H_G d_h) \, b, \tag{84}$$

其中 L_A 是保存完整历史的层数，C 是环形窗口容量，d_h 是每头维度，b 是每个坐标的字节数；因子 2 对应地址与内容。本配置 $L_A = 6, H_G = 2, d_h = 256, b = 4$，因此每个历史词元为 24576 bytes，$C = 300$ 时为 7.03 MiB。相比按 24 层、8 个头展开几何并保存解码副本的 337.50 MiB 表示，共享光路包将这部分存储缩减 48 倍。相同 FP32 精度下，源模型 GQA 历史数值具有相同的 24 KiB/词元规模；BF16 的对应规模为 12 KiB/词元。压缩收益来自共享出现表示、规范编码及瞬时恢复。

递推层的场系数也采用式 (83) 的规范编码，只为实际递推层分配场；其常驻规模由头数和场维度决定。MLP 探测器以真实命中的特征 ID 直接读取原有 down 传输系数，并行汇合后形成高维输出。gate/up 系数在前缀计算中复用于四个查询，down 使用原始连续系数布局，临时探测仅保留汇合所需的局部信号。

13.6 有效检查点上的最短恢复路径

令图 $G = (\mathcal{S}, \mathcal{E})$ 的节点表示一个具有完整数值依赖的有效状态或输出检查点，节点身份包含式 (82) 的版本。边表示经过验证的精确操作：状态恢复、下一步完整传播，或由原生 BVH 回执确认后直接读出已保存的词元队列。每条边由其起点保留的充分状态产生终点，代价 $c_e \geq 0$ 为实测的恢复、查询和传播时间。对当前有效检查点集合 $\mathcal{S}_0$ 和请求目标 s_*，选择

$$(s_0, \gamma_*) = \operatorname*{arg\,min}_{s \in \mathcal{S}_0, \, \gamma : s \rightsquigarrow s_*} \sum_{e \in \gamma} c_e. \tag{85}$$

这是非负边权的最短路径问题。已有完整输出的依赖匹配时，直接输出边沿后继地址继续查询；共享边界接入历史块并恢复高维行，当前进程保留一份递归场。新光路由原生传播物化所需的数值状态；当前场依赖一致时直接继续计算。完整注意力的各条非零路径仍在传播边内共同汇合，最短路径选择的是恢复与复用计划。

固定窗口采用预分配槽位，绝对时序标记标识每次出现。写入新词元覆盖已离开窗口的槽位，数值包驻留容量保持 C。以 N 表示已处理词元数，有

$$M_{\text{live packet}}(N) = 24576 \min(N, C), \qquad M_{\text{reserved packet}} = 24576 C. \tag{86}$$

实验分别记录有效载荷增长、预分配设备显存和驱动报告的实际驻留显存，并在相同窗口及明确精度下比较源模型。

13.7 分块传播与资源生命周期

前缀以 $B_w = 32$ 个词元为一块，按因果次序经过各层。每块继承已有历史光路包、卷积边界和递推场，其探测输出完整恢复到高维后传入下一层。上一块的末态与数值历史是下一块的充分状态。由各层的因果性和式 (70) 的递推等价，分块传播与整个前缀的传播保持相同结果。查询、归一化信号、键的写入中间值和 MLP 信号共用固定大小的计算工作区；键完成几何写入后，其工作区供探测器读出复用。历史命中回执只保存实例索引，每个回执为 4 bytes。回执矩阵的容量为 $4B_w(C+1)$ bytes，随窗口线性增长。

实际历史场景为每个完整注意力层建立一个入口域，每 16 个历史实例构成一个 BLAS，故

$$n_{\mathrm{BLAS}} = 6\left\lceil \frac{C}{16} \right\rceil, \qquad n_{\mathrm{TLAS}} = 6. \tag{87}$$

射线掩码、背面裁剪与光程范围直接限定原生 BVH 查询的有效域；探测器按硬件返回的实例与特征回执读取数值包及固定传输系数。共享组在传输系数中也保存一次，高维恢复时映射回各个查询头。

权重以 64 MiB 上传块流入设备。静态词表、特征、透镜和标量场完成建树后释放构建 scratch；上传暂存完成后释放。动态历史场景保留增量更新所需的构建工作区。诊断用的逐层快照与回读空间按请求生成并在读出后释放。计算状态的长期规模由历史光路包、递推场及有效检查点决定。

13.8 长编码任务的独立测量

在 RTX 5060 Ti 上，输入 190 个词元，窗口为 1024，输出预算为 4096，请求生成标准库 JSONL 日志分析 CLI。RT 与原模型分属独立进程，回复缓存关闭。RT 使用 BF16 固定系数与 FP32 探测；源模型分别以 BF16 和 FP32 运行，使用相同窗口和绝对位置。表中的已加载请求包含前缀计算与全部生成，冷启动另含分词和模型加载。

实现	输出词元	冷启动秒	已加载词元/秒	新增峰值 MiB
RT 光路包	1433	24.77	64.60	4482
源模型 FP32	1433	55.76	32.41	7550
源模型 BF16	4096	145.38	31.38	4060

RT 的 1433 个输出词元与源模型 FP32 逐项相同。持续生成的 GPU 探测吞吐为 69.56 词元/秒，设备分配为 4101050368 bytes，整段生成的分配增量为 0。驱动测得持续生成的新增驻留为 4462 至 4464 MiB。固定传输系数为 3767362720 bytes，历史光路包为 24 MiB，历史场景为 2912256 bytes，递推场及分块帧为 20987904 bytes。静态建树 scratch 与上传暂存的持续生成驻留均为 0。编码输出及 CLI 功能验收保存在同一实验记录中。

300 窗口的早期完整场检查点配置中，缓存关闭和开启的新增峰值分别为 4355 与 4494 MiB；两个检查点合计 55456672 bytes。缓存命中直接读出 32 个词元的 GPU 耗时中位数为 9.664 微秒，计入前缀恢复为 0.244736 毫秒。该读出与原先完整计算的词元及最终隐藏状态一致，并通过后续生成的终态恢复验证。

13.9 长上下文的显存增长对比

用已处理词元数 N 与窗口容量 C 分别描述历史增长和预留容量。令 $n = \min(N, C)$，本模型的 6 个完整注意力层、2 个共享组和 256 维头给出

$$M_{\mathrm{RT,live}}(N, C) = 24\, n \text{ KiB}, \tag{88}$$

$$M_{\mathrm{KV,FP32}}(N, C) = 24\, n \text{ KiB}, \tag{89}$$

$$M_{\mathrm{KV,BF16}}(N, C) = 12\, n \text{ KiB}. \tag{90}$$

在窗口填满前，每新增词元的历史有效载荷增长分别为 24、24 和 12 KiB；填满后，环形历史的有效容量保持 C。RT 以规范数值光路包保存 FP32 信号，源模型按共享 GQA 保存相应 KV。在同一数值精度下，共享组的完整信息量给出相同的载荷斜率。此前展开几何与常驻解码副本的历史载荷为 $1152n$ KiB；规范光路包的增长斜率为其 1/48。

表 1 按式 (90) 计算不同容量的历史有效载荷，数值统一使用 MiB。固定传输系数、递推场和计算工作区另计；历史 BVH、命中回执和显存池分配见原生实测。较大容量行按相同层数、共享组数和精度作容量推算。

表 1: 历史载荷随上下文容量的增长：固定架构的容量计算（MiB）

窗口 词元数	RT FP32 光路包	源模型 FP32 KV	源模型 BF16 KV	旧 RT 展开历史
300	7.03	7.03	3.52	337.50
1024	24	24	12	1152
2048	48	48	24	2304
4096	96	96	48	4608
8192	192	192	96	9216
32768	768	768	384	36864

总设备分配还包含实际加速结构与分配粒度。令 M_{fixed} 包含固定系数、递推场及 32 行计算工作区，则 RT 的窗口相关存储可写为

$$M_{\mathrm{RT,device}}(C) = M_{\mathrm{fixed}} + 24576C + M_{\mathrm{AS,hist}}(C) + 128(C+1) + M_{\mathrm{aux}}(C) + M_{\mathrm{pool}}(C). \tag{91}$$

这里 $128(C+1)$ 为 32 行、每项 4 bytes 的历史命中回执，M_{aux} 为时序标记及输入控制，M_{pool} 为对齐与预留空闲区。历史场景采用 $6\lceil C/16 \rceil$ 个 BLAS 与 6 个 TLAS；容量增加时复用已有显存池的空闲区，设备分配呈阶梯增长。

在 RTX 5060 Ti 上，以同一 190-token 编码提示和 16 个生成词元，关闭回复缓存、关闭逐层诊断，独立运行各容量。表 2 记录首次前缀计算后 Vulkan 原生设备分配和有效历史场景。各容量的输出均与已保存的源模型 FP32 前 16 个词元一致。三个窗口中，持续生成阶段的原生设备分配增量均为 0 bytes。

图 6 左侧展示至 32K 的载荷容量计算，右侧使用长编码任务的实际历史记录。右侧窗口固定为 1024：RT 预留 24 MiB 光路包；源模型 FP32 和 BF16 的动态 KV 随词元数增长，达到窗口后分别保持 24 和 12 MiB。原模型逐批记录的载荷斜率实测为 24576 与 12288 bytes/词元。RT 的预留量和当前有效载荷按 C 与 n 分别统计，使长期增长、固定窗口复用和总设备分配具有明确的比较口径。

图 7 给出同一长编码任务的整体显卡驻留轨迹。纵轴为驱动报告的显卡使用量减去各独立进程

表 2: RT 原生窗口容量实测：预分配设备存储（MiB）

窗口词元数	光路包	历史 BVH 场景	原生设备分配
300	7.03	0.84	3887.07
1024	24.00	2.78	3911.07
2048	48.00	5.53	3935.07

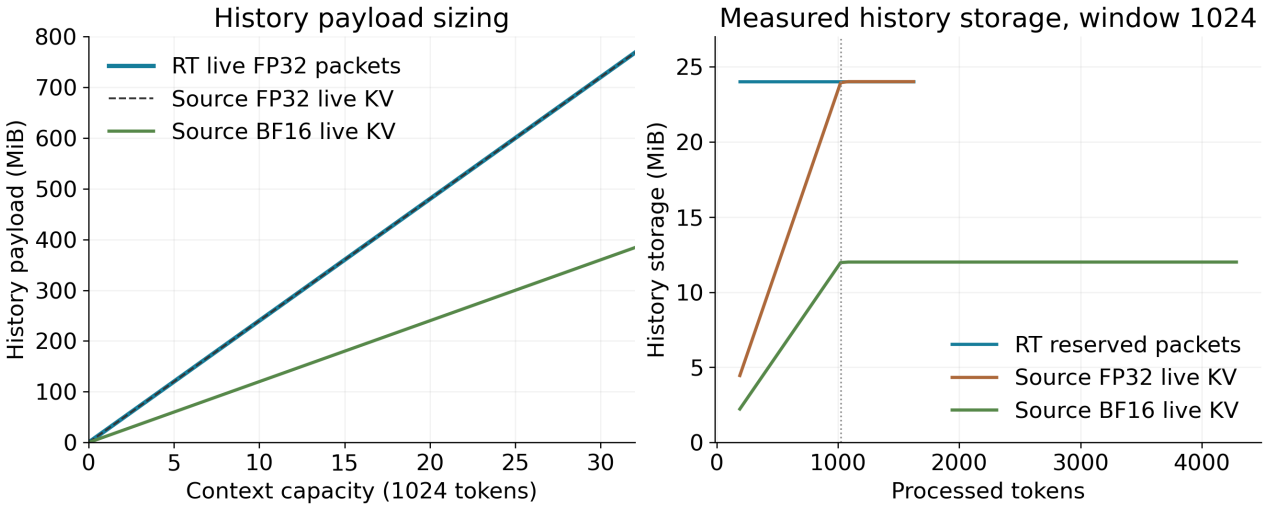


图 6: 长上下文历史存储。左：固定模型尺寸的容量推算；右：1024 窗口长编码任务的 RT 预留光路包与源模型动态 KV 实测。RT 与 FP32 KV 保留同精度的历史数值；BF16 每坐标使用两字节。

加载前的基线，因此同时包含固定权重、数值状态、加速结构、工作区和驱动分配。RT 保留 BF16 系数与 FP32 探测，源模型分别采用 FP32 和 BF16。三个进程使用相同 1024 窗口；曲线长度由实际生成的词元数决定。RT 持续生成驻留为 4462 至 4464 MiB，原生设备分配增量为 0。源模型的动态历史在窗口填充阶段增长，图中的窗口边界与式 (90) 对应。整体驻留和历史载荷两组图共同描述总显存规模与随词元数变化的部分。

本节容量实测覆盖 300、1024、2048 三个原生窗口。逐批实验记录同时保存历史载荷、原生设备分配与驱动驻留，为容量表及各条增长曲线提供独立来源。

13.10 原生 BVH 裁剪与实际存储

原生 RT Core/BVH 执行射线与包围层次的相交测试、候选定位和最近命中，遮挡通过同一个场景的射线查询语义决定。查询后只读取所需命中的内容有效负载。BVH 裁剪降低遍历和有效负载访问量；遍历代价取决于空间分布、包围盒重叠和查询方向，按实测统计给出。

底层显存由共享模板、历史实例、独立变形几何、加速结构和缓存共同组成：

$$M_{\text{state}} = M_{\text{template}} + M_{\text{instance}} + M_{\text{deform}} + M_{\text{AS}} + M_{\text{cache}}. \tag{92}$$

共享 BLAS、实例复用、有效实例生命周期管理与实际几何压缩降低存储量。一次查询的裁剪更新访问集合，几何驻留和释放由实例生命周期与内存管理控制。运行评测分别统计驻留显存、读取字节、候选数量、命中数量和缓存命中率。

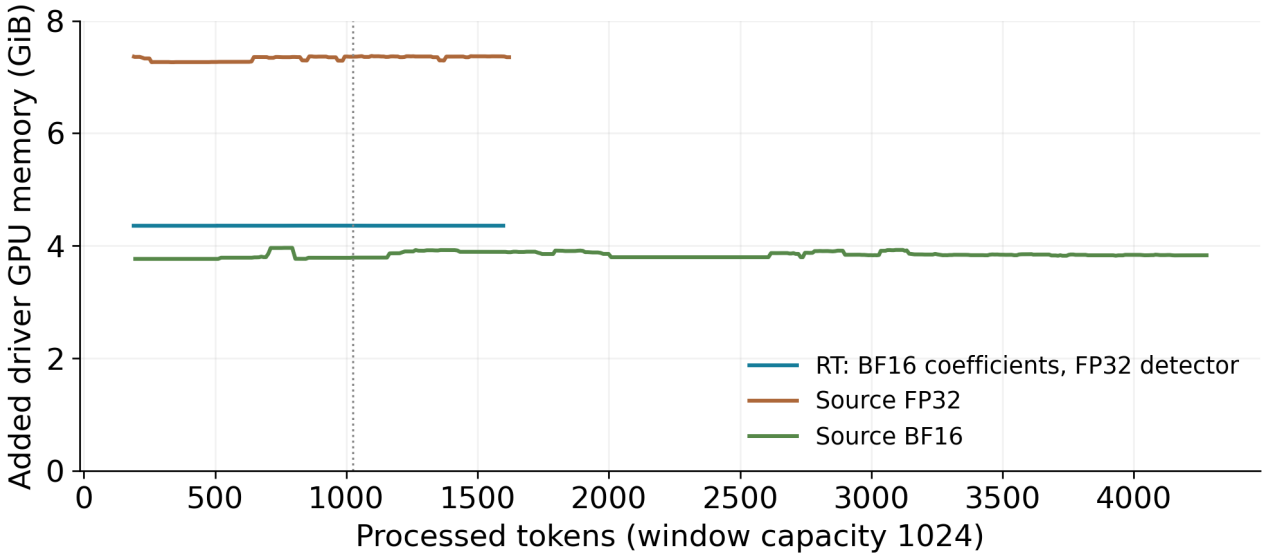


图 7: 同一 1024 窗口长编码任务的整体显卡驻留实测。各曲线扣除本次进程加载前的显卡基线；虚线表示窗口填满的位置。RT 与源模型独立运行，回复缓存关闭。

13.11 硬件加速结构与光强执行

设备端将几何组织、空间查询和探测计算连接成一条光路：

$$G_\ell \xrightarrow{\text{Build/Update}} \mathcal{A}_\ell = (\mathrm{BLAS}_\ell, \mathrm{TLAS}_\ell) \xrightarrow{\mathrm{RT}(Q_{\ell t})} \mathcal{H}_{\ell t} \xrightarrow{\mathcal{D}_\ell} y_{\ell t}. \tag{93}$$

G_ℓ 保存图元、实例变换和固定系数的索引，$\mathcal{A}_\ell$ 是 Vulkan 原生加速结构，$\mathcal{H}_{\ell t}$ 是实际求交返回的实例、图元和光程，$\mathcal{D}_\ell$ 执行命中后的传播、增强、平衡探测及高维恢复。历史、透镜、标量传输、MLP 特征、词表和回复缓存均采用这一加速结构接口。

几何准备程序写入顶点与实例缓冲，由 `vkCmdBuildAccelerationStructuresKHR` 提交 BLAS/TLAS 的设备构建或更新。查询程序通过 `rayQueryInitializeEXT` 和 `rayQueryProceedEXT` 发起硬件 BVH 遍历与图元求交，实例域、射线掩码、背面与光程共同限定访问范围。RT Core 承担空间遍历和求交，命中着色程序承担折射、光强乘法与探测汇合；批量线性传输经 Vulkan cooperative matrix 调用 Tensor Core。三个计算单元通过同一设备缓冲与依赖屏障衔接。

对一次命中集合，光强探测为

$$S_r^+ = \sum_{\gamma \in \mathcal{H}_r} I_\gamma^+, \qquad S_r^- = \sum_{\gamma \in \mathcal{H}_r} I_\gamma^-, \qquad y_r = S_r^+ - S_r^-. \tag{94}$$

对应式 (58)，固定传输项与当前发射强度在命中程序中相乘，并在探测端形成正负通道差。MLP 的门控与升维共享输入批次，在同一分块内产生式 (61) 的幅度耦合，随后进入降维探测。固定特征几何的首次 RT 回执可由各位置复用；完整贡献配置覆盖全部参与神经元，按回执读取原始压缩系数。

最后一层恢复得到 $y_t \in \mathbb{R}^m$，输出发射器随此前向状态产生词表射线。词表 BVH 返回带词元 ID 与分块 ID 的图元回执，固定压缩系数给出 $s_{tv} = \sum_b (P_b y_t)^\mathsf{T} (P_b w_v)$，探测比较确定最大信号的词元。所有块平面组织为同一个原生 AABB BLAS，TLAS 以单个根实例复用整个词表场。原生 BVH 返回局部包围盒候选，命中程序在该候选内计算块平面的交点，光程和交点归属共同给出平面命中回执。位掩码分别记录每个词元的分块命中，块载荷在共享响应下逐通道恢复，各块的贡献在同一词元探测器中汇合。完整词表工作点保持所有词元参与比较，几何查询的词元身份、分数和输出顺序由原模型映射验证。已验证的因果回复节点将上下文查询地址直接映射到下一词元，沿硬件 Tree

命中时复用该节点已经完成的模型计算。

13.12 索引并行预填充与设备恢复

给同一层的输入位置 t 和历史分段 s 分配查询索引 (t, s)。同批查询分别写入自己的命中行，探测器按照 $j \le t$ 的因果域读取历史。几何写入在批量投影后并行进行，所属层的加速结构更新完成后，所有已就绪位置的查询并行提交。各行经过光强归约恢复高维状态，再作为下一层的完整输入。这一调度保留层间的数据依赖，并展开层内的位置、头、通道和历史分段。

完整注意力的探测采用分块在线汇合。若旧分块的最大对数光强为 m，参考强度为 R，内容信号为 C，新分块分数为 a_j，恢复内容为 v_j，则

$$m' = \max\bigl(m, \max_j a_j\bigr), \tag{95}$$

$$R' = e^{m-m'} R + \sum_j e^{a_j - m'}, \tag{96}$$

$$C' = e^{m-m'} C + \sum_j e^{a_j - m'} v_j, \qquad z = C'/R'. \tag{97}$$

分数与内容仅取自对应的有效 RT 回执。共同尺度在内容与参考信号的比值中消去，增益轨道保留最大对数光强与参考值，物理增强沿用前述光路定义。分块过程共享压缩系数读取和历史光路解码工作，全部参与项的最终比值对应完整注意力算子。

原生预填充默认每批 512 个位置，门控/升维融合，历史光路打包与 Q/K/V 投影均按位置索引并行。递归光学场按列分组，每组以 subgroup 内的四个执行通道协作更新。相同设备工作区承载相邻层的恢复信号，历史保留 Q4_K 地址与 Q6_K 内容包。共享边界接入历史块与高维行，已验证的因果地址直接参与解码查询；新光路在当前 GPU 传播中形成所需递归场。扩容后迁移历史光路与实例，重新构建迁移区域的加速结构，后续通过原生 BUILD 维护受影响的 BLAS 与所属 TLAS。

13.13 9B 模型的原生预填充实测

2026 年 11 月 9 日，在 NVIDIA GeForce RTX 5060 Ti 上，QwenFlash 9B 的 32 层模型采用原始 Q4_K/Q6_K 权重载荷，预填充使用 FP16 cooperative matrix 算术与设备端探测汇合。初始历史容量为 1024，位置批量为 512，回复缓存关闭。各工作量预热后测量两次，表 3 给出 GPU 计时中位数与对应吞吐。

表 3: 9B 完整模型的原生预填充。吞吐由位置数除以 GPU 时间得到。

输入位置数	GPU 时间（ms）	吞吐（token/s）	完整历史 Tree 更新次数
25	70.53	354	8
256	91.18	2808	8
1024	375.40	2728	16

同卡、同源 GGUF 的 llama.cpp Vulkan（构建 `7d7f02875`）使用 FP16 历史与 FlashAttention，256 和 1024 位置分别测得 2535 和 2679 token/s。RT 实测中的 1024 位置以两个批次执行，八个完整历史层共更新 16 次，每个位置在每个完整历史层形成一个行级查询地址。底层射线按历史分段展开，行级查询数与实际射线数分别统计。

数值验证保留 FP32 参照与独立 CPU 算子检查，比较相同输入在选词前的逐层状态，另行验证

缓存重放的一致性。FP16 运算顺序与历史再量化共同影响浮点误差。32/128 维头的小模型、非对齐前缀、1/2 位置尾批及连续扩容均已验证；32 维头采用 subgroup 探测归约，批量投影继续复用矩阵分块。9B 的三项 300-token 编码与说明任务通过输出检查，已生成的 LRUCache 类通过读写和淘汰行为检查，三项任务的前 64 个词元缓存重放均与本次计算一致。预填充时延、状态数值误差和任务输出分别保存为独立实测记录。

13.14 完整分块词表与解码并行实测

QwenFlash 9B 的隐藏宽度为 4096，完整坐标选择器产生 16 个块，每块包含 128 个双坐标包。编译索引为 280 bytes。词表包含 248320 个词元，所有词元块形成 3973120 个 AABB 图元，由一个 BLAS 与单根 TLAS 组织；每个输出位置发出 124160 次块域查询。静态词表场驻留为 244010240 bytes，即 232.71 MiB，其中包围盒数据为 95354880 bytes，构建 scratch 在首次前向后释放。

两条验证状态的前两个坐标均为零，其余完整坐标分别来自词元 1000 与 2000 的原输出权重。各自的分块查询与探测分别选中这两个词元；零状态按词元 ID 决胜规则选中 0。完整状态的拼接逆变换与抽样输出系数均逐位一致。整数乘法与 LRUCache 两项无缓存对照分别生成 95 和 320 个词元，与固定原生基线的全部输出一致，生成 GPU 吞吐分别为 39.42 与 37.75 token/s。

解码将查询、键、门控和内容投影分别绑定原格式的专用量化内核，独立目标缓冲的投影在同一设备提交中执行，完成后统一建立后续读取依赖。MLP 的量化传输从三个连续元数据字同时解出相邻组的尺度与最小值，由一个压缩数据字恢复八个传输系数，保持原始系数数值和各通道的乘加次序。同一二分查找输入的 48 词元剖析结果见表 4；优化前后全部输出词元一致。

表 4: 9B 单词元解码剖析。阶段时间为各词元平均 GPU 毫秒。

指标	基准调度	专用投影与共享解码
输入投影与几何准备	7.85	5.22
输出投影与 MLP	20.20	15.36
完整词表读出	3.36	3.44
生成吞吐（token/s）	30.50	39.36

13.15 CLI 端到端生成与因果缓存实测

端到端测试通过原生 CLI 的 JSONL 流式接口执行。外部观察程序在写入提示时记录 t_{submit}，在收到第一个词元事件和最终回复事件时分别记录 t_1 与 t_{reply}。定义

$$\tau_1 = t_1 - t_{\mathrm{submit}}, \qquad T_{\mathrm{request}} = t_{\mathrm{reply}} - t_{\mathrm{submit}}, \qquad r_{\mathrm{request}} = \frac{N_{\mathrm{out}}}{T_{\mathrm{request}}}. \tag{98}$$

该时间范围包含分词、几何初始化或前缀恢复、Tree 扩容、预填充、逐词元生成、进程通信、文本解码、日志及最终回复序列化。进程启动至运行时就绪的时间独立记录。每个词元事件携带一个原生输出词元，最终回复中的词元序列与流式接收序列逐项核对。

本轮使用 QwenFlash 9B、RTX 5060 Ti、原始 Q4_K/Q6_K 载荷与完整 16 块词表场。初始历史容量与预填充批量均为 512，每次原生流式请求预算为 32。运行时启用日志与 GPU 遥测，使用已有编译缓存。首次请求完成模型计算并写入因果回复路径，随后以同一前缀重放一次。初始化后的普通计算在独立关闭回复缓存的运行时中，完成一次相同请求后再计时。

两项编码任务分别为 OrderedDict 实现的 LRUCache，以及含 92 行 Vulkan Python 运行时代码的短读取与 EOF 审查。输入分别为 41 与 1818 个词元；LRUCache 在 300 词元预算处结束，代码审查在 266 词元处输出结束标记。表 5 给出外部观察程序测得的完整请求吞吐。

表 5: 9B CLI 端到端吞吐。单位为 token/s，输出数在各项计算与重放中保持一致。

任务	输出词元	首次请求	初始化后计算	因果缓存重放
LRUCache	300	30.50	36.10	9248
长代码审查	266	18.01	20.63	8261

LRUCache 首次完整请求为 9.835 秒，初始化后计算为 8.310 秒，缓存重放为 32.440 毫秒。长代码审查对应 14.771 秒、12.896 秒和 32.201 毫秒。首次请求包含一次性场景与管线准备；长输入的 Tree 从 512 扩为 2048，生成时继续扩为 4096。初始化后重新执行完整输入，长代码审查的预填充 GPU 时间为 824.79 毫秒，普通生成 GPU 吞吐为 22.64 token/s。

表 6: 同一 CLI 请求的首词元延迟。单位为毫秒。

任务	首次请求	初始化后计算	因果缓存重放
LRUCache	1514.66	97.74	2.13
长代码审查	2326.74	884.74	4.35

进程启动到运行时就绪分别为 3.295 与 3.241 秒。另一个 25 词元输入的二分查找任务输出 128 词元，普通生成 GPU 为 38.48 token/s，CLI 逐词元生成为 36.90 token/s，因果缓存重放的完整请求为 10014 token/s。每个流式事件携带一个词元，结束事件与接收序列逐项一致。

三项缓存重放的全部 694 个输出词元与各自首次计算一致，编码任务在关闭缓存后的完整输出也与上述输出逐项一致。每次重放的缓存词元数等于输出词元数，MLP 特征与词表计算回执均为零，原生设备分配增量为零。在 LRUCache 与长代码审查的首次生成中，历史、词表、MLP 与缓存查询着色区间分别占生成 GPU 时间的 6.16% 与 3.59%。生成后的原生设备分配分别为 6239.69 与 6283.94 MiB，包含模型载荷、完整分块词表、设备工作区、历史加速结构与回复缓存。

上述实测采用图 1 所示的完整模型算子连接。

13.16 共享边界的四轮编码任务实测

同一模型进程依次分析 TTLCache、根据失败测试回执修复、补充续期测试、运行工具并总结。四轮输入为 203、472、959、1228 个词元，输出为 41、67、132、41 个词元。四次回答各异，真实工具完成五项测试，缓存开启和关闭的全部 281 个输出逐词元一致。公共历史分别检索到 0、196、465、952 个前缀位置；状态补算与直接输出命中分别计时计数。

该配置的设备分配为 6189.19 MiB，关闭缓存为 6173.19 MiB。边界行按式 (76) 增长；公共块以引用复用，模型、当前递归场、历史场景和工作区分别计入设备分配。

返回四个已计算分支时，281 次因果地址查询全部命中，逐词元输出为 12996 token/s，历史接入的 GPU 时间合计为 4.328 ms。每步沿后继地址继续，MLP 与词表新计算回执均为零。四轮首词元时延为 3.45、9.61、7.06、9.57 ms。新光路任务生成吞吐为 29.60 token/s，完整请求吞吐为 22.89 token/s。

表 7: 各轮回复结束后的共享边界存储。

输入词元	边界数	高维行载荷（bytes）	共享块与场景（MiB）
203	3	49152	3.88
472	8	131072	9.32
959	14	229376	19.00
1228	19	311296	24.26

表 8: RTX 5060 Ti、QwenFlash 9B 四轮编码任务实测。

执行方式	新光路请求	返回已计算分支	含真实工具调用
输出词元	281	281	281
完整耗时（ms）	12276.87	52.69	263.13
吞吐（token/s）	22.89	5333	1068

14 几何词表输出与编译验证

14.1 词元身份与光强排序

LM Head 编译保留词元 ID、分块 ID、各双坐标包与原始压缩传输系数。输出查询由最终高维状态 y_i 形成，原生 BVH 命中返回实例与图元身份，固定系数的光路探测按照式 (5) 恢复词元分数。共同增强尺度 C_i 使

$$J_{iv} = \exp\left(\sum_b (P_b y_i)^\top (P_b w_v) + C_i\right), \qquad \widehat{s}_{i+1} = \arg\max_{v\in\mathcal{W}} J_{iv} = \arg\max_{v\in\mathcal{W}} y_i^\top w_v. \tag{99}$$

相同分数采用与原模型一致的词元 ID 决胜规则。词元地址与高维系数共同组成编译资产，输入嵌入和输出头共享权重时复用同一份固定载荷。

相交分区或目标实例定义候选集合 $\mathcal{C}_{\mathrm{vocab}}(y_i)$。完整词表最优项的候选覆盖率为

$$\mathrm{Recall@1} = \mathbb{E}_{y_i}\left[\mathbf{1}_{\{\arg\max_{v\in\mathcal{W}} y_i^\top w_v \in \mathcal{C}_{\mathrm{vocab}}(y_i)\}}\right]. \tag{100}$$

原始范数按式 (5) 保留在分数中。各块候选定位的效果由完整块覆盖率与候选数量共同度量，直接几何选词则由完整原模型输出一致性评估。全词表地址初始化、高维分数恢复和词表候选召回分别作为独立验证阶段。

记第 b 个块的实际平面命中词元集合为 $\mathcal{C}_b$，查询批次的词元覆盖率与块覆盖率分别为

$$r_{\mathrm{token}} = \frac{|\bigcup_b \mathcal{C}_b|}{V}, \qquad r_{\mathrm{block}} = \frac{\sum_b |\mathcal{C}_b|}{VB_P}. \tag{101}$$

输出探测器返回一个词元，查询工作量由上述两个覆盖率与系数读取规模描述。完整贡献工作点有 $r_{\mathrm{token}} = r_{\mathrm{block}} = 1$；候选工作点同时记录覆盖率、最终最优词元召回与输出一致性。硬件内部 BVH 节点访问量作为独立遍历指标，平面命中回执计数统计实际图元贡献。

14.2 固定权重编译检查

编译逐层读取原始权重格式，保存投影形状、量化块布局、系数位模式与词元顺序。几何索引与固定传输系数通过确定性映射关联，各层恢复后的高维状态按原有依赖顺序进入下一层。对同一输

入，依次比较原模型与原生光路的中间状态、最终 logits 与输出词元，并检查相同分数的决胜规则和因果缓存重放的一致性。

14.3 验证协议与性能指标

验证按数学目标分别报告：

1. 全词表与各坐标块覆盖、复合身份唯一性、拼接逆变换及原始位模式恢复。
2. 固定光路的解析求交、反射、强度及内容读出误差，以及内容/参考比值对完整注意力的数值误差。
3. 稀疏候选的权重覆盖、原模型输出一致率、分布距离、分支误差和独立语言任务表现。
4. 共享模板与独立出现的语义更新、重复贡献合并、拓扑缓存验证和场景变更后的数值缓存失效。
5. 在明确硬件、精度、前缀长度、批量和候选规模下，报告前缀写入、首词延迟、持续生成吞吐、BVH 更新、有效负载读取和驻留显存。

离线词表转换、原生几何计算验证与原模型任务对照形成相互衔接的阶段。固定权重、词元身份与光路数值关系通过同一组输入验证，输出质量、路径规模与实际硬件代价共同描述模型的可用工作点。